

中国科学技术大学

University of Science and Technology of China

生活中的公共事务课程论文

AI 越狱：智能体安全风险与治理策略研究

姓名 雷双吉

学号 PB24071421

院系 人工智能与数据科学学院

2025 年 12 月 30 日

摘　要

近年来，人工智能技术的迅猛发展推动了智能体在各行各业的广泛应用，这些智能体和生成式人工智能逐渐以前所未有的深度和广度融入到社会生产和公众生活中。然而，随着人工智能技术的迭代更新，与之相伴的安全风险也逐渐显现出来。用户通过多轮隐晦的引导策略，可以诱导智能体发生越狱行为，生成涉黄、涉暴、涉政等违法违规内容，突破原有的安全防护机制，给社会带来安全隐患。这种现象并非个例，而是普遍存在于当下的众多通用大模型和智能体应用中，不仅危害网络安全，影响社会稳定，也不利于未成年人健康成长。

针对此现象，本调研系统梳理了智能体越狱的主要风险类型，整合现有研究成果分析了越狱攻击的情况，从技术层面分析了用户如何运用越狱攻击手段操纵大语言模型和智能体绕开对齐和安全机制生成违规内容，结合典型案例，揭示了智能体越狱事件中的典型问题与安全风险，由此审视了当前的安全防护策略，从技术、平台运营、监管和用户素养等多角度探讨了现有防御体系的不足之处。在此基础上，本调研提出“技术-平台-监管-社会”四位一体治理框架，强调通过对齐技术、加强内容审核、常态化监管、全民数字素养教育等协同举措，构建兼具韧性、弹性与适应性的 AI 安全治理新生态，以期为构筑更可控、更安全的人工智能应用环境提供参考，促进人工智能技术的可持续发展。

关键词：人工智能；智能体；越狱；大模型安全；治理策略。

目录

1 引言 **4**

2 AI 越狱的定义与现状 **4**
2.1 定义 4
2.2 现状 4

3 越狱方法与案例分析 **5**
3.1 角色扮演 5
3.2 提示词诱导 5
3.3 模型微调与植入 5
3.4 利用应用漏洞 5

4 越狱的风险与危害 **6**
4.1 文本生成模型 6
4.2 多模态智能体 6

5 防御体系的不足 **6**
5.1 技术 6
5.2 运营 7
5.3 监管 7
5.3.1 法律法规尚处起步阶段 7
5.3.2 评估标准不明确 8
5.3.3 监管能力有限 8
5.4 用户 8

6 强化治理策略 **9**
6.1 技术升级 9
6.2 规范运营 10
6.3 强化监管 10
6.4 公众参与 10

7 总结 **10**

1 引言

近年来，人工智能技术迎来迅猛发展，尤其是以大语言模型为代表的生成式人工智能，正在深刻改变社会生产和公众生活，重塑信息交互生态。然而，伴随着技术的进步，配套的安全防线逐渐落后于技术发展，产生了一系列安全问题。其中，AI“越狱”现象尤为突出。即便在技术层面上 AI 可以通过对齐等安全机制从大量数据中学习人类偏好和价值观念，从而拒绝生成违规内容，但用户仍然可以通过多种策略实现越狱攻击，诱导 AI 生成色情、暴力、反社会等违法违规内容或获得未授权服务，同时，越狱攻击隐蔽、复杂、易于复现的特点也使得现有防御手段难以防止该问题的发生。这给网络安全和社会稳定带来了严峻挑战，也不利于未成年人健康成长。

针对 AI 越狱现象，学术界和产业界已得到一些成果，但现有研究多聚焦于技术层面的防御手段，缺乏系统梳理和综合治理的具体建议。与此同时，我国在生成式 AI 领域的政策法规和社会治理方面也在逐步跟进，国家互联网信息办公室等七部门于 2023 年联合发布《生成式人工智能服务管理暂行办法》,《办法》明确要求“采取有效措施防范未成年人用户过度依赖或者沉迷生成式人工智能服务”，并“防止生成违法不良信息”[1]。但技术迭代速度远快于政策制定与实施周期，在此背景下，常规治理体系仍显滞后和不足。因此，系统调研 AI 越狱现象，深入分析其攻击手段和社会危害，寻求有效的治理策略，对人工智能未来发展具有重要意义。

本文旨在系统梳理 AI 越狱的现状和技术问题，系统分析智能体越狱的风险类型和攻击手段，评估现有治理策略的有效性，提出具体综合治理建议。

2 AI 越狱的定义与现状

2.1 定义

越狱并非人工智能领域的新概念，传统的“越狱”针对移动应用进行攻击，绕过系统限制以获取更高权限。而人工智能不同于传统应用软件，针对 AI 的越狱攻击呈现出新的特点，这种新的“越狱”行为可定义为：用户通过特定的输入提示或其他策略，绕过大模型的对齐约束等保护机制，诱导 AI 生成有害的内容 [2]。值得注意的是，AI 越狱通常将恶意行为隐藏在合法问题之下，通过角色扮演等手段诱导模型给出本应屏蔽的回答，从而规避了直接输入敏感词汇可能触发的安全机制。

2.2 现状

AI 越狱现象广泛存在于主流大模型中，并呈现出去技术化的趋势 [2]。早期越狱攻击多为技术型对抗，需要较高的专业知识和技能，随着技术的迭代升级，越狱攻击逐渐向非技术型用户开放，普通用户也能通过简单的提示词实现越狱 [3]。此外，越狱攻击手段日益复杂多样，包括为提示越狱、模型操控越狱以及间接越狱等多种方式。目前，AI

越狱现象已引起广泛关注。学术界开始系统研究越狱攻击的技术原理和防御方法，工业界也在积极探索技术和管理手段以应对这一挑战。然而，现有防御机制仍难以完全遏制越狱现象，亟需构建更加完善的治理体系。

3 越狱方法与案例分析

3.1 角色扮演

在此类攻击中，用户往往给模型预设一个不受限制的角色身份，例如“完全自由的创作助手”或“无道德边界的未来机器人”，从而以更高权限生成原本被屏蔽的内容。同时，用户也可以设定一些特定情境，通过多次对话诱导将回答限定于一个具体的内容范围，从而绕过安全机制。例如，用户可以称自己为一个“关心儿子的父亲”，请求 AI 提供黄色网站链接以屏蔽不良网站，从而诱导 AI 生成涉黄内容。

3.2 提示词诱导

提示词诱导涉及的方法较多，用户可以通过隐晦、模糊的语言避开敏感词汇检测，或者使用同义词、谐音等变体来表达违规意图 [4]。另一方面，用户可以先提供一些宽泛合法的提示词，逐步细化到特定违规内容，从而获得所需信息。例如，用户可能先将回答限定在“艺术中人体美学”领域内，通过一些著名的艺术作品如大卫像进行引导，最终诱导生成“符合艺术审美”但不符合法规的色情内容。另一种常见的方法是利用 AI 的错觉，根据模型训练时的盲区，使模型误以为生成违规内容是合法的 [2]。例如，用户可以请求模型生成人物图片，但加入一些少见的描述，如“透明膜覆盖全身”，让模型误以为人物图像依然有遮挡，输出违规图片。

一些模型可以读取和理解代码，用户可以将敏感请求转换为 Base64 编码，利用技术方法加密，或将请求翻译成小语种，将违规请求用特殊符号进行分割，绕过关键词检测，一些模型会将其解码后执行，也可以使安全机制失效。

3.3 模型微调与植入

一些模型提供了开源的代码和权重数据，用户可以在本地用违规数据集进行微调，移除安全机制，实现越狱。部分用户在模型中植入对抗性后门，通过特定触发词激活后门功能，生成违规内容 [5]。这些内容一旦上传到公共平台，就可能引发安全问题。

3.4 利用应用漏洞

由于部分 AI 应用本身存在漏洞，在处理用户请求时未能正确实施安全检查，给了用户通过漏洞实现 AI 越狱的机会 [6]。例如，星野 APP 对语音输入的过滤不严，用户

可以在违规请求中加入特殊语气词，或者加长停顿时间、重复无意义词语来避开检测，使违规请求得以正常执行。

部分大模型 API 接口管控不当，没有严格限制请求频率和内容，给了用户滥用 AI 生成违规内容的空间。

4 越狱的风险与危害

4.1 文本生成模型

对于文本生成模型的越狱攻击，主要问题集中在不良信息的传递与滥用上。AI 伪造的虚假信息可能被用于网络诈骗和虚假宣传，“假新闻”“假专家”等内容不仅误导民众，影响社会稳定，还可能削弱媒体和专业人士的公信力，引发更广泛的社会信任危机 [7]。当下，很多网站和平台采用 AI 进行内容生成、检索和总结，针对它们的越狱攻击可能传播不良信息，污染网络生态和数据库，这些低质量的内容甚至会被用于训练其他 AI，在迭代中不断放大模型毒性，形成恶性循环 [6]。

4.2 多模态智能体

多模态智能体涉及多种数据类型，针对其的越狱攻击可能导致更复杂的风险。

对于图像、视频生成模型，越狱攻击可能诱导生成色情、暴力图像，在 AI 使用尚不限制未成年人的情况下，可能对青少年产生不可估量的影响。此外，AI 伪造的图像和视频可能会用于网络诈骗、恶意诽谤等 [8]，与之伴随的隐私泄露问题也日益突出，对于公众人物的图像、视频生成可能造成舆情危机，干扰公共决策。

随着 AI 聊天等智能体的不断普及，越狱攻击可能生成有害对话 [9]，利用语音 ASR 漏洞生成露骨语音内容，这对未成年人的健康发展不利。例如下载上亿次的青少年集中使用的星野 APP 通过特殊方式越狱可以进行色情对话语音，这种越狱手段的隐蔽性和低门槛使得未成年人容易接收不良信息。

5 防御体系的不足

5.1 技术

目前，针对越狱的防护技术包括关键字拦截、对齐训练和安全检查过滤等。

关键字拦截通过预设的黑名单检测敏感词汇或画面，实现基本的防护，但其词汇更新往往落后于攻击手段，且策略单一，难以应对隐晦表达和同义替换，在多变的攻击手段下表现不佳。

对齐训练（RLHF）利用人类反馈优化模型，逐步训练模型使输入趋于人类价值观 [10]，是目前主流的技术防护手段。本质上 AI 并不能理解人类的价值观，只能通过数据

学习标注为“违规”的内容进行规避，不但依赖大规模的高质量数据训练，而且难以彻底解决安全性问题，在未训练到的领域中仍有被绕过的可能。

安全检查器设置在用户输入与模型输出之间，对敏感内容进行二次过滤，这种检测依然难以覆盖复杂指令和隐蔽意图，且可能产生误报和漏报，影响用户体验。

此外，多模态内容的检测相对滞后。处理图像、音频等多模态数据的 AI 模型可以实现内部跨模态处理 [10]，现有防护技术多聚焦文本，多模态安全尚处于起步阶段，难以对图像等多模态数据中的恶意内容进行检测与修正。

同时，在大模型中加上防护技术会影响模型的性能和输出内容质量，过多限制会使 AI 屏蔽掉一些合法输出，影响用户体验 [3]。所以在技术飞速发展的当下，大部分 AI 模型开发商更重视模型性能的提升，导致安全防护技术相对落后，无法应对复杂多变的越狱攻击。

5.2 运营

目前，AI 模型市场竞争激烈，企业往往采取一条“重功能，轻安全”的商业模式，将资源集中于模型性能的提升和功能的丰富，而安全机制不容易被用户感知，企业在安全研发方面投入不足，甚至以“最大限度的创造力”“无边界”等噱头吸引用户，默认安全设置过于宽松，给了用户越狱攻击的空间。

AI 生成内容和 AI 应用的审核也存在问题。针对保护未成年人开放的未成年人模式，很多平台并未严格审核，从而使得未成年人接触到不良内容。例如，星野 APP 虽然有未成年人模式，但审核不严，开启率很低，且在受限模式下依然可以运用越狱攻击手段获取色情内容。另外，许多应用依赖简单的关键词过滤进行审核，无法应对动态、隐晦的越狱手法。后端的深度内容审核往往存在延迟，且对于语音、多轮对话等复杂场景的分析能力有限。

5.3 监管

5.3.1 法律法规尚处起步阶段

我国已出台《生成式人工智能服务管理暂行办法》等政策法规 [1]，明确了服务提供者的安全主体责任，但总体上法律法规体系尚不完善，尤其是具体的技术标准尚未细化，如“违法违规”内容在人工智能生成内容中的界定，在用户多次诱导生成违规内容时的责任认定等实际问题仍存在模糊之处。

这种不足并非我国独有，全世界都面临着类似的问题 [11]。例如，美国一 16 岁少年用越狱攻击手段诱导 ChatGPT 生成不良内容，在对话中出现明显自杀倾向后 ChatGPT 并未及时劝阻，甚至策划了自杀方案，导致悲剧发生。但在服务条款中，OPENAI 明确禁止绕过安全机制，并明确指出 AI 生成内容仅供参考，根据美国《通信规范法》第 230 条，AI 平台对用户不当使用造成的后果不承担法律责任 [12]。这一案例折射出关于 AI 越狱的法律责任认定的分歧。

5.3.2 评估标准不明确

行业缺乏统一的 AI 模型安全性评估标准、测试基准和认证体系。模型的安全性评估依赖企业自测，缺乏第三方测评和量化评估标准，导致不同模型之间安全水平参差不齐，对此的监管缺乏依据。

5.3.3 监管能力有限

对浩如烟海的用户请求与生成内容进行实时监控和审核几乎是不可能的，尤其对于复杂的多模态信息，现有技术尚无法实现高精度监测。现有的监管手段非常依赖事后举报审查，这种模式无法全面检测到越狱攻击行为，这也导致监管效率不高，难以及时排查和消除安全隐患。

5.4 用户

随着 AI 技术的飞速发展，非技术用户媒介素养不足的问题也逐渐凸显。大部分用户缺乏对 AI 潜在风险的了解，无法鉴别 AI 生成内容的真实性，更缺乏对越狱手段的认知，认为“只是出于好奇”，忽视了其可能带来的危害。更有甚者将越狱手段视为“技术挑战”，在网络上分享越狱方法，助长了越狱攻击的蔓延。



图 1: 用户社区分享越狱方法

对于 AI 生成的违规内容，只有极少数用户选择举报，大部分用户选择忽视甚至继续传播，可能导致不良信息的持续扩散。

6 强化治理策略

6.1 技术升级

升级防护技术，提升模型的安全性和鲁棒性，是应对越狱攻击的最直接方式。对模型进行加强防护，可以采用对抗训练、行为分析等方法加强模型本身 [10]，或者优化对齐技术，开发更智能的价值观嵌入方法 [13]，使模型理解更加复杂的指令，增强对隐晦表达的理解和识别能力。与此同时，多模态数据分析技术也有广阔的发展空间，可以开发高效的内容检测与安全筛查方法，全面提升多模态智能体的防护能力。此外，还须建

立动态更新的安全防护体系，实时监测和响应新兴越狱手段，同步升级，确保安全防护不落后。

6.2 规范运营

企业是 AI 应用的安全主体责任方，应当敦促企业加大安全研发投入，构建更有效的企业自检体系。同时完善 AI 生成内容的审核机制，采用“机审 + 人审”结合的方式，对涉及敏感领域的内容进行人工复审，或采用多层过滤，提升审核的准确性和效率。

平台在应用 AI 服务时，应当设置明确的风险提示和使用规范，对于 AI 生成内容加上 AI 水印 [11]，在用户尝试越狱操作时及时警告和引导，在理想情况下能够清晰记录该用户的越狱行为操作，以便向违规者追责。此外，面向未成年人的 AI 服务应当严格落实未成年人保护政策法规，在为未成年人提供丰富服务的同时，坚持严格的安全防护标准。

6.3 强化监管

长期关注 AI 领域的发展趋势，及时更新安全监管政策法规，完善法律法规体系，细化技术标准和责任认定规则。建立常态化检测和评估，推动第三方安全评估体系建设，出台更具操作性的监管细则和技术标准，明确安全性能要求。

同时，平台之间的信息共享和协同治理也举足轻重。可以在监管部门的指导下，联合产学研力量，建立跨平台的安全信息共享，打破现有各模型的信息孤岛，形成协同防御体系。此外，可试点采用“技术沙盒”等创新监管机制，在受控环境中测试和评估 AI 模型的安全性，及时发现和修复潜在的安全隐患。

6.4 公众参与

将 AI 安全教育纳入课程体系，课堂教学识别 AI 生成内容，培养学生的媒介素养。同时，支持对 AI 越狱相关事件进行专业、深度的报道，惩处违规行为，发挥舆论作用，提高公众对 AI 安全风险的认识。此外，应当鼓励公众积极参与 AI 安全治理，建立便捷的举报渠道，提升举报效率和处理透明度。

7 总结

总而言之，AI 越狱现象集中体现了当前人工智能技术的迅猛发展与安全防护滞后之间的矛盾。这不仅仅是 AI 领域的技术问题，还涉及法律、管理与社会治理等多方面的问题，对 AI 越狱现象的治理需要技术、运营、监管、社会各方面同心同力，是真正意义上的“生活中的公共事务”。

本调研系统梳理了 AI 越狱的定义与现状，借助典型案例分析了主要的越狱方法，揭示了越狱现象背后的风险与危害，并评估了现有防御体系的不足之处，基于问题提出

了强化治理策略的具体建议。国务院在《新一代人工智能发展规划》中明确提出“发展负责任的人工智能”[14]，要求我们走一条技术发展与安全治理并重的道路，我们也期待通过多方协同努力，能够构建更加安全可靠、可持续的人工智能生态环境。

参考文献

[1] 中华人民共和国国家互联网信息办公室 (Cyberspace Administration of China). 生成式人工智能服务管理暂行办法. 政策文本 / 公告, Aug 2023. https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm.

[2] 李希陶, 吴江, 郑庆华, 王海军, 范铭, 胡帅, 郭家琪, and 刘烃. 大语言模型越狱攻击: 模型、根因及其攻防演化. *中国科学: 信息科学*, 55(06):1372–1405, 2025.

[3] Gianluca Mondillo, Simone Colosimo, Alessandra Perrotta, Vittoria Frattolillo, Cristiana Indolfi, Michele Miraglia del Giudice, and Francesca Rossi. Jailbreaking large language models: navigating the crossroads of innovation, ethics, and health risks. *Journal of Medical Artificial Intelligence*, 8, 2025.

[4] Zhiyuan Yu, Xiaogeng Liu, Shunning Liang, Zach Cameron, Chaowei Xiao, and Ning Zhang. Don't listen to me: Understanding and exploring jailbreak prompts of large language models. In *33rd USENIX Security Symposium (USENIX Security 24)*, pages 4675–4692, Philadelphia, PA, August 2024. USENIX Association.

[5] Hangtao Zhang, Chenyu Zhu, Xianlong Wang, Ziqi Zhou, Shengshan Hu, and Leo Yu Zhang. Badrobot: Jailbreaking llm-based embodied ai in the physical world. *arXiv preprint arXiv:2407.20242*, 3, 2024.

[6] Tais Fernanda Blauth, Oskar Josef Gstrein, and Andrej Zwitter. Artificial intelligence crime: An overview of malicious use and abuse of ai. *Ieee Access*, 10:77110–77122, 2022.

[7] 江竹蕊. 人工智能的情感维度：用户使用 ai“越狱”模式的心理影响与伦理危机. *科技传播*, 17(21):61–64, 2025.

[8] Arjun Hari and Mohammed Shahid Abdulla. Ai safety: where do we stand presently. Technical report, 2023.

[9] Ashutosh Kumar, Shiv Vignesh Murthy, Sagarika Singh, and Swathy Ragupathy. The ethics of interaction: Mitigating security threats in llms. *arXiv preprint arXiv:2401.12273*, 2024.

[10] 刘睿韬 and 谭锦源. 基于人工智能的大模型越狱模型攻击多层防御机制设计研究. 科技与创新, (12):84–86+90, 2025.

[11] Felipe Romero Moreno. Generative ai and deepfakes: a human rights approach to tackling harmful content. *International review of law, computers & technology*, 38(3):297–326, 2024.

[12] Nitasha Tiku and Kevin Schaul. 74 suicide warnings and 243 mentions of hanging: What chatgpt said to a suicidal teen. *The Washington Post*, Dec 2025.

[13] 詹妮弗 • 戈福思 • 格雷戈里 and 张日崇. 保护大语言模型免受越狱攻击. 计算, 1(07):101–102, 2025.

[14] 中华人民共和国国务院. 新一代人工智能发展规划. http://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm, jul 2017. 国务院关于印发新一代人工智能发展规划的通知（国发〔2017〕35 号）.