2025 春《数据分析及实践》期末考试 参考答案

一、单选题（每题 3 分，共 30 分）

题号	1	2	3	4	5	6	7	8	9	10
答案	C	D	B	C	B	C	A	A	A	C

简要解析

1. C — 爬虫的标准流程为载入（下载）→ 解析 → 存储；检索属搜索引擎，不属于爬虫。
2. D — $H = -(0.2 \cdot \log_2 0.2 + 0.3 \cdot \log_2 0.3 + 0.5 \cdot \log_2 0.5) \approx 1.485 \approx 1.49$。
3. B — Min-Max 归一化把数据线性映射到 [0,1]。
4. C — A、B、D 均错；α 即犯第一类错误的概率（教材常表述为显著性水平 / 置信度）。
5. B — NoSQL 通常采用 BASE（最终一致性），不要求高度一致性。
6. C — TF = 词频，IDF = 逆文档频率（衡量整个语料库），算法简单，常用于关键词抽取。
7. A — 变异系数刻画的是离散程度，不属于集中趋势指标。
8. A — Precision = 80 / (80+40) = 66.7%；Recall = 80 / (80+120) = 40%。
9. A — CRPS 是概率 / 不确定性预测的评价指标；MSE / RMSE / MAE 是点预测指标。
10. C — 决策树是符号主义的典型代表；感知机、SVM 属于连接 / 统计学派。

二、简答题（每题 4 分，共 20 分）

1. 三种数据预处理方法及目的

方法：

(1) 数据清洗：处理缺失值（删除 / 插补）、异常值（盖帽 / 剔除）、重复值、噪声；

(2) 数据集成：合并多源数据，解决冗余、命名 / 单位冲突；

(3) 数据变换：标准化（Z-score）、归一化（Min-Max）、独热编码、离散化、对数变换等；

(4) （可补充）数据规约：属性约简 / PCA / 抽样。

为什么要预处理：现实数据普遍存在缺失、噪声、不一致和量纲差异，脏数据会直接降低模型精度甚至导致结论错误；预处理可提升数据质量、统一尺度、压缩规模，为后续建模提供可靠输入。

2. 特征工程的意义与流程

意义：“数据和特征决定了机器学习的上限，模型和算法只是逼近这个上限。”好的特征能显著降低模型复杂度、提升精度、增强可解释性，并减少过拟合风险。

主要流程：

(1) 特征理解与清洗：分析特征类型、分布、缺失情况；

(2) 特征构建 / 衍生：通过分箱、组合、统计聚合、文本 / 时间特征提取构造新特征；

(3) 特征变换：标准化、归一化、对数 / Box-Cox、独热编码等；

(4) 特征选择：过滤法（卡方、互信息）、包装法（RFE）、嵌入法（L1 正则、树模型重要性）；

(5) 特征降维：PCA、LDA、t-SNE 等。

3. 假设检验步骤及与参数估计的区别

步骤：

(1) 提出原假设 H_0 与备择假设 H_1；

(2) 选择检验统计量及其在 H_0 下的分布（如 z、t、χ^2、F）；

(3) 给定显著性水平 α（如 0.05），确定拒绝域；

(4) 由样本计算检验统计量的观测值或 p 值；

(5) 若落入拒绝域（或 $p < \alpha$）则拒绝 H_0，否则不拒绝。

维度	参数估计	假设检验
目标	估计未知参数“是多少”	判断关于参数的论断“对不对”
输出	点估计 / 置信区间	拒绝 / 不拒绝 H_0
思想	由样本推断总体取值	反证法 + 概率反例

4. ROC 的绘制方法与 AUC = 0.5 / 1 的含义

绘制方法：横轴为假阳率 FPR = FP / (FP+TN)，纵轴为真阳率 TPR = TP / (TP+FN)。将分类器输出的概率 / 得分按阈值从高到低逐一移动，每个阈值得到一对 (FPR, TPR)，连接所有点即得 ROC 曲线，起点 (0,0)、终点 (1,1)。

AUC = 0.5：分类器无判别能力，与随机猜测一样（曲线为对角线）。

AUC = 1：完美分类器，存在阈值能将正负样本完全分开。

5. KNN 基本原理与“非参数方法”的由来

原理：对待分类样本 x，在训练集中按某种距离度量（欧氏 / 曼哈顿 / 余弦）找出最近的 K 个邻居，由这 K 个邻居中出现最多的类别投票决定 x 的类别；回归任务则取 K 个邻居标签的均值。

为何称为“非参数方法”：KNN 不预先假设数据服从某个特定的参数化分布，也不学习一组固定数量的模型参数（如 w、b），其“模型”就是全部训练样本本身，决策完全基于局部邻域的数据分布；参数量不固定（随样本量增长），因此属于典型的非参数学习。

三、计算题（共 50 分）

1. 相似度计算（10 分）

$x_1 = (1, 1, 0, 1, 0)$，$x_2 = (0, 1, 1, 0, 1)$

① Jaccard 相似度

两者均为 1 的位置：仅第 2 位，|交| = 1；

至少一个为 1 的位置：第 1，2，3，4，5 位，|并| = 5；

$J(x_1, x_2) = 1 / 5 = 0.2$

② Cosine 相似度

点积 = 0 + 1 + 0 + 0 + 0 = 1；$\|x_1\| = \sqrt{3}$，$\|x_2\| = \sqrt{3}$；

$\cos(x_1, x_2) = 1 / (\sqrt{3} \cdot \sqrt{3}) = 1 / 3 \approx 0.333$

③ Euclidean 距离

$d^2 = 1 + 0 + 1 + 1 + 1 = 4$；$d = \sqrt{4} = 2$

④ Pearson 相关系数

均值：$\bar{x}_1 = \bar{x}_2 = 0.6$

中心化 $x_1 - \bar{x}_1 = (0.4, 0.4, -0.6, 0.4, -0.6)$

中心化 $x_2 - \bar{x}_2 = (-0.6, 0.4, 0.4, -0.6, 0.4)$

分子 $\Sigma = -0.24 + 0.16 - 0.24 - 0.24 - 0.24 = -0.80$

分母 $= \sqrt{1.2} \cdot \sqrt{1.2} = 1.20$

$r = -0.80 / 1.20 = -2 / 3 \approx -0.667$

2. 概率矩阵分解（PMF）的最大后验目标函数（10 分）

由贝叶斯公式：

$$p(U, V \mid R, \sigma^2, \sigma_U^2, \sigma_V^2) \propto p(R \mid U, V, \sigma^2) \cdot p(U \mid \sigma_U^2) \cdot p(V \mid \sigma_V^2)$$

其中：

$$p(R \mid U, V, \sigma^2) = \prod_{i,j} [\, N(R_{ij} \mid U_i^T V_j, \sigma^2) \,]^{I_{ij}}$$

$$p(U \mid \sigma_U^2) = \prod_i N(U_i \mid 0, \sigma_U^2 I), \quad p(V \mid \sigma_V^2) = \prod_j N(V_j \mid 0, \sigma_V^2 I)$$

取负对数并舍去常数项后，最大后验估计等价于最小化：

$$L(U, V) = (1/2) \cdot \Sigma_{i,j} I_{ij} (R_{ij} - U_i^T V_j)^2 + (\lambda_U/2) \cdot \Sigma_i \|U_i\|^2 + (\lambda_V/2) \cdot \Sigma_j \|V_j\|^2$$

其中 $\lambda_U = \sigma^2 / \sigma_U^2$，$\lambda_V = \sigma^2 / \sigma_V^2$，$I_{ij}$ 是评分指示函数。

含义：第一项是带观测 mask 的重建均方误差，后两项分别对 U、V 施加 L2 正则（来自高斯先验）。

3. Apriori 关联规则挖掘（10 分）

共 6 笔交易，min_sup = 33.34% × 6 ≈ 2，min_conf = 60%。

第 1 次扫描（$C_1 \rightarrow L_1$）

候选项	支持计数	是否频繁
{中性笔}	4	
{笔记本}	2	

{荧光笔}	2	
{矿泉水}	3	
{巧克力}	4	

第 2 次扫描（$C_2 \rightarrow L_2$）

候选项	支持计数	频繁?
{中性笔，笔记本}	2	
{中性笔，荧光笔}	1	
{中性笔，矿泉水}	2	
{中性笔，巧克力}	2	
{笔记本，荧光笔}	1	
{笔记本，矿泉水}	0	
{笔记本，巧克力}	0	
{荧光笔，矿泉水}	0	
{荧光笔，巧克力}	1	
{矿泉水，巧克力}	3	

第 3 次扫描（$C_3 \rightarrow L_3$）

由 L_2 连接并剪枝（任意 2 子集必须在 L_2 中）：

{中性笔，矿泉水，巧克力}：三个 2 子集均在 L_2 ；支持计数 = 2

其余 3 项集含有非频繁 2 子集，被剪枝；C_4 为空，算法终止。

所有频繁项集（共 10 个）：$L_1 \cup L_2 \cup L_3$

关联规则及置信度（★ = 强关联规则，置信度 ≥ 60%）

规则	支持度	置信度	强?
矿泉水 → 巧克力	50.0%	3 / 3 = 100%	★
笔记本 → 中性笔	33.3%	2 / 2 = 100%	★
{中性笔，矿泉水} → 巧克力	33.3%	2 / 2 = 100%	★
{中性笔，巧克力} → 矿泉水	33.3%	2 / 2 = 100%	★
巧克力 → 矿泉水	50.0%	3 / 4 = 75%	★
矿泉水 → 中性笔	33.3%	2 / 3 ≈ 66.7%	★
矿泉水 → {中性笔，巧克力}	33.3%	2 / 3 ≈ 66.7%	★
{矿泉水，巧克力} → 中性笔	33.3%	2 / 3 ≈ 66.7%	★
中性笔 → 笔记本	33.3%	2 / 4 = 50%	—
中性笔 → 矿泉水	33.3%	2 / 4 = 50%	—
中性笔 → 巧克力	33.3%	2 / 4 = 50%	—
巧克力 → 中性笔	33.3%	2 / 4 = 50%	—
中性笔 → {矿泉水，巧克力}	33.3%	2 / 4 = 50%	—
巧克力 → {中性笔，矿泉水}	33.3%	2 / 4 = 50%	—

强关联规则按置信度排序：

1. 矿泉水 → 巧克力 (100%)
2. 笔记本 → 中性笔 (100%)
3. {中性笔, 矿泉水} → 巧克力 (100%)
4. {中性笔, 巧克力} → 矿泉水 (100%)
5. 巧克力 → 矿泉水 (75%)
6. 矿泉水 → 中性笔 (66.7%)
7. 矿泉水 → {中性笔, 巧克力} (66.7%)
8. {矿泉水, 巧克力} → 中性笔 (66.7%)

4. 朴素贝叶斯分类（10 分）

训练样本：滑雪 = 是 共 4 条（第 4，6，7，8 天）；滑雪 = 否 共 4 条（第 1，2，3，5 天）。

(1) 先验概率

$P(是) = 4 / 8 = 0.5$，$P(否) = 4 / 8 = 0.5$

(2) 条件分布

滑雪 = 是	晴	雨	雪	≥ 50	< 50
计数	1	1	2	3	1
概率	1/4	1/4	2/4	3/4	1/4

滑雪 = 否	晴	雨	雪	≥ 50	< 50
计数	1	2	1	1	3
概率	1/4	2/4	1/4	1/4	3/4

(3) 三个待预测样本的分类

A. 晴天，≥ 50

$P(是) \cdot P(晴 \mid 是) \cdot P(\geq 50 \mid 是) = 0.5 \times 0.25 \times 0.75 = 0.09375$

$P(否) \cdot P(晴 \mid 否) \cdot P(\geq 50 \mid 否) = 0.5 \times 0.25 \times 0.25 = 0.03125$

$0.09375 > 0.03125 \rightarrow$ 预测：滑雪 = 是

B. 雨天，< 50

$P(是) \cdot P(雨 \mid 是) \cdot P(<50 \mid 是) = 0.5 \times 0.25 \times 0.25 = 0.03125$

$P(否) \cdot P(雨 \mid 否) \cdot P(<50 \mid 否) = 0.5 \times 0.5 \times 0.75 = 0.1875$

$0.03125 < 0.1875 \rightarrow$ 预测：滑雪 = 否

C. 雪天，< 50

$P(是) \cdot P(雪 \mid 是) \cdot P(<50 \mid 是) = 0.5 \times 0.5 \times 0.25 = 0.0625$

$P(否) \cdot P(雪 \mid 否) \cdot P(<50 \mid 否) = 0.5 \times 0.25 \times 0.75 = 0.09375$

$0.0625 < 0.09375 \rightarrow$ 预测：滑雪 = 否

5. ARIMA(1，2，1) 预测第 7 小时负荷（10 分）

原始序列 Y：500，504，509，515，520，528

① 一阶差分 $\Delta Y_t = Y_t - Y_{t-1}$

t	2	3	4	5	6
ΔY	4	5	6	5	8

② 二阶差分 $W_t = \Delta Y_t - \Delta Y_{t-1}$

序号	W_1	W_2	W_3	W_4
值	1	1	-1	3

模型形式：$W_t = \Phi_1 \cdot W_{t-1} + \varepsilon_t + \theta_1 \cdot \varepsilon_{t-1}$，其中 $\Phi_1 = 0.5$，$\theta_1 = -0.4$，$\varepsilon_1 = \varepsilon_2 = \varepsilon_3 = 0$。

③ 由 W_4 反推 ε_4

$W_4 = \Phi_1 \cdot W_3 + \varepsilon_4 + \theta_1 \cdot \varepsilon_3$

$3 = 0.5 \times (-1) + \varepsilon_4 + (-0.4) \times 0 \rightarrow \varepsilon_4 = 3.5$

④ 预测 W_5（即第 7 小时对应的二阶差分），预测期望 $E[\varepsilon_5] = 0$：

$$W_5^{pred} = 0.5 \times W_4 + 0 + (-0.4) \times \varepsilon_4 = 0.5 \times 3 - 0.4 \times 3.5 = 1.5 - 1.4 = 0.1$$

⑤ 还原到原始尺度

$$\Delta Y_7 = \Delta Y_6 + W_5^{pred} = 8 + 0.1 = 8.1$$

$$Y_7^{pred} = Y_6 + \Delta Y_7 = 528 + 8.1 = 536.1\ \text{MW}$$

—— 答案完 ——