第一章：数据科学基础

1.1 大数据的特点（4V）

- **数据量大（Volume）**：临界点通常为PB级别
- **数据种类多样（Variety）**：结构化、半结构化、非结构化
- **高实时性（Velocity）**：数据产生与处理速度快
- **数据价值巨大（Value）**：蕴含潜在商业或科研价值

1.2 科学范式

- **经验科学**：基于观察和实验
- **理论科学**：建立数学模型与理论
- **计算科学**：计算机模拟与数值计算
- **数据密集化科学**：以数据为中心的研究范式
- **第五范式**：智能化科研（AI辅助科研）

1.3 数据的未来：合成数据（Synthetic Data）

- **人为标注数据的缺点**：
  - 耗时耗力，成本高昂
  - 某些任务数据难以获取或标注
- **合成数据的定义**：基于计算机模拟或算法生成的人造数据，模仿现实世界观察
- **优势**：
  - 降低数据获取成本
  - 可控性强
  - 无隐私安全问题
  - 可减少真实世界的偏见
- **缺陷**：

缺点类别	具体问题
数据质量	真实性不足、过度简化、缺少长尾
偏差问题	放大原始偏差、固化不公平
模型退化	自噬循环、分布崩塌
评估困难	缺乏统一标准、下游有效性难验证
法律风险	版权争议、衍生作品界定
成本门槛	训练计算量大、需要专业团队
缺乏反馈	无法捕捉动态环境变化

1.4 大数据的未来：数据Prompt化

- 将各类数据（如图、表格）描述为文本，利用大语言模型（LLM）的自然语言理解能力处理
- **示例**：将二维图数据转为文本prompt，输入LLM解决图数据问题

1.5 什么是数据科学?

- 基于数学、统计学理论，运用计算机技术进行大规模数据计算、分析与应用的学科
- 另一种表述：用数据的方法研究科学，用科学的方法研究数据（鄂维南院士）

以下是根据您提供的完整PDF内容（第二章）进一步强化、补充和校订后的复习文档。文档严格遵循原章节顺序，统一了格式，并针对所有可计算的指标补充了详细公式、解释及例题。同时，保留了PPT中的示例与关键说明，删除了重复内容，确保内容准确、完整、易于复习。

第二章：数据入门

2.1 数据采集

2.1.1 检索与公开数据

- **搜索引擎**：百度（中文）、Google（英文）、Google Scholar、DBLP
- **Google Dataset Search**：2018年推出，专门搜索数据集
- **国内公开数据**：国家统计局、银保监会等
- **国际公开数据集**：
  - ImageNet（1400万图像）
  - Amazon AWS 公开数据集
  - YouTube 社交网络数据
- **代表性公开数据集**：
  - MovieLens（用户评分）
  - 头条文本分类数据集
  - 金融股票数据
  - SNAP（大规模网络数据）
  - ASSISTments、EduData（教育数据）
  - 阿里天池、KDDCup、NeurIPS Challenge

2.1.2 合成数据（Synthetic Data）

- **人为标注缺点**：耗时、昂贵、难获取
- **合成数据定义**：基于计算机模拟或算法生成的人造数据
- **优势**：低成本、可控、无隐私、减少偏见
- **代表**：MIT的Synthetic Data Vault
- **案例**：生成非洲服饰数据集解决数据偏差
- **Gartner预测**：到2030年，合成数据将完全超越真实数据用于AI模型

2.1.3 数据增强

- **合成数据**：无中生有（质量可能有损）
- **数据增强**：有中生更多（基于已有标注数据，安全可靠）
- **大模型增强**：利用LLM重构语义相似但不同的样本，如AugGPT

2.1.4 数据众包

- **定义：**一种利用大众力量来收集、分析和处理数据的模式
- **流程**：需求方分包 → 平台分发 → 大众标注 → 质量评估 → 返回
- **对比**：

类型	单人准确性	人员数量	耗时	费用
专家标注	高	少	久	高
众包标注	低	多	快	低

2.1.5 网络爬虫

基本概念

- **定义**：自动抓取网页信息的程序/脚本
- **行为**：载入 → 解析 → 存储（最复杂为载入）
- **URL**：统一资源定位符；**API**：应用程序接口

网页访问示例

- 用户 Request → 服务器 Response（HTML/JSON/XML）
- 协议：HTTP（明文）、HTTPS（加密，加入SSL层）

请求方式

- **GET**：参数放于URL（如 `http://www.adc.com?p=1&q=2`），不安全，长度受限
- **POST**：在向目标URL发送请求时，将参数放置在一个网络请求的报文头中。相比于Get，多了Form Data部分（请求体），更安全，常用于登录

响应状态码

- 200：成功；404：未找到；其他常见状态码

动态页面处理

- **Ajax异步请求**：需要浏览器渲染或用户操作触发
- **解决方案**：
  - 抓包分析（Charles等），模拟请求（快速但有难度）
  - Selenium/WebDriver（模拟浏览器，操作简单但慢）
  - 其他：Splash、Pyv8

反爬虫与应对

- **常见反爬**：验证码、账号/IP封禁、返回假数据
- **应对**：
  - 减少访问频率，去重
  - 多Cookie（识别用户）
  - 多IP（代理）

数据解析

- **格式**：HTML、JSON、XML
- **对比**：

特性	JSON	XML
可读性	简洁	规范
数据体积	小，传输快	大，传输慢
编码解码	容易	复杂（树结构）
数据描述	一般	更好
数据交互	与JS交互方便	适合跨平台

- **示例**：JSON对象与XML标签对比（原PPT有详细代码）
- 这里"数据描述"指的是**对数据含义、结构和约束的表达能力**。具体来说，XML在以下几个方面比JSON更强大：

能力	XML	JSON
属性（Attribute）	可为元素添加额外的元数据（如 `<price currency="USD">100</price>`）	无直接属性概念，只能通过嵌套键值对模拟
命名空间（Namespace）	支持，可合并不同来源的XML文档避免标签冲突	不支持
注释（Comment）	支持 `<!-- 注释 -->`	不支持（JSON标准中无注释）
实体（Entity）	支持预定义和自定义实体（如 `<` 表示 `<`）	不支持
混合内容	元素可包含文本和子元素混合（如 `<p>这是<b>重要</b>内容</p>`）	不能，值要么是纯文本，要么是嵌套对象/数组
数据类型验证	可通过DTD或XML Schema（XSD）定义复杂的数据类型、取值范围、出现次数等约束	JSON Schema虽存在，但非标准原生，功能较弱且普及度低
文档结构定义	DTD/XSD可严格规定元素的顺序、个数、嵌套层次	仅靠示例或外部文档描述，无强约束机制

XML可以精确控制数据和元数据的表达；JSON追求简单和易解析，牺牲了部分描述能力。在需要严格定义数据格式、进行数据校验、或处理复杂文档（如Office文档、电子病历、法律文书）时，XML的优势就体现出来。而在Web API、配置文件等场景，JSON更常见。

去重服务

- **Bloom过滤器**：二进制向量 + 多个哈希函数，通过多个hash函数将一个元素映射成一个位阵列（Bit Array）中的多个点。当所有哈希结果一致判定为重复数据。

常用爬虫工具

- **Java**：HttpClient，Jsoup
- **Python**：URLLIB（内置），BeautifulSoup（解析），Scrapy（框架）
- **可视化工具**：八爪鱼、火车采集器（合肥乐维）、数据堂

Robots协议与法律合规

- **Robots协议**（也称为爬虫协议、机器人协议等）的全称是"网络爬虫排除标准"（RobotsExclusion Protocol），网站通过Robots协议告诉爬虫哪些页面可以抓取，哪些页面不能抓取。
- `域名/robots.txt` 规定可爬取范围
- **法律**：
  - 2021年《数据安全法》
  - 2023年《生成式人工智能服务管理暂行办法》
- **禁止行为**：
  - 规避反爬措施 → 非法获取计算机信息系统数据罪
  - 干扰网站运营 → 破坏计算机信息系统罪
  - 爬取公民个人信息 → 侵犯公民个人信息罪
- **合规建议**：只采集公开数据，遵守用户协议，不侵犯隐私

2.2 数据存储

2.2.1 数据类型

- **结构化数据**：可以使用关系型数据库表示和存储的数据，拥有固定结构，如关系型数据库，二维表
- **半结构化数据**：弱结构化，虽然不符合关系型数据模型的要求，但是含有相关的标记(自描述结构)，分割实体及期属性。如XML、JSON，含标记
- **非结构化数据**：没有固定数据结构，或很难发现统一数据结构的数据，如文本、图像、视频、音频等

2.2.2 数据库基本概念

- **数据(Data)**：描述事物的符号记录
- **数据库(DB)**：长期存储、有组织、可共享的数据集合
- **数据库管理系统(DBMS)**：位于用户与OS之间的数据管理软件
- **数据库系统(DBS)**：DB + DBMS + 应用系统 + 管理员

2.2.3 关系型数据库（SQL）

特点

- 逻辑结构：二维表（行=元组，列=属性）
- 必须满足第一范式：每个分量不可再分（不允许表中套表）
- 优点：管理效率高（十万～千万级），存取路径对用户隐蔽

SQL语言

- 增删改查（INSERT、DELETE、UPDATE、SELECT）
- 示例：`INSERT INTO Student VALUES('200215126','张成民','男',18,'CS');`

完整性

- 实体完整性（主键唯一且非空）
- 参照完整性（外键约束）
- 用户定义完整性（如年龄范围）

安全性

- **自主存取控制(DAC)**：用户自主授权
- **强制存取控制(MAC)**：系统标记安全等级
  - 主体许可证 ≥ 客体密级 → 可读
  - 主体许可证 ≤ 客体密级 → 可写

索引

- 目的：加快查询
- 自动建索引：PRIMARY KEY，UNIQUE
- 索引结构：B+树（动态平衡）、Hash（快速查找）

关系模式的不足（冗余问题）

- 数据冗余（系主任重复存储）
- 更新异常（修改系主任需多处改动）
- 插入异常（新系无学生时无法插入系主任）
- 删除异常（学生毕业后丢失系主任信息）

2.2.4 NoSQL数据库

产生原因

- 数据量爆炸（GB→TB→PB）
- RDBMS范式、事务、磁盘I/O限制
- 开发需求不明确（如直播带货）

四大类型对比

类型	代表	适用场景	数据模型	优点	缺点
文档型	MongoDB	Web应用	文档（类似JSON）	无固定结构，灵活	查询性能不高，缺统一语法
键值型	Redis	缓存、计数器	哈希表	极快	数据无结构化
列存储	HBase	日志、分布式文件	列簇存储	高扩展，压缩好	功能局限，缺查询语言
图数据库	Neo4j	社交网络、推荐	节点+关系	免索引邻接，O(1)	不适合分布式

MongoDB 详解

- **特点**：C++编写，文档存储（BSON），支持索引，最像RDBMS的NoSQL
- **适用**：日志、博客、内容杂乱、大文件（GridFS支持>16M）
- **数据结构**：集合(collection) = 表，文档(document) = 行，字段无强约束
- **示例**：

```
{ "_id" : "BA18011000", "name" : "zhang san", "age" : 18, "class" :
["Math","Music"] }
```

- **常见操作**：`use db`, `show dbs`, `insert`, `find`, `remove`
- **与MySQL对比**：

对比	MongoDB	MySQL
模型	非关系型	关系型
存储	内存+持久化	引擎相关
事务	不支持	支持
成熟度	新兴	成熟

事实上，MongoDB从4.0版本开始支持事务了。

Redis 详解

- **数据结构**：key-value，value可为整数、字符串、列表、哈希表、二进制
- **操作示例**：
  - 数字：`SET counter 10` → `INCR counter` → `GET counter`
  - 队列：`RPUSH names "taylor"` → `LPOP names`
  - 哈希：`HSET user:1000 name "John"`
- **应用**：电商秒杀（避免超卖）、发布订阅、计数器

HBase 详解

- **列存储**：同一列数据存在一起
- **适用**：十亿级以上数据，大规模实时入库，大数据分析
- **注意**：传统数据库能解决则不用HBase（分布式有损耗）
- **扩展**：可支持SQL、图查询、Hadoop、搜索引擎

Neo4j 详解

- **图存储**：节点+关系，直接存储物理地址（免索引邻接）
- **性能**：深度5的朋友查询，MySQL需1543秒，Neo4j仅2.13秒（100万人，平均50个朋友）
- **Cypher查询示例**：

```
CREATE (n:person{name:"郭靖",age:"33"})
MATCH (n:person{name:"杨康"}) DELETE n
```

NoSQL vs RDBMS 总结

NoSQL	RDBMS
不仅仅是SQL	高度组织化
无声明性查询语言	SQL
无预定义模式	表结构固定
最终一致性	ACID
CAP定理	严格一致性

2.2.5 图像数据存储

- **方式一**：存储图片路径（本地文件系统）
- **方式二**：存储像素值（numpy数组、二进制）
- **图像表示**：彩色图 → 960×1280×3 数组（RGB），灰度图 → 960×1280 数组，每个值0~255

2.2.6 图数据存储

- **表示**：SQL表有冗余和大量空白；Neo4j符合图特性
- **免索引邻接**：直接物理地址遍历，O(1)性能

2.3 数据预处理

2.3.1 为什么需要预处理

- **脏数据来源**：不同应用、不同采集手段、不同格式
- **脏数据表现**：
  - 不完整（缺失值）
  - 不准确（错误值、噪声、离群点）
  - 不一致（编码差异、命名差异、重复记录）
- **举**
  例：同一主体的不同称呼、输入错误、内嵌控制信息、重复缺失、噪声、UCG数据（弹幕、颜文字等）
- **数据质量维度**：正确性、一致性、完整性、可靠性（3C1R）
- **工作量**：预处理占数据分析工作量的80%

2.3.2 数据清理

处理缺失值

- **缺失原因**：反爬虫、采集故障、存储故障、设计问题（如学生收入）
- **缺失类型**：
  - 完全随机缺失（无偏）
  - 随机缺失（与其他属性相关，如“期末成绩”依赖“平时表现”）
  - 非随机缺失（与自身取值有关，如高收入人群拒填工资）
- **处理方法**：
  - 删除（记录、属性、改变权重）

    - 填充：
        - 特殊值（NULL，mask）
        - 均值/中位数/众数
        - 热卡填充（找最相似样本并直接用该值填充）
        - KNN（K最近邻加权平均）
        - 回归模型预测
        - **EM算法**（期望最大化，适用于随机缺失）

注：关于三种缺失机制的进一步说明

完全随机缺失（MCAR）：缺失与任何已观测或未观测的变量均无关，例如仪器随机故障。此时删除缺失样本不会引起偏差。

随机缺失（MAR）：缺失的概率仅依赖于已观测到的其他变量，而与缺失值本身无关。例如，“期末成绩”缺失与否可能与“平时成绩”有关，但与期末成绩的具体分数无关。

“随机缺失”的“随机”是指：在给定所有已观测变量后，缺失与否相当于“随机”发生（就像抛硬币，但硬币的偏向可由观测数据完全决定），不再依赖于缺失值本身。因此**它是一种条件随机，而不是完全无条件的随机。**

非随机缺失（MNAR）：缺失的概率与缺失值本身有关。例如，高收入人群因收入过高而拒填工资，低收入人群因羞耻也不填。此时缺失机制不可忽略，需专门建模。

理解这三种机制是选择缺失值处理方法的前提：

MCAR → 可安全删除或简单填补

MAR → 推荐使用基于模型的填补（如回归、EM算法）

MNAR → 需建立选择模型或进行敏感性分析

清洗噪声

- **噪声**：测量误差、离群点
- **方法**：
    - **分箱（Binning）**：
        - 排序后等深分箱 → 按箱均值/中值/边界平滑
        - **例题**：数据 4,8,15,21,21,24,25,28,34 等深分3箱，均值平滑得 [9,9,9,22,22,22,29,29,29]；边界平滑得 [4,4,15,21,21,24,25,25,34]
    - **回归**：通过线性回归模型，对不符合回归的数据进行平滑处理，也可以用来预测某些属性
    - **聚类**：识别落在簇外的离群点

根据需求清理

- 推荐系统（通用推荐、冷启动）、教育大数据、社交网络、POI（Point of interest）等

2.3.3 数据集成

- **目标**：多源合并，获得更完整、更全面的数据画像（如用户画像：购物+社交+视频）
- **冗余问题**：
    - 冗余属性：浪费存储、重复计算
    - 冗余样本

检测冗余属性

Pearson 相关系数 r 衡量两个变量 X 和 Y 之间的**线性相关程度**，取值范围 $[-1,1]$：

- $r=1$：完全正线性相关
- $r=-1$：完全负线性相关
- $r=0$：无线性相关（但可能存在非线性关系）

样本相关系数公式（最常用）：$r=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i-\bar{X})^2\cdot\sum_{i=1}^{n}(Y_i-\bar{Y})^2}}$

总体相关系数公式（已知总体参数时）：$\rho_{X,Y}=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}=\frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X\sigma_Y}$ 其中 μ_X,μ_Y 为总体均值，σ_X,σ_Y 为总体标准差。

> **注意**：实际数据分析中，总体参数通常未知，因此使用样本公式。若题目特意说明"总体方差已知"，则用总体公式计算 ρ，但比较少见。

例题：计算变量 $A=[1,3,5]$, $B=[2,6,10]$ 的 Pearson 相关系数。

解：

- 均值 $\bar{A}=3$, $\bar{B}=6$。
- 偏差乘积：$(1-3)(2-6)=8$, $(3-3)(6-6)=0$, $(5-3)(10-6)=8$，分子 = 16。
- 偏差平方和：$(1-3)^2+(3-3)^2+(5-3)^2=4+0+4=8$，同理 B 是 32。
- 分母 = $\sqrt{8\times32}=16$。
- r=16/16=1，二者完全正相关。

卡方检验用于判断两个**分类变量**之间是否显著相关（即是否独立）。原假设 H_0：两个变量相互独立。

卡方统计量：$\chi^2=\sum_{i=1}^{r}\sum_{j=1}^{c}\frac{(O_{ij}-E_{ij})^2}{E_{ij}}$

- O_{ij}：第 i 行、第 j 列的实际观测频数。
- E_{ij}：在 H_0 成立下的期望频数，计算公式为：$E_{ij}=\frac{(\text{第 }i\text{ 行合计})\times(\text{第 }j\text{ 列合计})}{\text{总样本数}}$
- r,c 分别为行数、列数。

判断规则：

- 计算得到的 χ^2 值越大，越倾向于拒绝独立性的原假设，即两个变量越相关。
- 与临界值比较（自由度 $df=(r-1)(c-1)$）：若 $\chi^2>\chi^2_\alpha(df)$，则拒绝 H_0。

1. 建立列联表，填入实际观测频数 O_{ij}。
2. 计算行合计、列合计及总样本数。
3. 计算每个单元格的期望频数 E_{ij}。
4. 计算每个单元格的 $\frac{(O-E)^2}{E}$。
5. 将所有单元格的值相加得到 χ^2 值。
6. 根据自由度查表或计算 p 值，判断是否相关。

题目：调查 100 人的性别（男/女）与网购偏好（是/否），数据如下表。检验性别与网购是否相关（$\alpha=0.05$）。

	网购	不网购	行合计
男	30	20	50
女	40	10	50
列合计	70	30	100

解：

- 计算期望频数 E_{ij}：
  - $E_{11} = (50 \times 70)/100 = 35$
  - $E_{12} = (50 \times 30)/100 = 15$
  - $E_{21} = (50 \times 70)/100 = 35$
  - $E_{22} = (50 \times 30)/100 = 15$
- 计算 χ^2：$\chi^2 = \frac{(30-35)^2}{35} + \frac{(20-15)^2}{15} + \frac{(40-35)^2}{35} + \frac{(10-15)^2}{15} = \frac{25}{35} + \frac{25}{15} + \frac{25}{35} + \frac{25}{15} = 0.714 + 1.667 + 0.714 + 1.667 = 4.762$
- 自由度 $df = (2-1)(2-1) = 1$，查表得 $\chi^2_{0.05}(1) = 3.841$。
- 由于 $4.762 > 3.841$，拒绝 H_0，认为性别与网购行为相关。

在理论推导或某些假设检验中，若已知总体的协方差 $\mathrm{Cov}(X,Y)$ 和标准差 σ_X, σ_Y，则总体相关系数为：

$\rho = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y}$

此时无需抽样计算，直接得到总体参数。但实际场景极少知道总体真值，因此考试一般不要求计算，只需理解概念。当题目明确说“总体方差已知”，可使用该公式代入数值。

检测冗余样本

在数据集成中，不同数据源可能包含重复或高度相似的样本，需要检测并去重。常用方法包括距离度量、相似度计算、相关性分析和有序数据度量。

一、距离度量

距离度量用于衡量两个样本之间的数值差异。设两个样本 $\mathbf{p} = (p_1, p_2, \ldots, p_n)$ 和 $\mathbf{q} = (q_1, q_2, \ldots, q_n)$。

- **欧几里得距离**（Euclidean Distance）
  $d = \sqrt{\sum_{k=1}^{n} (p_k - q_k)^2}$ **例题**：$\mathbf{p} = (1,2), \mathbf{q} = (4,6) \rightarrow d = \sqrt{(3)^2 + (4)^2} = 5$
- **曼哈顿距离**（Manhattan Distance）
  $d = \sum_{k=1}^{n} |p_k - q_k|$ **例题**：同上 $\rightarrow d = |1-4| + |2-6| = 3 + 4 = 7$
- **汉明距离**（Hamming Distance）
  两个等长字符串或二进制向量中不同位置的个数。
  例题：1011101 与 1001001 → 第3位(1 vs 0)和第5位(1 vs 0)不同 → 距离=2
- **明可夫斯基距离**（Minkowski Distance）
  $d = \left(\sum_{k=1}^{n} |p_k - q_k|^r\right)^{1/r}$
  - $r = 1$：曼哈顿距离
  - $r = 2$：欧几里得距离

- $r=\infty$：切比雪夫距离（取各维度差值的最大值）

- **马氏距离**（Mahalanobis Distance）
  考虑协方差结构，消除量纲和变量相关性的影响。
  $D_M(\mathbf{p},\mathbf{q})=\sqrt{(\mathbf{p}-\mathbf{q})^T\Sigma^{-1}(\mathbf{p}-\mathbf{q})}$ 其中 Σ 为协方差矩阵。若总体参数已知，Σ 的元素为 $\Sigma_{ij}=\mathrm{Cov}(X_i,X_j)$；实际计算常用样本协方差矩阵：
  $S=\frac{1}{m-1}\sum_{t=1}^{m}(\mathbf{x}_t-\bar{\mathbf{x}})(\mathbf{x}_t-\bar{\mathbf{x}})^T$ **意义**：当特征量纲不同时（如身高cm、体重g），马氏距离自动归一化，避免欧氏距离的错误判断。

二、相似度计算

适用于二值属性或高维稀疏数据。

- **简单匹配系数（SMC）**
  对于两个二值向量，定义：
  - F_{11}：p=1且q=1的属性数
  - F_{00}：p=0且q=0的属性数
  - F_{01}：p=0且q=1的属性数
  - F_{10}：p=1且q=0的属性数
    $\mathrm{SMC}=\frac{F_{11}+F_{00}}{F_{01}+F_{10}+F_{11}+F_{00}}$ **例题**：$\mathbf{p}=(1,0,0,0,0,0,0,0,0,0),\mathbf{q}=(0,0,0,0,0,0,1,0,0,1)$
    $\rightarrow F_{01}=2,F_{10}=1,F_{00}=7,F_{11}=0\rightarrow\mathrm{SMC}=7/10=0.7$

- **Jaccard系数**：将全0的数据排除在外 $\mathrm{Jaccard}=\frac{F_{11}}{F_{01}+F_{10}+F_{11}}$

  例题（同上）$\rightarrow\mathrm{Jaccard}=0$

- **余弦相似度**（Cosine Similarity）
  $\cos\theta=\frac{\mathbf{A}\cdot\mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|}$ **例题**：$\mathbf{A}=(3,2,0,5,0,0,0,2,0,0),\mathbf{B}=(1,0,0,0,0,0,0,1,0,2)$
  点积= $3\times1+2\times0+0+5\times0+0+0+0+2\times1+0+0\times2=5$
  $\|\mathbf{A}\|=\sqrt{9+4+25+4}=\sqrt{42}\approx6.48,\|\mathbf{B}\|=\sqrt{1+1+4}=\sqrt{6}\approx2.45$
  $\cos\theta=5/(6.48\times2.45)\approx0.315$

三、相关性分析（是的在PPT里面这个东西又出现了一次）

用于检测冗余属性（特征）或样本之间的统计关联。

- **Pearson相关系数**（线性相关）
  样本公式：
  $r=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i-\bar{X})^2\cdot\sum_{i=1}^{n}(Y_i-\bar{Y})^2}}$
  总体公式（总体方差已知时）：
  $\rho=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}$
  取值范围 $[-1,1]$：1 完全正相关，-1 完全负相关，0 无线性相关。
  例题：$X=[1,2,3],Y=[2,4,6]$
  $\bar{X}=2,\bar{Y}=4$
  分子：$(-1)(-2)+(0)(0)+(1)(2)=2+0+2=4$
  分母：$\sqrt{(1^2+0^2+1^2)\times(2^2+0^2+2^2)}=\sqrt{2\times8}=4\rightarrow r=1$

四、有序数据度量

当数据具有顺序（如排名、推荐列表）时，使用这些指标。

- **Spearman秩相关系数**（等级相关）
  $\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$
  其中 d_i 为两个排名在第 i 个对象上的等级差。
  例题：X 的排名为 (a,b,c,d,e,f) 即等级 1~6；Y 的排名为 (c,a,e,d,f,b) 即等级 (3,1,5,4,6,2)
  $d = (2, -1, 2, 0, 1, -4)$，$\sum d^2 = 4+1+4+0+1+16 = 26$，$n = 6$
  $\rho = 1 - \frac{6\times 26}{6\times(36-1)} = 1 - \frac{156}{210} \approx 0.257$

- **NDCG（归一化折损累计增益）**
  用于评估排序列表的质量。

  - **CG@k**（累计增益）：$\mathrm{CG}_k = \sum_{i=1}^{k} rel_i$
  - **DCG@k**（折损累计增益）：$\mathrm{DCG}_k = \sum_{i=1}^{k} \frac{2^{rel_i}-1}{\log_2(i+1)}$ ，排名靠前的项占有更大的权重。
  - **IDCG**：理想排序下的 DCG
  - **NDCG@k** = $\mathrm{DCG}_k / \mathrm{IDCG}_k$

  例题：返回6个物品，相关度 $rel = [3, 2, 3, 0, 1, 2]$
  $\mathrm{CG}_6 = 3+2+3+0+1+2 = 11$

  $$\mathrm{DCG}_6 = \frac{2^3-1}{\log_2 2} + \frac{2^2-1}{\log_2 3} + \frac{2^3-1}{\log_2 4} + \frac{2^0-1}{\log_2 5} + \frac{2^1-1}{\log_2 6} + \frac{2^2-1}{\log_2 7}$$
  $$= 7 + 1.89 + 3.5 + 0 + 0.387 + 1.07 = 13.847$$
  假如我们实际召回了8个物品，除了上面的6个，还有两个物品，第7个相关性为3，第8个相关性为0。那么在理想情况下的相关性分数排序应该是3、3、3、2、2、1、0、0。理想排序 $[3, 3, 3, 2, 2, 1]$
  $\mathrm{IDCG}_6 = 7 + \frac{7}{1.585} + \frac{7}{2} + \frac{3}{2.32} + \frac{3}{2.585} + \frac{1}{2.807} = 7 + 4.42 + 3.5 + 1.29 + 1.16 + 0.356 = 17.726$
  $\mathrm{NDCG}_6 = 13.847 / 17.726 \approx 0.781$

在 NDCG（归一化折损累计增益）的计算中，**实际返回列表** 和 **理想排序** 的差别来源于以下两个概念：

1. **实际返回列表**（模型给出的排序结果）
   通常长度为 k（如 $k=6$），每个位置 i 上的物品有一个相关度 rel_i。这个列表可能只包含了系统认为最相关的 k 个物品，或者因为某些限制（如只展示了前6个）而截断。

2. **理想排序（Ideal Ranking）**
   是基于 **所有可被召回的相关物品** 的相关度，按降序排列得到的全局最优序列。

   - 可被召回的物品总数可能大于 k（例如系统实际从库中找出了8个相关物品，但展示时只展示前6个）。
   - 因此，理想排序的长度通常是 **所有相关物品的总数**（例如8个），而不仅仅是 k。
   - 但在计算 **IDCG@k**（前 k 个的理想累计折损增益）时，只取理想排序的前 k 个物品。

例题中的情况：

- 实际返回了6个物品，相关度为 $[3, 2, 3, 0, 1, 2]$。
- 但系统实际上可以召回 **8 个物品**，其中第7个相关度=3，第8个相关度=0。
- 那么理想排序（全部8个）应为：$[3, 3, 3, 2, 2, 1, 0, 0]$。

- 计算 **IDCG@6** 时，取前6个：$[3, 3, 3, 2, 2, 1]$。

为什么会有这种差别?

- 模型或系统可能只返回前 k 个结果（例如用户只关心前6个推荐），但评估时需要知道理论上最佳的前 k 个能拿到多少收益，因此 IDCG 基于全局理想排序的前 k 个来计算。
- 如果实际返回列表长度小于可召回总数，IDCG 不受影响，因为它只关心全局最优的前 k 个物品是否被实际返回列表覆盖。
- 反之，如果实际返回列表长度等于可召回总数，则 IDCG 就是全部物品的理想排序。

总结：NDCG 中的 “理想” 是基于所有可能的相关物品（而非仅实际返回的那些）进行排序，因此即使实际只返回了部分物品，IDCG 仍然需要**全局最优顺序**来提供一个上界，从而公平地评估实际返回列表的质量。

2.3.4 数据变换

规范化

- **目的**：使不同量纲的数据具有可比性（如满分100分 vs 150分）

最小-最大规范化（归一化）

- 公式：`v' = (v - min_A)/(max_A - min_A) * (new_max - new_min) + new_min`
- 常见映射到[0,1]：`v' = (v - min)/(max - min)`
- **例题**：成绩范围[60,100]，将85归一化到[0,1] → (85-60)/(100-60)=25/40=0.625
- **另一例**：属性区间[-100,100]映射到[0,1]，值66 → (66-(-100))/(100-(-100))=166/200=0.83

z-score规范化

- 公式：`v' = (v - μ)/σ`（假设数据服从正态分布）
- **例题**：某科平均80，标准差10，成绩90 → (90-80)/10=1.0
- **两门课比较**：素质课平均73，标准差7，得分78 → (78-73)/7≈0.714；实践课平均80，标准差6.5，得分83 → (83-80)/6.5≈0.462 → 素质课更好

小数定标规范化

- 公式：`v' = v / 10^j`，其中j是使max|v'|<1的最小整数
- **例题**：属性范围[-999,88] → 最大绝对值999 → j=3 → 新范围[-0.999,0.088]

规范化方法对比

方法	优点	缺点	适用场景
最小-最大	简单，保留关系	对极值敏感，需重新计算	数据分布较集中
z-score	不受量纲影响，可比较	需知μ,σ，结果无具体意义	离群点影响大，分布近似正态
小数定标	实现简单	无实际比较意义	相同含义的数据，量级相差大

离散化

- **目的**：连续数据分段，便于分析和算法处理
- **非监督离散化**：分箱（等深分箱、等宽分箱）、聚类
- **有监督离散化**：基于熵的离散化

信息熵（Entropy）

- 公式：$H(t) = - \Sigma\ p(j|t)\ \log_2\ p(j|t)$，p(j|t)为区间t中第j类的概率
- 范围：[0, $\log_2 C$]，C为类别数
- **例题**：区间t有6个样本，C1=2, C2=4 → p1=1/3, p2=2/3 → H = -[(1/3)$\log_2$(1/3)+(2/3)$\log_2$(2/3)] = -[(1/3)×(-1.585)+(2/3)×(-0.585)] = -[-0.528-0.39] = 0.918
- **均匀分布熵最大**：若C=2且各3个 → H=1；若C=4且各占1/4 → H=$\log_2 4$=2

信息增益（Information Gain）

- 父节点P分裂为K个子区间：$Gain = H(P) - \Sigma\ (n_i/n)\ H(i)$
- 选择使增益最大的分隔点
- **例题**：父节点熵=1.0，分为两个区间，样本数各半，子区间熵分别为0.2和0.3 → Gain = 1.0 - (0.5×0.2+0.5×0.3)=1.0-0.25=0.75

熵的应用

- 旅游季节划分、决策树、交叉熵损失函数
- 前沿：基于专利技术分布的熵预测公司前景

2.3.5 数据规约

维度规约

- **目的**：减少属性数量，信息损失最小
- **方法**：
  - **主成分分析(PCA)**
    - 思想：向低维投影，最大化方差，各主成分相互独立
    - 步骤：去均值 → 计算协方差矩阵 C = (1/m) X^TX → 特征值分解 → 取前k大特征值对应的特征向量构成变换矩阵P → Y = XP
    - 存储：原始N×M，PCA后为K×M + N×K
    - 不足：高维时协方差计算量大，特征分解慢
    - **例题**：10个城市8个属性数据，通过PCA得到3个主成分（特征向量表）
    - **图像压缩示例**：16×16图像块作为256维向量，PCA取前4/8/16...个主成分重构
  - **特征子集选择**：删除不相关/冗余特征
    - 启发式步骤：生成子集 → 评价 → 停止准则 → 验证
    - 评价策略：Filter（独立于模型，如信息增益、距离）、Wrapper（以分类器性能评价，计算量大）、Embedded（特征选择嵌入训练，如L1正则化、决策树）
  - **奇异值分解(SVD)、矩阵分解(PMF)、深度学习(AutoEncoder)**

数值规约

- **参数化方法**：回归模型、对数线性模型（只存参数）
- **非参数化方法**：直方图、聚类、抽样

2.4 特征工程

2.4.1 定义与意义

- **特征工程**：从数据中提取有效特征，使模型达到更好效果
- **意义**：
  - 特征越好，模型灵活性越强
  - 特征越好，模型越简单
  - 特征越好，模型性能越出色

2.4.2 特征工程流程（迭代）

1. 头脑风暴（领域知识、数据统计）
2. 特征设计（人工/自动）
3. 特征选择
4. 评估模型
5. 上线测试 → 未达标则重复2~5

2.4.3 从原始数据设计特征

基本特征提取

- 归一化、离散化、缺失填充、数据变换

独热表示（One-hot）

- 每个属性值对应一个维度（如词表大小）
- 优点：直观简洁
- 缺点：维度灾难（维数＝词典大小），语义鸿沟（所有向量都正交，无法表达词间关系）

函数变换特征

- 傅里叶变换：将时域信号转为频域，提取频率特征
- 示例：两个正弦波(7Hz和17Hz)+噪声 → 傅里叶变换后得到两个峰值频率7和17

TF-IDF（词频-逆文档频率）

TF-IDF 用于评估一个词对文档的重要程度，**其值与词在文档中出现的频率成正比，与包含该词的文档数成反比。**

公式

- **词频（Term Frequency, TF）**
  $\mathrm{TF}(w,d) = \frac{\text{词 } w \text{ 在文档 } d \text{ 中出现的次数}}{\text{文档 } d \text{ 的总词数}}$
- **逆文档频率（Inverse Document Frequency, IDF）**
  $\mathrm{IDF}(w) = \log\left(\frac{N}{1+\mathrm{DF}(w)}\right)$ 其中：

- N：语料库中的文档总数
- $\mathrm{DF}(w)$：包含词 w 的文档数量（加1是为了避免分母为零）

- **TF-IDF**
  $$\text{TF-IDF}(w, d) = \mathrm{TF}(w, d) \times \mathrm{IDF}(w)$$

完整例题

假设语料库包含以下 3 个文档：

- d_1：`"A B C C S D A B T S S S T W W"`（总词数 = 15）
- d_2：`"C S S T W W A B S B"`（总词数 = 10）
- d_3：`"X Y Z"`（不含 A,B,C,D,S,T,W 等词，总词数 = 3）

步骤1：计算每个文档中各词的词频（TF）

以词 A 为例：

- $\mathrm{TF}(A, d_1) = 2/15 \approx 0.133$
- $\mathrm{TF}(A, d_2) = 1/10 = 0.100$
- $\mathrm{TF}(A, d_3) = 0/3 = 0$

类似计算其他词（此处列出部分）：

词	TF(d_1)	TF(d_2)	TF(d_3)
A	2/15≈0.133	1/10=0.100	0
B	2/15≈0.133	2/10=0.200	0
C	2/15≈0.133	1/10=0.100	0
D	1/15≈0.067	0	0
S	4/15≈0.267	2/10=0.200	0
T	2/15≈0.133	0	0
W	2/15≈0.133	2/10=0.200	0

步骤2：计算每个词的 IDF

总文档数 $N = 3$。

- 词 A：出现在 d_1, d_2 中，$\mathrm{DF}(A) = 2 \rightarrow \mathrm{IDF}(A) = \log(3/(1+2)) = \log(1) = 0$（通常使用自然对数或常用对数，此处以自然对数为例，若用自然对数则 log(1)=0）
- 常见做法加1：实际公式为 $\mathrm{IDF} = \log(N/(1+\mathrm{DF}))$，若 DF=2，则分母=3，log(3/3)=0。
  为避免 IDF 为零，有时采用平滑版本 $\mathrm{IDF} = \log(N/\mathrm{DF})$ 并加1，或使用 $\log(N/(1+\mathrm{DF}))+1$。
  为了演示，我们采用不加1的经典形式 $\mathrm{IDF} = \log(N/\mathrm{DF})$（但需注意 DF=0 时处理）。这里按常用教学公式 $\mathrm{IDF} = \log(N/(1+\mathrm{DF}))$ 计算：

词	DF	IDF = log(3/(1+DF))
A	2	log(3/3)=0
B	2	0
C	2	0
D	1	log(3/2)=log(1.5)≈0.405
S	2	0
T	1	log(3/2)≈0.405
W	2	0

可以看到，只在单个文档中出现的词（D, T）获得非零的 IDF 值，而出现在两个及以上文档中的词 IDF 为 0（因为 log(1)=0）。实践中常使用平滑 IDF 以避免常见词权重为0，例如 $\mathrm{IDF} = \log(N/\mathrm{DF})$ （不加1）时，DF=2 时 IDF=log(3/2)≈0.405。这里我们改用不加1的形式重新计算：

$$\mathrm{IDF}(w) = \log\left(\frac{N}{\mathrm{DF}(w)}\right)$$

词	DF	IDF
A	2	log(3/2)=0.405
B	2	0.405
C	2	0.405
D	1	log(3/1)=1.099
S	2	0.405
T	1	1.099
W	2	0.405

步骤3：计算 TF-IDF

$$\text{TF-IDF}(w, d) = \mathrm{TF}(w, d) \times \mathrm{IDF}(w)$$

词	TF-IDF(d_1)	TF-IDF(d_2)
A	0.133×0.405=0.054	0.100×0.405=0.041
B	0.133×0.405=0.054	0.200×0.405=0.081
C	0.133×0.405=0.054	0.100×0.405=0.041
D	0.067×1.099=0.074	0
S	0.267×0.405=0.108	0.200×0.405=0.081
T	0.133×1.099=0.146	0
W	0.133×0.405=0.054	0.200×0.405=0.081

> 注意：文档 d_3 不含这些词，TF-IDF 均为 0。

解读：

- 在 d_1 中，词 T 和 S 的 TF-IDF 较高，说明它们是该文档的重要关键词。
- 在 d_2 中，词 B、S、W 较为重要。
- 词 D 只在 d_1 中出现，IDF 高，但 TF 较低，最终权重中等。

应用场景

- 搜索引擎关键词提取
- 文本相似性计算
- 推荐系统中的用户-标签权重（如计算用户对标签的兴趣程度）

优点与缺点

优点	缺点
算法简单快速，计算成本低	仅依赖词频，未考虑词的位置（如标题 vs 正文）和顺序
结果符合直观认识（罕见词权重更高）	无法发现词之间的隐含联系（如同义词、语义相似）
不仅适用于文本，也可推广到其他离散特征	对短文本效果不佳（TF 值不稳定）

特征组合

- 高阶特征：两两、三三组合
- 因子分解机(Factorization Machine, 2012)

轨迹数据特征

- 基本统计：速度/加速度/角速度的均值、极值、中位数
- 新特征：运动方向、曲线平滑度、偏导、领域知识（如鼠标轨迹区分人机）

2.4.4 特征选择

- **子集生成**：
  - 全局最优（穷举、分支定界）
  - 启发式（前向、后向、双向搜索）
  - 随机算法（模拟退火、遗传算法）
- **评价策略**：
  - **Filter**：独立于模型，基于信息统计（距离、信息增益、卡方、一致性）
  - **Wrapper**：以分类器性能为评价（如准确率），计算量大但效果好
  - **Embedded**：特征选择嵌入训练（L1正则化、决策树、随机森林、GBDT）
    - L1正则化使系数变稀疏，自动特征选择
    - L2正则化使系数更平均

2.4.5 传统特征工程的缺点

- 昂贵的人力成本

- 依赖领域知识
- 泛化能力差

2.4.6 特征学习（自动特征提取）

- **自编码器(Auto-Encoder)**：无监督学习特征
- **卷积神经网络(CNN)**：图像特征提取
  - 卷积层 → 池化层 → 全连接层 → 特征向量
  - 层次化特征：Layer1边缘/颜色，Layer2纹理/轮廓，Layer3/4物体部分
- **循环神经网络(RNN)**：序列数据特征（保留位置和顺序信息）
  - 应用：知识追踪（EKT模型）
- **预训练特征**：
  - 图像：ImageNet（1400万图，2万类），ResNet/AlexNet/VGG
  - 文本：Twitter/Wiki，Word2Vec（CBOW、Skip-gram、Glove）
- **预训练模型**：Elmo，GPT，Transformer，BERT

2.4.7 特征的可解释性

- 人工设计特征：天然可解释（如轨迹统计量）
- Word2Vec：词相似性（“国王-王后”≈“男人-女人”），解决语义鸿沟
- CNN特征图可视化：Layer1边缘，Layer2角/圆，Layer3复杂图案

第二章小结

- **数据采集**：检索、公开数据、合成数据、数据增强、众包、爬虫（协议、法律）
- **数据存储**：结构化/半结构化/非结构化，关系型(SQL)，NoSQL（文档/键值/列/图），图像与图数据
- **数据预处理**：清理（缺失、噪声）、集成（冗余检测、距离/相似度/相关性）、变换（规范化、离散化、熵）、规约（PCA、特征选择）
- **特征工程**：设计（统计、TF-IDF、组合）、选择（Filter/Wrapper/Embedded）、学习（CNN/RNN/预训练）、可解释性

参考资料（见PPT末页）：

- 数据挖掘导论、机器学习书籍
- 特征选择综述、Sklearn文档
- Kaggle/天池比赛论坛
- 相关论文（ICDM, TKDE, AAAI等）

第三章：数据统计

3.1 数据分布基本指标

3.1.1 集中趋势

1. 平均数（均值，Mean）

- **定义**：一组数据相加后除以数据个数，适用于数值型数据。
- **简单平均数（未分组数据）**：$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$
- **加权平均数（分组数据）**：$\mu = \frac{\sum_{i=1}^{K} x_i f_i}{\sum_{i=1}^{K} f_i} = \frac{\sum x_i f_i}{n}$
  - 频数 f_i 越大，该组对均值影响越大。
- **几何平均数**：适用于比率数据（如年利率、合格率）。$G = \sqrt[n]{x_1 x_2 \cdots x_n} = \left(\prod_{i=1}^{n} x_i\right)^{1/n}$ 若为增长率：$G = \sqrt[n]{(1+x_1)(1+x_2)\cdots(1+x_n)} - 1$
  - 受极端值影响小于算术平均数；但若变量值为负则可能无意义。
  - 可视为先取对数再做算术平均，然后取指数。

例题（几何平均数）： 某股票第一年初10元，第一年涨100%，第二年跌50%，计算两年平均增长率。 解：第一年末=20元，第二年末=10元。 几何平均收益率：$G = \sqrt{(1+1)\times(1-0.5)} - 1 = \sqrt{2\times 0.5} - 1 = 1 - 1 = 0$。 算术平均数：$(100\% + (-50\%))/2 = 25\%$，显然几何平均更合理。

2. 中位数（Median，M_e）

- 定义：排序后处于中间位置的变量值。适用于顺序数据及数值型数据，不适用于分类数据。
- 计算公式： $M_e = \begin{cases} x_{(\frac{n+1}{2})}, & n\text{为奇数} \$4pt] \frac{1}{2}\left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}\right), & n\text{为偶数} \end{cases}$
- 当数据对称分布时，均值 = 中位数。

例题：数据 [3, 5, 7, 9, 11]，中位数 = 7（第3个）； 数据 [3, 5, 7, 9]，中位数 = (5+7)/2 = 6。

3. 分位数（Quantile）

- **四分位数**：将数据四等分的三个点。
  - 下四分位数 Q_1（第25百分位数）
  - 中位数 Q_2（第50百分位数）
  - 上四分位数 Q_3（第75百分位数）
- **四分位距（IQR）**：$IQR = Q_3 - Q_1$，用于衡量中间50%数据的离散程度。
- **箱图（Box Plot）**：由 Tukey 发明，显示数据分布（最小值、Q_1、中位数、Q_3、最大值），并标识异常值。

箱图各标识的详细意义

箱图（又称盒须图）通过以下要素直观展示数据分布特征：

1. **箱体（Box）**
   - 下边界 = Q_1（第25百分位数）
   - 上边界 = Q_3（第75百分位数）
   - 箱体高度 = $IQR = Q_3 - Q_1$，表示中间50%数据的波动范围。
2. **中位线（Median Line）**
   - 箱体内部的一条线，表示中位数 Q_2（第50百分位数）。
   - 如果中位数偏向箱体的一侧，说明数据存在偏态。
3. **须（Whiskers）**
   - 从箱体两端向外延伸的线段，表示数据正常分布的范围（非异常值）。

- 通常定义：
  - 下须端点 = $\max(\min(\text{数据}), Q_1 - 1.5 \times IQR)$
  - 上须端点 = $\min(\max(\text{数据}), Q_3 + 1.5 \times IQR)$
- 须的长度可以反映尾部数据的分散程度。

4. **异常值（Outliers）**

- 落在须范围之外的数据点，通常用单独的点（如圆圈、星号）标出。
- 分类：
  - **温和异常值**：位于 $Q_3 + 1.5 \times IQR$ 到 $Q_3 + 3 \times IQR$ 之间（或对称的下侧）。
  - **极端异常值**：大于 $Q_3 + 3 \times IQR$（或小于 $Q_1 - 3 \times IQR$）。
- 箱图通过异常值标识帮助发现数据中的极端观测或录入错误。

5. **可选：均值点**

- 有时会在箱图中用菱形或叉号标出算术平均数，方便与中位数比较，判断对称性。

箱图的作用

- **识别异常值**：自动将超出 $1.5 \times IQR$ 的点标记为异常。
- **比较分布**：可并排绘制多个箱图，直观比较不同组别的分布差异（中心趋势、分散程度、偏态）。
- **不受异常值影响**：箱体、中位数和须对异常值稳健，不会因少数极端点而严重变形。

例题：数据集 [1,3,5,7,9,11,13,15,17]，求 Q_1, Q_3, IQR。 排序后共9个，Q_2 = 第5个 = 9；Q_1 = 第3个 = 5；Q_3 = 第7个 = 13；$IQR = 13 - 5 = 8$。

4. 众数（Mode，M_o）

- 定义：出现次数最多的变量值。适用于分类数据，也适用于数值型及顺序数据。
- 不受极端值影响；数据量较大时才有意义。
- **异众比率（Variation Ratio）**：衡量众数的代表性。 $V_r = 1 - \frac{f_m}{\sum f_i}$ 其中 f_m 为众数组频数，$\sum f_i$ 为总频数。V_r 越大，众数代表性越差。

例题：某班学生成绩：优(10人)，良(20人)，中(15人)，差(5人)。众数为"良"(20人)。 异众比率 $V_r = 1 - 20/(10+20+15+5) = 1 - 20/50 = 0.6$，说明众数代表性一般。

对于连续型的数据，通常先分箱再统计众数。

3.1.2 离散程度

1. 方差（Variance）与标准差（Standard Deviation）

- **总体方差（未分组）**：$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$
- **总体方差（分组）**：$\sigma^2 = \frac{1}{N}\sum_{i=1}^{K}(x_i - \mu)^2 f_i$
- **标准差**：$\sigma = \sqrt{\sigma^2}$，与原数据量纲相同。

例题：数据集 [2,4,6,8]，均值 $\mu = 5$。 方差 $\sigma^2 = [(2-5)^2 + (4-5)^2 + (6-5)^2 + (8-5)^2]/4 = (9+1+1+9)/4 = 20/4 = 5$，标准差 $\sigma = \sqrt{5} \approx 2.236$。

2. 极差（Range）

- $R = \max(x_i) - \min(x_i)$，只反映两端信息，易受极端值影响。

3. 四分位差（Quartile Deviation）

- $Q = Q_3 - Q_1$，也称为内矩。不受极端值影响，反映中间50%数据的分散程度。

4. 变异系数（Coefficient of Variation）

- $c_v = \frac{\sigma}{\mu}$，反映单位均值上的离散程度，常用在两个总体均值不等的离散程度的比较上。
- 若 $c_v > 15\%$（经验值），数据可能不正常。
- **例题**：某组数据均值=80，标准差=10，则 $c_v = 10/80 = 0.125 = 12.5\%$。 另一组数据均值=200，标准差=30，$c_v = 30/200 = 0.15 = 15\%$。 虽然第二组标准差更大，但相对波动更大。
- 缺陷：当平均值接近于0的时候，微小的扰动也会对变异系数产生巨大影响，造成精确度不足。变异系数因此无法发展出类似于均值的置信区间的工具。

5.建模技巧

利用数据指标指导建模思路：

- 若均值与中位数接近，且偏度接近0，可知数据分布是近似对称的，建模时可考虑运 用对称信息。
- 若极差或四分位差较大，建模时需考虑数据是否有长尾现象

3.1.3 分布形态

1. 偏度（Skewness）

- 用于描述数据的对称性，公式为三阶中心矩/标准差的立方：$\text{Skewness} = \frac{\frac{1}{n}\sum(x_i-\bar{x})^3}{(\frac{1}{n}\sum(x_i-\bar{x})^2)^{3/2}}$ $(\text{样本公式可能分母 } n-1)$
- 偏度 = 0：对称；>0：右偏（正偏，长尾在右）；<0：左偏（负偏，长尾在左）。

例题：数据集 [1,2,3,4,100] 均值=22，大多数值集中在左边，有一条长尾向右 → 右偏。

2. 峰度（Kurtosis）

- 用于描述数据分布的陡峭程度，公式为四阶中心矩/方差的平方：$\text{Kurtosis} = \frac{\frac{1}{n}\sum(x_i-\bar{x})^4}{(\frac{1}{n}\sum(x_i-\bar{x})^2)^2}$
- 正态分布峰度 = 3。实际计算中常减3来与正态分布对比（相对于正态的超额峰度）：>0 尖峰，<0 平峰。

例题：拉普拉斯分布（双指数）比正态分布更尖 → 峰度 > 3。

3.2 参数估计

3.2.1 基本概念

- **参数**：描述总体的度量（如总体均值 μ、方差 σ^2）。
- **统计量**：描述样本的度量（如样本均值 $\bar{x}$、样本方差 s^2）。
- **参数估计**：用样本统计量估计总体参数。

3.2.2 点估计

点估计是指用样本统计量$\hat{\theta}$的某个取值直接作为总体参数θ的估计值。简单来说就是直接以样本指标来估计总体指标

常用方法：

- **矩估计（Method of Moments）**：用样本矩替换总体矩。例如：用样本均值估计总体均值。
- **最小二乘估计（LSE）**：最小化残差平方和，常用于线性回归。
- **极大似然估计（MLE）**：最大化似然函数 $L(\theta|X) = \prod f(x_i|\theta)$。
- **最大后验估计（MAP）**：最大化后验概率 $p(\theta|X) \propto p(X|\theta)p(\theta)$。
- **贝叶斯估计**：估计参数的后验分布，而非单点值。

① 极大似然估计（MLE）

例题（离散）：抛硬币100次，70次正面，估计正面概率 θ。 似然函数 $L = C_{100}^{70}\theta^{70}(1-\theta)^{30}$，取对数求导得 $\hat{\theta}_{MLE} = 70/100 = 0.7$。

例题（连续）：样本来自正态分布 $N(\mu, \sigma^2)$，求MLE。 解：$\hat{\mu} = \frac{1}{n}\sum x_i$，$\hat{\sigma}^2 = \frac{1}{n}\sum(x_i - \hat{\mu})^2$。

② 最大后验估计（MAP）

- 目标：$\hat{\theta}_{MAP} = \arg\max_\theta p(X|\theta)p(\theta)$。
- 引入先验 $p(\theta)$，相当于在MLE基础上增加正则化。

> **注**：在PPT中，MAP的完整公式为 $\hat{\theta}_{MAP} = \arg\max_\theta \frac{p(X|\theta)p(\theta)}{p(X)}$，其中 $p(X)$ 是边缘概率（证据，evidence），与 θ 无关，作为归一化常数不影响最大化，因此可简化为 $\arg\max_\theta p(X|\theta)p(\theta)$。

例题（使用 Beta 先验）：抛硬币10次，观察到7次正面（$k=7$），3次反面。假设我们相信硬币偏向均匀，即 θ（正面概率）的先验分布为 Beta 分布，参数 $\alpha = 5, \beta = 5$（均值0.5，对称）。求 θ 的 MAP 估计。

1. 模型设定

- 似然函数（二项分布）：$p(X|\theta) = \binom{10}{7}\theta^7(1-\theta)^3$
- 先验分布（Beta 分布）：$p(\theta) = \frac{1}{B(\alpha,\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1}, \quad \alpha=5, \beta=5$ 其中 $B(\alpha,\beta)$ 是 Beta 函数（归一化常数）。

2. 后验分布（正比于似然×先验）

忽略常数因子，后验密度：$p(\theta|X) \propto \theta^7(1-\theta)^3 \cdot \theta^{5-1}(1-\theta)^{5-1} = \theta^{7+4}(1-\theta)^{3+4} = \theta^{11}(1-\theta)^7$ 即后验分布为 $\text{Beta}(\alpha' = 5+7 = 12, \beta' = 5+3 = 8)$。

3. MAP 估计（后验众数）

对于 Beta 分布，众数为：$\hat{\theta}_{MAP} = \frac{\alpha'-1}{\alpha'+\beta'-2} = \frac{12-1}{12+8-2} = \frac{11}{18} \approx 0.611$

4. 与 MLE 比较

- MLE（极大似然估计）：$\hat{\theta}_{MLE} = \frac{k}{n} = \frac{7}{10} = 0.7$
- MAP 估计：$\hat{\theta}_{MAP} \approx 0.611$

先验均值 $E[\theta] = \frac{\alpha}{\alpha+\beta} = \frac{5}{10} = 0.5$，MAP 估计介于先验均值和 MLE 之间。

5. 样本量增大的影响

若实验次数增加到 $n = 1000$，正面次数 $k = 700$，取相同先验 $\text{Beta}(5, 5)$：

- 后验参数 $\alpha' = 5 + 700 = 705$，$\beta' = 5 + 300 = 305$
- MAP 估计：$\hat{\theta}_{MAP} = \frac{705-1}{705+305-2} = \frac{704}{1008} \approx 0.6984$
- MLE 估计：$\hat{\theta}_{MLE} = 700/1000 = 0.7$

此时 MAP 非常接近 MLE，说明先验的影响随样本量增大而减弱。

6. 补充说明

- 若先验为 $\text{Beta}(1, 1)$（均匀分布），则 MAP = MLE。
- Beta 分布是二项分布的共轭先验，后验仍为 Beta 分布，便于解析计算。
- 选择 $\alpha = \beta = 5$ 表示先验认为 θ 接近 0.5 的可信度相当于“已经看过 10 次虚拟实验，其中 5 正 5 反”。

③ 贝叶斯估计

贝叶斯估计不求参数的单点值，而是计算**后验分布** $p(\theta|X)$，保留不确定性。

- **核心公式**：$p(\theta|X) = \dfrac{p(X|\theta)p(\theta)}{p(X)}$，$p(X) = \int p(X|\theta)p(\theta)d\theta$
- **预测**：$p(x^*|X) = \int p(x^*|\theta)p(\theta|X)d\theta$，其中$x^*$表示一个新的、尚未观测过的数据点，公式预测的是新数据出现的概率（或概率密度）
- **共轭先验**：先验与后验形式相同，简化计算。例如：二项分布似然 + Beta先验 → 后验为Beta分布。

例题：抛硬币，先验 $\theta \sim \text{Beta}(5, 5)$（均值0.5）。观测20次，14正6反。

- 后验：$\text{Beta}(5 + 14,\ 5 + 6) = \text{Beta}(19, 11)$
- 贝叶斯点估计（后验均值）：$\hat{\theta}_{\text{Bayes}} = \frac{19}{19+11} = 0.633$
- 对比：MLE = 0.7，MAP = $\frac{18}{28} \approx 0.643$

贝叶斯估计介于先验（0.5）与MLE之间，且当样本量增大时会趋近MLE。

一般来说，计算积分是不可能的（PPT原话），选择一个合理的先验分布非常重要。

④ 点估计的评价标准

- **无偏性**：$E(\hat{\theta}) = \theta$。样本均值是总体均值的无偏估计；样本方差 $s^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$ 是总体方差的无偏估计。
- **有效性**：两个无偏估计，方差小的更有效。
- **相合性（一致性）**：样本量越大，估计值越接近真值。

例题：比较两个无偏估计 $\hat{\theta}_1, \hat{\theta}_2$，若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$，则 $\hat{\theta}_1$ 更有效。

⑤ 点估计误差指标

- **MAE（平均绝对误差）**：$\mathrm{MAE} = \frac{1}{N}\sum|y_i - \hat{y}_i|$
- **MSE（均方误差）**：$\mathrm{MSE} = \frac{1}{N}\sum(y_i - \hat{y}_i)^2$
- **RMSE（均方根误差）**：$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$

例题：真实值 [3,5,7]，预测值 [2,6,8]。 MAE = (|3-2|+|5-6|+|7-8|)/3 = (1+1+1)/3=1； MSE = (1+1+1)/3=1； RMSE=1。

3.2.3 区间估计

- 构造置信区间 $[L, U]$，以一定置信水平（如95%）包含总体参数真值。
- 在数据科学中，区间估计应用较少，但物理、化学等实验领域常用。

3.3 假设检验

3.3.1 基本原理

- **小概率事件原理**：在一次试验中几乎不可能发生。若发生，则怀疑原假设。
- **反证法**：先提出原假设 H_0，再构造检验统计量，判断是否落入拒绝域。

3.3.2 基本概念

- **原假设 H_0**：想要拒绝的假设（如 $\mu = \mu_0$）。
- **备择假设 H_1**：与 H_0 对立的假设（如 $\mu \neq \mu_0$、$\mu > \mu_0$、$\mu < \mu_0$）。
- **检验统计量**：用于决策的样本函数（如 Z 统计量、t 统计量）。
- **显著性水平 α**：犯第一类错误的概率（通常取0.01, 0.05, 0.1）。
- **拒绝域**：由 α 决定的临界值区域。

常见临界值（双侧）： $\alpha = 0.05 \to Z_{\alpha/2} = 1.96$； $\alpha = 0.01 \to Z_{\alpha/2} = 2.58$。 单侧：$\alpha = 0.05 \to Z_{\alpha} = 1.645$； $\alpha = 0.01 \to Z_{\alpha} = 2.33$。

3.3.3 两类错误

决策	H_0 为真	H_0 为伪
接受H_0	正确（$1-\alpha$）	第二类错误（β）
拒绝H_0	第一类错误（α）	正确（$1-\beta$，即功效）

- α**（弃真）**：错把正确假设拒绝（如把好人判刑）。
- β**（取伪）**：错把错误假设接受（如把坏人放走）。
- 在固定样本量下，α 和 β 互斥；增大样本量可同时减小两类错误。

3.3.4 单总体均值 Z 检验（大样本或正态总体且方差已知）

- 检验统计量：$Z = \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}$ 或 $Z = \frac{\bar{x}-\mu_0}{s/\sqrt{n}}$ (方差未知时用样本标准差，大样本近似)
- 判断：若 $|Z| > Z_{\alpha/2}$（双侧）或 $Z > Z_{\alpha}$（右侧）等，则拒绝 H_0。

例题：已知零件椭圆度总体 $\mu_0 = 0.081\text{mm}$，$\sigma = 0.025$。新机床200个样本，$\bar{x} = 0.076$。问是否有显著差异（$\alpha = 0.05$）？

解：$H_0 : \mu = 0.081,\ H_1 : \mu \neq 0.081$ $Z = \frac{0.076 - 0.081}{0.025/\sqrt{200}} = \frac{-0.005}{0.0017678} \approx -2.83$ 查表得 $Z_{0.025} = 1.96$，$|Z| = 2.83 > 1.96$，拒绝 H_0，认为有显著差异。

3.3.5 应用举例

- 推荐系统：用 Z 检验比较不同算法的评分差异是否显著（p ≤ 0.01）。
- 异常检测：检验某个会话的“领先分数”是否显著高于期望。

3.4 抽样方法

3.4.1 为什么要抽样

- 提高效率，节省时间与计算资源。
- 总体无法全部获取或成本过高。
- 解决样本不均衡（欠采样、过采样）。
- 定性分析需要（如访谈、观察）。

3.4.2 非概率抽样

- 不是随机原则，有主观偏差，无法推断总体。
- 常见：随意抽样、判断抽样、志愿抽样、滚雪球抽样。

3.4.3 等概率抽样（每个单元入样概率相等）

① 简单随机抽样（SRS）

- 逐个抽取，每个个体被抽概率相等 = $1/N$。
- 方法：抽签法、随机数表法。

随机数表法示例：从随机数表任选一起始位置，按行或列读取预定位数的数字，直到抽够所需样本。

② 系统抽样

- 将总体编号后，按固定间隔 $k = N/n$ 抽取。
- 若 N/n 非整数，可先剔除若干个体。
- 例如：礼堂30排，每排40座，留座位号为20的听众 → 系统抽样。

③ 分层抽样

- 按特征将总体分成若干层（层内差异小，层间差异大），再按比例在各层内简单随机抽样。
- 例如：职工500人，按年龄分三层，按比例分配样本。

例题：500人，<35岁125人，35~49岁280人，≥50岁95人，需抽100人。 比例 = 100/500 = 1/5，每层抽取人数：125/5=25，280/5=56，95/5=19。

④ 整群抽样

- 将总体分为许多"群"，随机抽取若干群，对群内所有个体调查。
- 优点：操作简单，费用低。缺点：若群间差异大则误差大。
- **多阶段抽样**：先抽群，再在群内二次抽样。

3.4.4 不等概率抽样

- 单元入样概率与其规模（或重要性）成正比，适用于总体单元差异大的情况。
- 例如：估计商业零售总额，大型商场概率高，小型商店概率低。
- 需要知道每个单元的辅助变量（如规模）以确定概率。
- 常见场景：抽样审计、大型调查中与其它抽样结合。

第三章总结

模块	关键内容
数据分布	均值（算术、加权、几何）、中位数、分位数、众数、异众比率；方差、标准差、极差、四分位差、变异系数；偏度、峰度
参数估计	矩估计、LSE、MLE、MAP、贝叶斯估计；无偏性、有效性、相合性；MAE/MSE/RMSE
假设检验	原假设/备择假设、显著性水平、Z检验、两类错误（α, β）
抽样方法	非概率抽样；等概率抽样（简单随机、系统、分层、整群）；不等概率抽样

补充说明：在实际数据分析中，应先通过描述统计（均值、方差、分位数、偏度等）了解数据基本特征，再根据问题选择合适的参数估计或假设检验方法，并合理设计抽样方案以提高效率。

第四章：数据挖掘

4.1 数据挖掘基础

4.1.1 什么是数据挖掘

- **定义**：从大量的数据中挖掘那些令人感兴趣的、有用的、隐含的、先前未知的和可能有用的模式或知识，并据此更好地服务人们的生活。
- **近义词**：从数据中挖掘知识（Knowledge Discovery in Data, KDD）、知识提炼、数据/模式分析、数据考古、数据捕捞、信息收获、资料勘探等。
- **学术会议**：SIGKDD（Knowledge Discovery and Data Mining）
- **参考书**：《数据挖掘导论》（Pang-Ning Tan, Michael Steinbach, Vipin Kumar, Addison Wesley）

4.1.2 数据挖掘四大任务

任务	类型	说明	示例
聚类（Clustering）	无监督学习	将样本划分为若干组，组内相似、组间相异	铁路票价制定、搜索词条聚类（"USTC"与"中科大"）
关联分析（Association Analysis）	无监督学习	发现数据中项目之间的关联关系	"啤酒与尿布"、林彪通过战报数据找到敌人指挥所
分类与预测（Classification & Prediction）	监督学习	学习特征到类别的映射，或预测连续数值	垃圾邮件分类、电影评分预测、信用卡欺诈检测
异常检测（Anomaly Detection）	可监督/无监督	检测与大多数数据显著不同的样本	盗电检测、网络入侵检测

4.2 关联规则挖掘（Association Rule Mining）

4.2.1 基本概念

项集（Itemset）

- 一个或多个项目（items）的集合
- k-itemset：大小为 k 的项集
- 例：{Milk, Bread, Diaper} 是 3 项集

关联规则

- 形如 X → Y 的表达式，X、Y 均为项集
- 表示：当事务中出现 X 时，往往也会出现 Y
- 例：{牛奶, 面包} → {黄油}

支持度（Support）

衡量规则出现的频率：

$$\text{Support}(X \to Y) = \text{Support}(X \cup Y) = P(X \cup Y) = \frac{\text{同时包含 } X \text{ 和 } Y \text{ 的事务数}}{\text{总事务数}}$$

> 在PPT中，项集的支持度通常写成 Support({X, Y, ...})，即同时包含项集中所有项的事务占总事务的比例。

置信度（Confidence）

衡量规则的可靠程度：

$$\text{Confidence}(X \to Y) = P(Y|X) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)}$$

表示：在出现 X 的情况下，Y 出现的概率。

频繁项集（Frequent Itemset）

若项集支持度不小于最小支持度阈值（minsup）：

$$\text{Support}(X) \geq \text{minsup}$$

则称为频繁项集。

强关联规则

用户自行设定最小置信度阈值 minconf，置信度大于 minconf 的规则称为强关联规则。

关联规则挖掘任务

给定事务集合 T，找出所有满足以下条件的规则：

- support ≥ minsup threshold
- confidence ≥ minconf threshold

暴力解法不可行：对于 d 个项目，候选项集总数为 2^d，穷举计算量过大。

两步策略：

1. **频繁项集生成**（只关注支持度）：生成所有满足 minsup 的项集
2. **规则产生**（只关注置信度）：从每个频繁项集中生成高置信度规则

4.2.2 Apriori 算法

核心思想

Apriori 性质（反单调性）：

> 如果一个项集是频繁的，那么它的所有非空子集一定也是频繁的。

反之：

> 如果一个项集不是频繁的，则它的所有超集都不可能频繁。

数学基础：$\forall X, Y : X \subseteq Y \rightarrow \text{support}(X) \geq \text{support}(Y)$

算法流程

基本方法：广度优先搜索，自底而上遍历，逐步生成候选集与频繁项集。整个过程由**连接步**和**剪枝步**两步组成。

```
Step1: 生成候选1项集 C₁ → 统计每个项的支持度
Step2: 生成频繁1项集 L₁ → 保留 support ≥ minsup 的项集
Step3: 生成候选2项集 C₂ = L₁ ⋈ L₁
Step4: 计算支持度 → 扫描数据库，计算 C₂ 中每个项集的支持度
Step5: 得到频繁2项集 L₂ → 保留 support ≥ minsup 的项集
Step6: 产生候选3项集 C₃ = L₂ ⋈ L₂
    • 连接（Join）：例如 {l1,l2} 与 {l1,l3} 生成 {l1,l2,l3}
    • 剪枝（Prune）：检查所有 (k-1) 子集是否频繁
        - 例如 {l1,l3,l5} 的子集 {l1,l3}、{l1,l5}、{l3,l5}
        - 若 {l3,l5} 不是频繁项集，则删除 {l1,l3,l5}
Step7: 以此类推，直至无法找出更多频繁项集
```

连接步

输入：所有频繁 (k-1) 项集 L_{k-1}；输出：候选 k 项集 C_k。

执行自连接 $L_{k-1} \bowtie L_{k-1}$，其中 L_{k-1} 的两个项集可连接当且仅当它们前 (k-2) 个项相同，且 $l_1[k-1] < l_2[k-1]$（避免产生重复项集）。

示例：$L_3 = \{abc, abd, acd, ace, bcd\}$，自连接后 $C_4 = \{abcd, acde\}$

剪枝步

利用反单调性：任何非频繁的 (k-1) 项集都不可能是频繁 k 项集的子集。若候选 k 项集的 (k-1) 项子集不在 L_{k-1} 中，则该候选从 C_k 中删除。

示例：$C_4 = \{abcd, acde\}$，检查子集，最终 $L_4 = \{abcd\}$

Apriori 算法完整实例

【例】某商店的用户购买记录，共 9 个事务，设最小支持度计数 = 2。事务中的项按字典次序存放。

TID	事务
T100	{I1, I2, I5}
T200	{I2, I4}
T300	{I2, I3}
T400	{I1, I2, I4}
T500	{I1, I3}
T600	{I2, I3}
T700	{I1, I3}
T800	{I1, I2, I3, I5}
T900	{I1, I2, I3}

迭代过程：

(1) 生成 C_1 并扫描计数：{I1}:6, {I2}:7, {I3}:6, {I4}:2, {I5}:2 → 全部 ≥2，L_1 = 全部五项

(2) $L_1 \bowtie L_1$ 产生 C_2（共 10 个候选 2 项集）

(3) 扫描计数得 L_2（最小支持度 = 2）： {I1,I2}:4, {I1,I3}:4, {I1,I5}:2, {I2,I3}:4, {I2,I4}:2, {I2,I5}:2 （{I1,I4}:1, {I3,I4}:0, {I3,I5}:1, {I4,I5}:0 被剪去）

(4) $L_2 \bowtie L_2$ 产生 C_3：

- 连接步得：{I1,I2,I3}, {I1,I2,I5}, {I1,I3,I5}, {I2,I3,I4}, {I2,I3,I5}, {I2,I4,I5}
- 剪枝步：检查 2 项子集是否都在 L_2 中
    - {I1,I2,I3} 的子集 {I1,I2}, {I1,I3}, {I2,I3} 都在 L_2 中 → 保留
    - {I1,I2,I5} 的子集 {I1,I2}, {I1,I5}, {I2,I5} 都在 L_2 中 → 保留

- {I1,I3,I5} 的子集 {I3,I5} 不在 L_2 中 → 删除
- 同理删除其他，最终 C_3 = {{I1,I2,I3}, {I1,I2,I5}}

(5) 扫描计数：{I1,I2,I3}:2, {I1,I2,I5}:2 → L_3 = 两项

(6) $L_3 \bowtie L_3$ 产生 C_4：连接得 {I1,I2,I3,I5}，但其子集 {I2,I3,I5} 不在 L_3 中 → 剪去。C_4 = ∅，算法终止。

算法最终输出所有频繁项集：

- L_1（5 个）：{I1}, {I2}, {I3}, {I4}, {I5}
- L_2（6 个）：{I1,I2}, {I1,I3}, {I1,I5}, {I2,I3}, {I2,I4}, {I2,I5}
- L_3（2 个）：{I1,I2,I3}, {I1,I2,I5}

Apriori 特点

优点：适用于稀疏数据、高频模式、短频繁项集

缺点：

1. **候选集爆炸**：可能产生大量候选项集
2. **多次扫描数据库**：效率较低

Apriori 改进算法

- DHP（Direct Hashing and Pruning）
- Partition
- Sample
- DIC（Dynamic Itemset Counting）
- FP-Growth

4.2.3 FP-Growth 算法

基本思想

由韩家炜于 2000 年提出。核心是构建 **FP-Tree（频繁模式树）**，通过压缩事务数据库，避免像 Apriori 那样生成大量候选集，从而高效挖掘频繁项集。

- 不生成候选集，避免组合爆炸
- 只需扫描数据库两遍
- 采用分治策略，递归分解问题
- 特别适合**稠密数据**和**长频繁模式**

FP-Growth 产生频繁项集的步骤

第一步：构建 FP-Tree

1. **第一次扫描数据库**：统计每个单项的支持度，删除不满足 minsup 的项，得到频繁 1 项集，并按支持度降序排序（如 `a:8, b:7, c:6, ...`）。
2. **第二次扫描数据库**：对每个事务，保留其中的频繁项并按照全局排序，然后插入到 FP-Tree 中。
    - 每个节点包含：项名、计数、父节点指针、子节点指针、指向同名节点的链。

- 相同前缀的事务共享路径，计数累加。
- 同时维护一个 **头表**，记录每个频繁项的首个节点指针。

第二步：递归挖掘频繁项集（分治）

从 **头表底部（支持度最低的项）** 开始向上挖掘，对于每个项 X（如 e）：

1. **提取条件模式基**：从 FP-Tree 中找到所有包含 e 的路径（即从根到 e 的前缀路径），每条路径的计数取 e 节点的计数。
2. **构建条件 FP 树**：将这些路径作为新事务，删除路径中支持度低于 minsup 的节点，形成一个新的压缩树（条件树）。
3. **在条件树上递归挖掘**：合并项 X 与条件树中挖掘出的频繁项集，得到包含 X 的频繁项集。
4. 重复直到条件树为空或只包含单条路径（此时可直接组合出所有子集）。

Apriori vs FP-Growth 对比

对比项	Apriori	FP-Growth
候选集生成	生成大量候选集	不生成候选集
扫描次数	需多次扫描数据库	仅需 2 次扫描
内存占用	较小（但时间慢）	较大（需建树）
适用场景	稀疏数据、短模式	稠密数据、长模式

FP-Growth 算法详细示例

事务数据库（共 5 个事务），最小支持度计数 minsup = 2：

TID	事务项集
1	{a, b, c, d}
2	{a, b, c, e}
3	{a, b, e}
4	{a, c, e}
5	{b, c, e}

第一步：扫描数据库，得到频繁 1 项集并排序

统计每个单项的出现次数：a:4, b:4, c:4, d:1（删除，<2）, e:4。 按支持度降序排序：`a:4, b:4, c:4, e:4`

第二步：构建 FP-Tree

再次扫描数据库，对每个事务只保留频繁项并按全局排序（a,b,c,e），插入到树中，共享前缀路径。

- 事务1 `{a,b,c,d}` → 过滤后 `{a,b,c}` → 创建路径 a:1 → b:1 → c:1
- 事务2 `{a,b,c,e}` → 共享前缀，计数累加：a:2 → b:2 → c:2 → e:1
- 事务3 `{a,b,e}` → 共享 a,b，新建分支：a:3 → b:3 → (c:2→e:1 分支, e:1 分支)
- 事务4 `{a,c,e}` → 共享 a，新建分支：a:4 → (b:3 分支, c:1→e:1 分支)

- 事务5 {b,c,e} → 从根的新分支：b:1 → c:1 → e:1

最终 FP-Tree 结构（头表含横向链表）：

```
null
├── a:4
│   ├── b:3
│   │   ├── c:2
│   │   │   └── e:1
│   │   └── e:1
│   └── c:1
│       └── e:1
└── b:1
    └── c:1
        └── e:1
```

第三步：递归挖掘频繁项集（从下往上）

挖掘顺序按头表项支持度升序：e → c → b → a。

挖掘项 e： 条件模式基 = {a,b,c}:1, {a,b}:1, {a,c}:1, {b,c}:1。统计各单项：a:3, b:3, c:3（均 ≥2）。构建条件树，递归挖掘得包含 e 的频繁项集：{e}, {a,e}, {b,e}, {c,e}, {a,b,e}, {a,c,e}, {b,c,e}（{a,b,c,e} 支持度仅 1，被剪枝）。

挖掘项 c： 条件模式基 = {a,b}:2, {a}:1, {b}:1。a:3, b:3（≥2）。得频繁项集：{c}, {a,c}, {b,c}, {a,b,c}。

挖掘项 b： 条件模式基 = {a}:3, {}:1。a:3（≥2）。得频繁项集：{b}, {a,b}。

挖掘项 a：无前缀，条件基为空。得 {a}。

第四步：合并所有频繁项集

```
{a}, {b}, {c}, {e}
{a,b}, {a,c}, {a,e}, {b,c}, {b,e}, {c,e}
{a,b,c}, {a,b,e}, {a,c,e}, {b,c,e}
```

> 总结：FP-Growth 通过一次扫描构建压缩树，第二次扫描只构建树，后续挖掘只需在内存中的条件树上递归，无需再次扫描原始数据库，大大提高了效率，尤其适合长模式稠密数据。

4.2.4 关联规则生成

规则生成任务

给定一个**频繁项集** L（例如 $L = \{A, B, C, D\}$），关联规则生成的目标是找到所有**非空真子集** $f \subset L$，使得规则 $f \rightarrow (L - f)$ 满足最小置信度（minconf）阈值。

示例：若 $L = \{A, B, C, D\}$，可能生成如下规则：

- $ABC \to D$, $ABD \to C$, $ACD \to B$, $BCD \to A$
- $AB \to CD$, $AC \to BD$, $AD \to BC$, $BC \to AD$, $BD \to AC$, $CD \to AB$
- $A \to BCD$, $B \to ACD$, $C \to ABD$, $D \to ABC$

所有规则都要求 f 和 $L - f$ 均非空。

候选规则数量

对于一个长度为 k 的频繁项集，可以生成的候选规则总数为：

$$\text{候选规则数} = 2^k - 2$$

（除去 $f = \emptyset$ 和 $f = L$ 两种情况）

示例：$k = 4$ 时，候选规则数为 $2^4 - 2 = 14$ 条。

复杂度（全局）

假设数据库中共有 d 个不同项目，则：

- 候选项集总数理论值为 2^d（包括空集）。
- 候选规则总数公式为：

$$3^d - 2^{d+1} + 1$$

例如当 $d = 6$ 时，候选规则数可达 602 条。这说明了**剪枝**的必要性——直接枚举所有规则不可行。

规则剪枝（置信度反单调性质）

对于同一个频繁项集 L，规则的置信度满足**反单调性质**：

$$\text{confidence}(ABC \to D) \geq \text{confidence}(AB \to CD) \geq \text{confidence}(A \to BCD)$$

即：**规则前件越大（后件越小），置信度越高**。

因此，生成规则时通常采用**逐层搜索**：

1. 先生成后件为单个项的规则（如 $ABC \to D$），计算置信度。
2. 如果某条规则不满足 minconf，那么其**所有后件更小**的规则（如将后件拆分为多个项）必然也不满足，可以剪枝。

剪枝示例：如果 $AB \to CD$ 不满足置信度，那么 $A \to BCD$ 也不需要计算，直接跳过。

规则生成算法（常用策略）

- 从频繁项集出发，每次将后件扩展一个项目（即从后件为 1 项开始，逐步增加后件大小）。
- 对每个大小的后件，利用反单调性质剪枝无效规则。
- 典型实现：在 Apriori 或 FP-Growth 挖掘出频繁项集之后，调用独立函数生成关联规则。

小结

步骤	说明
输入	频繁项集集合 + 最小置信度
输出	所有满足 $\text{conf} \geq \text{minconf}$ 的关联规则
关键	利用置信度反单调性减少候选规则
复杂度	仍可能指数级，但剪枝大幅降低实际计算量

4.2.5 关联规则评价指标

置信度的问题

例：`Tea → Coffee`，虽然 Confidence 很高，但 Coffee 本来就经常出现，因此规则可能具有误导性。

Lift（提升度）

$$\text{Lift} = \frac{P(X,Y)}{P(X)P(Y)}$$

- **Lift > 1**：正相关（X 的出现促进了 Y 的出现）
- **Lift = 1**：独立（X 与 Y 无关）
- **Lift < 1**：负相关（X 的出现抑制了 Y 的出现）

Interest（兴趣度）

$$\text{Interest} = \frac{P(X,Y)}{P(X)}$$

φ 系数（Phi Coefficient）

衡量两个二值变量之间的统计相关性：

$$\phi = \frac{P(X,Y) - P(X)P(Y)}{\sqrt{P(X)(1-P(X))P(Y)(1-P(Y))}}$$

4.2.6 相关关系与因果关系

相关 ≠ 因果

例：公鸡打鸣 → 太阳升起，虽然置信度很高，但不存在因果关系。真正原因是**地球自转**（隐藏变量/混杂变量）。

> 解释变量之间的关联时要特别小心，因为观察到的联系可能受其他混淆因素的影响。推荐因果科普书 Judea Pearl《The Book of Why》。

4.2.7 辛普森悖论（Simpson's Paradox）

定义

辛普森悖论指的是：当将数据分组后，原本在总体中呈现的趋势（如正相关、差异方向）在各个子组中**发生逆转**，或者完全消失的现象。

在数学上源于：$a/b < c/d$ 且 $p/q < r/s$ 并不能保证 $(a+p)/(b+q) \leq (c+r)/(d+s)$。

> 简单说：**总体结论与分组结论相反**。

经典示例

示例 1：HDTV 与健身器的购买关系

- **总体数据**（所有消费者）：购买 HDTV 的人，购买健身器的比例更高 → 认为两者正相关。
- **分组数据**（按身份划分）：
  - 大学生：购买 HDTV 的人中，购买健身器的比例反而**低于**未买 HDTV 的大学生。
  - 在职人员：同样出现相反的结果。
- **原因**：大学生群体中，购买 HDTV 的比例低，但购买健身器的比例本就低；而在职人员中，购买 HDTV 的比例高，同时购买健身器的比例也高。当合并时，在职人员的"双重高"掩盖了分组内部的负相关。

示例 2：伯克利大学研究生院录取（真实案例，1973 年）

- **总体数据**：男性录取率约 44%，女性录取率约 35% → 结论：可能存在性别歧视。
- **按专业分组**：大部分专业中，**女性录取率高于男性**。
- **原因**：女性集中在竞争激烈、录取率低的专业（如英语、心理学）；男性集中在录取率高的专业（如工程、计算机）。不同专业报考人数差异极大，导致总体比较时出现偏差。

辛普森悖论的本质原因

因素	说明
混杂变量（潜伏变量）	分组依据（如专业、身份）是一个未被控制的重要变量，它同时影响自变量和因变量。
不等样本量	各组样本大小差异悬殊，小样本组内的极端值可能扭曲总体趋势。
不恰当的总括	将不同质的数据直接合并，忽略了分层结构。

> 数学本质：两个条件概率的加权平均与各个条件概率的方向并不必然一致。

如何避免辛普森悖论

1. **合理分层（Stratification）**：根据领域知识，识别可能的混杂变量（如年龄、地区、专业、收入等级），先按层分析再综合结论。
2. **使用多变量回归（Multivariate Regression）**：将混杂变量作为协变量纳入模型，控制其影响。
3. **计算层间标准化（Standardization）**：如计算"直接标准化率"（按专业人数加权平均的女性录取率）。
4. **可视化分组数据**：绘制分组散点图、分组条形图，观察是否存在交叉现象。
5. **警惕"总体结论"**：当发现总体结论与常识或直觉相悖时，主动检查是否存在分组逆转。

辛普森悖论的现实意义

- **数据科学**：在 A/B 测试、用户行为分析、医疗效果评估中，忽略混杂变量会导致错误决策。
- **公共政策**：统计数据可能被误用，需结合分组分析避免偏见。

- **机器学习**：特征选择时应考虑交互效应，避免模型学到虚假相关性。

> **警示：总体的平均数不等于分组平均数的平均数**，尤其当各组规模差异极大时。

4.2.8 关联规则挖掘扩展

多维关联规则

如：{购买:电脑} ∧ {年龄 ∈ [20,30]} → {购买:手机}

多层关联规则

利用概念层次提高支持度。如：{光明牛奶} 的支持度低，抽象化为 {牛奶} 等高层概念。

```
光明牛奶 → 牛奶（概念层次提升）
```

稀有模式挖掘

应用：欺诈检测、金融安全（普通交易行为 vs 非正常/欺诈交易）

负模式挖掘

如：{可口可乐} → ¬{百事可乐}

序列模式挖掘

考虑时间顺序：$A \rightarrow B \rightarrow C$，而非简单共现。

序列模式挖掘算法：

- **类 Apriori 算法**：序列模式的任一子序列也是序列模式。代表：GSP、SPADE。
- **基于划分的模式生长算法**：基于分治思想，迭代划分数据。代表：FreeSpan、PrefixSpan。
- **基于序列比较的算法**：定义序列大小度量，枚举所有 k-序列。代表：Disc-all。

预测方法扩展：时间序列分析方法（AR、MA、ARMA）、隐马尔可夫模型（HMM）、CRF、循环神经网络（RNN）。

4.3 分类与预测（Classification & Prediction）

4.3.1 监督学习基础

数据挖掘四大任务回顾：聚类（无监督）、分类与预测（监督）、关联分析（无监督）、异常检测（可监督/无监督）。

分类（Classification）：预测离散标签。示例：垃圾邮件识别、贷款违约预测、手写数字识别。

预测（Prediction / 回归）：预测连续数值。示例：房价预测、电影评分预测。

监督学习（Supervised Learning）：训练数据为 (X, Y)，其中 X 为特征向量（如收入、年龄），Y 为标签（如是否违约）。目标是学习映射 $f(X) = Y$，用于预测新样本。

一般流程：

1. **模型训练**：利用训练数据（有标签），学习一个分类或预测模型。流程：训练集 → 学习算法 → 模型
2. **模型预测**：利用学习的模型，预测测试数据的标签。流程：测试集 → 模型 → 预测标签

常见分类方法：

- 规则分类（可解释性强但人工构造困难）
- 决策树（直观，可处理混合类型特征）
- 贝叶斯分类（朴素贝叶斯假设特征独立）
- KNN（懒惰学习，依赖距离）
- SVM（核技巧，适合小样本）
- 神经网络（表达力强，需大量数据）
- 集成学习（随机森林、XGBoost，精度高）

4.3.2 决策树（Decision Tree）

基本概念

定义：树形结构分类模型，通过选择最优特征递归划分数据。内部节点为特征测试，分支为测试输出，叶节点为类别（或回归值）。

组成：

- **根节点**：第一个分裂特征
- **内部节点**：属性测试
- **叶节点**：类别标签
- **路径**：对应分类规则，如 `(HomeOwner=No) ∧ (Married=Yes) → Borrower=No`

优势：可解释性强（路径即规则）、无需特征缩放、可处理混合类型特征。

训练流程（Hunt 贪心算法框架）

1. 若当前节点样本全属同一类 → 标记为叶节点并返回。
2. 否则，选择最优特征（分裂属性）将样本划分为若干子集。
3. 对每个子集递归执行步骤 1~2，直到满足停止条件（样本数小于阈值、无特征可用等）。

三个关键步骤：

1. **特征选择**：选择最优分裂特征（核心问题）
2. **生成决策树**：递归分裂直到满足停止条件
3. **剪枝**：防止过拟合

特征选择指标（核心）

熵（Entropy）

$$H(D) = -\sum_{i=1}^{c} p_i \log_2 p_i$$

其中 c 为类别数，p_i 为第 i 类样本占比。熵越小，纯度越高。

信息增益（Information Gain）

$$\text{Gain}(D, A) = H(D) - \sum_{j=1}^{v} \frac{|D_j|}{|D|} H(D_j)$$

选择增益最大的特征（ID3 算法）。

例题：10 个样本（5 正 5 负），按特征 A 划分：D_1(6 个，4 正 2 负)，D_2(4 个，1 正 3 负)。

$$\begin{aligned} H(D) &= 1 \\ H(D|A) &= \frac{6}{10}\left(-\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right)\right) + \frac{4}{10}\left(-\left(\frac{1}{4}\log_2\frac{1}{4} + \frac{3}{4}\log_2\frac{3}{4}\right)\right) \\ &= 0.6 \times 0.918 + 0.4 \times 0.811 = 0.875 \\ \text{Gain} &= 1 - 0.875 = 0.125 \end{aligned}$$

> **注意**：信息增益倾向于选择取值较多的特征，容易导致过拟合。

增益率（Gain Ratio）

信息增益倾向于选择取值较多的特征，容易导致过拟合。增益率通过引入"分裂信息"（Split Information）作为惩罚项，来平衡特征取值个数的影响。增益率由 Quinlan 在 C4.5 算法中提出。

$$\text{GainRatio}(D, A) = \frac{\text{Gain}(D, A)}{\text{SplitInfo}(D, A)}$$

其中：

- $\text{Gain}(D, A)$ 是特征 A 的信息增益。
- $\text{SplitInfo}(D, A) = -\sum_{j=1}^{v} \frac{|D_j|}{|D|} \log_2 \frac{|D_j|}{|D|}$，本质上是特征 A 自身取值的熵（即按 A 划分后子集大小的分布信息）。取值越多、分布越均匀，分裂信息越大。

计算示例：

设有数据集 D 包含 10 个样本，二分类（正负各 5 个），$H(D) = 1$。

- **特征 A**：取值 $\{A_1, A_2\}$，划分结果：D_1 含 6 个样本（4 正 2 负），D_2 含 4 个样本（1 正 3 负）。
  - 信息增益 $\text{Gain}(D, A) = 1 - 0.875 = 0.125$
  - 分裂信息 $\text{SplitInfo}(D, A) = -\frac{6}{10}\log_2\frac{6}{10} - \frac{4}{10}\log_2\frac{4}{10} = 0.971$
  - 增益率 $= 0.125 / 0.971 \approx 0.129$
- **特征 B**：取值 5 种，每个取值 2 个样本，各子集类别平衡（1 正 1 负）。信息增益 = 0，增益率 = 0。
- **特征 C**（极端情况）：取值有 10 种，每个子集 1 个样本（训练集完全分开）。
  - 信息增益 = 1（子集熵均为 0）
  - 分裂信息 ≈ 3.322
  - 增益率 ≈ 0.301

- 而另一个普通特征 D，信息增益 0.8，分裂信息 1，增益率 = 0.8 → 增益率会倾向于选 D，避免过拟合。

C4.5 中的启发式策略：

1. 先计算每个特征的信息增益，仅保留信息增益**高于平均水平**的特征。
2. 在这些候选特征中选择增益率最大的作为分裂特征。

优点：有效缓解信息增益对多值特征的偏好，提高泛化能力。 **缺点**：计算稍复杂（需要额外计算分裂信息）；当分裂信息趋近于 0 时无法使用。

基尼指数（Gini Index）

基尼指数（Gini Index）是衡量数据集不纯度（impurity）的常用指标，被引入决策树算法（尤其是 CART 算法）。对于包含 c 个类别的数据集 D：

$$\text{Gini}(D) = 1 - \sum_{i=1}^{c} p_i^2$$

其中 p_i 是第 i 类样本在数据集中的比例。基尼指数表示从数据集中随机抽取两个样本，其类别不一致的概率。该值越小，数据集的纯度越高。

取值范围：

- 当所有样本属于同一类别时，$\text{Gini} = 1 - 1 = 0$，纯度最高。
- 当各类别样本均匀分布时，$p_i = 1/c$，则 $\text{Gini} = 1 - 1/c$。二分类时 $\text{Gini} = 0.5$；三分类时 $\text{Gini} \approx 0.667$。

基尼增益：

使用特征 A 对数据集 D 进行划分（假设产生 v 个子集 $D_1, D_2, \ldots, D_v$），划分后的基尼指数加权平均为：

$$\text{Gini}_{\text{split}}(D, A) = \sum_{j=1}^{v} \frac{|D_j|}{|D|} \text{Gini}(D_j)$$

基尼增益（Gini Gain，也称基尼系数减少量）为：

$$\Delta\text{Gini}(D, A) = \text{Gini}(D) - \text{Gini}_{\text{split}}(D, A)$$

CART 算法选择使 **基尼增益最大** 的特征作为当前节点的分裂特征。

计算示例：

设有数据集 D 包含 10 个样本：正类 6 个，负类 4 个。

$$\text{Gini}(D) = 1 - \left(\frac{6}{10}\right)^2 - \left(\frac{4}{10}\right)^2 = 1 - 0.36 - 0.16 = 0.48$$

考虑特征 A 将 D 划分为两个子集：

- D_1：5 个样本（正类 4，负类 1） → $\text{Gini}(D_1) = 1 - (4/5)^2 - (1/5)^2 = 0.32$
- D_2：5 个样本（正类 2，负类 3） → $\text{Gini}(D_2) = 1 - (2/5)^2 - (3/5)^2 = 0.48$

$$\text{Gini}_{\text{split}} = \frac{5}{10} \times 0.32 + \frac{5}{10} \times 0.48 = 0.40$$

基尼增益：$0.48 - 0.40 = 0.08$。

与熵的对比：

- 基尼指数和熵都是衡量不纯度的指标，通常表现相似。基尼指数计算不涉及对数，速度略快；熵对概率变化在对数尺度上更敏感。
- CART 默认使用基尼指数，ID3/C4.5 使用熵/增益率。
- 对于二分类，基尼指数与熵的转化关系近似为：$\text{Gini} \approx 2H - H^2$（在一定范围内），但并非精确等价。

分类错误率（Classification Error）

$$\text{Error}(D) = 1 - \max_i(p_i)$$

即不属于多数类的样本比例。较少单独作为分裂指标（对概率变化不够敏感）。

连续属性的分裂

对于连续属性，通常做法是：

1. 将连续属性的取值排序
2. 将每两个相邻值的中点作为候选分裂点
3. 计算每个候选分裂点的信息增益（或基尼增益），选择最优分裂点

常用决策树算法对比

算法	分裂指标	处理类型	剪枝	输出
ID3	信息增益	离散特征	无	多叉树
C4.5	增益率	离散+连续	后剪枝	多叉树
CART	基尼指数/均方误差	离散+连续	成本复杂度剪枝	二叉树

停止分裂条件

满足以下任一条件时停止分裂：

- 当前节点所有样本属于同一类别
- 当前节点样本数小于设定阈值
- 无可用特征
- 分裂后信息增益（或其他指标）小于阈值

过拟合与剪枝

过拟合原因：

1. **噪声**：训练数据中的噪声被树学习到
2. **缺乏代表性样本**：训练集不能代表全体数据
3. **多重比较过程**：决策树在众多分裂选项中反复选择，可能偶然产生看似好的分裂

剪枝（Pruning）：防止过拟合。

- **预剪枝**：在建树过程中提前停止（设最小样本数、最大深度、最小信息增益等）
- **后剪枝**：先建完整树，再自底向上将子树替换为叶节点（基于验证集误差或成本复杂度）

决策树优缺点

优点	缺点
可解释性强，可视化好	容易过拟合（尤其深层树）
无需特征标准化	对噪声敏感
能处理非线性关系	类别不平衡时偏向多类
可处理混合类型特征	贪心搜索可能非全局最优

> 实际应用中，常使用集成方法（随机森林、梯度提升树）弥补单棵决策树的不足。

4.3.3 贝叶斯分类器（Bayesian Classifier）

贝叶斯定理

后验概率计算：

$$P(C \mid A_1, A_2, \ldots, A_n) = \frac{P(A_1, A_2, \ldots, A_n \mid C) P(C)}{P(A_1, A_2, \ldots, A_n)}$$

- C：类别变量
- A_i：样本的第 i 个属性

选择使后验概率最大的类别：

$$\hat{C} = \arg\max_C P(C) \prod_{i=1}^{n} P(A_i \mid C)$$

朴素贝叶斯（Naïve Bayes）

核心假设：在给定类别 C 的条件下，各属性 A_i 相互独立。

$$P(A_1, A_2, \ldots, A_n \mid C) = \prod_{i=1}^{n} P(A_i \mid C)$$

概率估计：

- **离散属性**：$P(A_i = a \mid C = c) = \frac{\text{训练集中 } A_i = a \text{ 且 } C = c \text{ 的样本数}}{N_c}$
- **连续属性**：通常假设服从正态分布

$$P(A_i = a \mid C = c) = \frac{1}{\sqrt{2\pi}\sigma_{ic}} \exp\left(-\frac{(a - \mu_{ic})^2}{2\sigma_{ic}^2}\right)$$

其中 μ_{ic}, σ_{ic}^2 分别为类别 c 中属性 A_i 的样本均值和方差。

拉普拉斯平滑（Laplace Smoothing）

为避免零概率导致连乘结果为 0，对每个计数加 1（或 α）：

$$P(A_i = a \mid C = c) = \frac{\text{count}(A_i = a, C = c) + 1}{\text{count}(C = c) + |\text{values}(A_i)|}$$

4.3.4 K 近邻（K-Nearest Neighbors, KNN）

基本思想

- **基于实例的学习**，不需要显式训练过程
- **假设**：相似的样本应属于同一类别
- **预测**：对于测试样本，找出训练集中最相似的 K 个样本，通过投票（分类）或平均（回归）得到结果

距离度量

- **欧几里得距离**：$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{m}(x_i - y_i)^2}$
- **曼哈顿距离**：$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{m}|x_i - y_i|$
- **汉明距离**（用于二进制向量）
- **余弦相似度**：$\cos\theta = \frac{\mathbf{x}\cdot\mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|}$

K 的选择

K	影响
太小	容易受噪声影响，过拟合
太大	可能包含其他类别的样本，决策边界平滑

常用方法：交叉验证选择最优 K。

特点

优点	缺点
简单直观，无需训练	预测时计算量大（需计算所有训练样本距离）
对异常值相对鲁棒（若 K 较大）	对特征缩放敏感
适用于多分类问题	需要存储全部训练数据

4.3.5 感知机（Perceptron）

模型定义

二分类线性模型：

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x} + b)$$

其中：

- $\mathbf{w}$：权重向量
- b：偏置
- $\text{sign}(z) = \begin{cases} +1, & z \geq 0 \\ -1, & z < 0 \end{cases}$

损失函数

对于误分类点集合 M，损失函数为：

$$L(\mathbf{w}, b) = -\sum_{\mathbf{x}_i \in M} y_i(\mathbf{w}^\top \mathbf{x}_i + b)$$

学习算法（原始形式）

随机梯度下降（SGD）：

$$\mathbf{w} \leftarrow \mathbf{w} + \eta y_i \mathbf{x}_i, \quad b \leftarrow b + \eta y_i$$

其中 η 为学习率。

收敛条件：训练集线性可分时，经过有限次迭代后误分类点数为 0。

局限性

- 只能解决**线性可分**问题
- 对噪声敏感
- 无法处理异或（XOR）等非线性问题

感知机 vs 逻辑回归

感知机和逻辑回归**不是同一个算法**，它们有本质区别：

对比项	感知机	逻辑回归
输出	离散类别（通常 +1 / -1）	概率值（0~1），再阈值化得到类别
激活/链接函数	阶跃函数（sign）	Sigmoid 函数
损失函数	误分类点到超平面的距离之和	交叉熵（负对数似然）
输出解释	直接输出类别	输出为属于正类的概率
收敛条件	要求数据线性可分	线性不可分也能给出概率预测
参数求解	随机梯度下降（每次用一个误分类点更新）	梯度下降（基于全部样本或 mini-batch）
本质	线性分类器，几何解释为找分离超平面	线性分类器，但输出概率，属于广义线性模型

简单记忆：

- 感知机：硬分类，只输出 ±1，线性可分才能收敛。
- 逻辑回归：软分类，输出概率，线性不可分也能用，是更现代、更常用的基础模型。

4.3.6 支持向量机（Support Vector Machine, SVM）

核心思想

寻找一个超平面 $\mathbf{w}^\top \mathbf{x} + b = 0$，使得两类样本到超平面的**间隔（margin）最大**。

间隔与支持向量

- **函数间隔**：$\hat{\gamma}_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b)$
- **几何间隔**：$\gamma_i = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}$

最大化几何间隔等价于：

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \ldots, n$$

其中"1"可以任意缩放，不影响最终超平面。

软间隔与松弛变量

允许部分样本不满足约束，引入松弛变量 ξ_i：

$$\min_{\mathbf{w},b,\xi} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0$$

- C：惩罚参数，控制对误分类的容忍程度

核函数（Kernel Trick）

将数据映射到高维空间，使线性不可分变为线性可分。

常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$
高斯核（RBF）	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$	$\sigma > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\beta > 0,\ \theta < 0$

特点

优点	缺点
泛化能力强（最大化间隔）	对大规模数据训练慢
可处理高维数据	对核函数选择敏感
仅依赖支持向量，内存高效	不易解释

4.3.7 集成学习（Ensemble Learning）

基本思想

结合多个基学习器的预测，获得比单一学习器更优的性能。

Bagging（Bootstrap Aggregating）

步骤：

1. 有放回地从训练集中采样 T 个大小为 m 的子集
2. 在每个子集上训练一个基学习器
3. 分类：投票；回归：平均

代表性算法：随机森林（Random Forest）

特点：降低方差，适合不稳定学习器（如决策树）

Boosting

步骤：

1. 初始样本权重相等
2. 每一轮训练一个基学习器，并根据其错误率更新样本权重（错误分类的样本权重增加）
3. 最后加权投票（权重为 α_t）

AdaBoost（Adaptive Boosting）： 基学习器 C_t 的投票权重：

$\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$

其中 ϵ_t 为加权错误率。预测时，将所有基学习器的投票按 α_t 加权求和，取最大类。

集成方法比较

方法	基学习器关系	并行/串行	主要作用	代表算法
Bagging	独立	并行	降低方差	随机森林
Boosting	依赖	串行	降低偏差	AdaBoost, GBDT, XGBoost

4.3.8 模型评估与选择

混淆矩阵

	预测为正	预测为负
真实为正	TP	FN
真实为负	FP	TN

衍生指标

- **准确率（Accuracy）**：$\frac{TP+TN}{TP+TN+FP+FN}$
- **精确率（Precision）**：$\frac{TP}{TP+FP}$
- **召回率（Recall）**：$\frac{TP}{TP+FN}$
- **F1 分数**：$2\times\frac{\text{Precision}\times\text{Recall}}{\text{Precision}+\text{Recall}}=\frac{2TP}{2TP+FP+FN}$

例题：TP=60, FN=40, FP=20, TN=80 → Accuracy=140/200=0.7，Precision=60/80=0.75，Recall=60/100=0.6，F1≈0.667。

处理不平衡数据

- 使用精确率/召回率/F1 替代准确率
- **ROC 曲线**：横轴为假正率（FPR），纵轴为真正率（TPR）
  - FPR = $\frac{FP}{TN+FP}$，TPR = $\frac{TP}{TP+FN}$
- **AUC**：ROC 曲线下的面积，值越大模型越好。AUC=1 完美分类器；AUC=0.5 随机猜测。

其他指标

- **对数损失（Log Loss）**：用于概率预测
- **均方误差（MSE）、平均绝对误差（MAE）**：用于回归

验证方法

方法	描述
留出法（Hold-out）	按比例划分训练集/测试集
K 折交叉验证（K-fold CV）	将数据分成 K 份，轮流做测试集，最终取平均值
留一法（LOOCV）	K = n，适用于小样本
自助法（Bootstrap）	有放回采样，用于集成学习或小样本估计

4.4 时间序列预测（Time Series Forecasting）

4.4.1 时间序列成分

- **趋势（Trend）**：长期上升、下降或平稳
- **季节性（Seasonality）**：固定周期波动（如每周、每年）
- **周期性（Cyclicality）**：不固定周期的波动（如经济周期）
- **随机性（Irregularity）**：不可预测的噪声

4.4.2 常用模型

ARIMA（自回归积分滑动平均模型）

ARIMA 是时间序列预测的经典线性模型，由三部分构成：**AR (p)**（自回归）、**I (d)**（差分）、**MA (q)**（移动平均）。其数学表达式（对差分后的平稳序列 w_t）为：

$$w_t = c + \phi_1 w_{t-1} + \cdots + \phi_p w_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

其中 w_t是对原始数据序列做d阶差分得到的差分序列，ε_t 为白噪声。当 $d = 0$ 时即为 ARMA(p,q)。

ARIMA(p,d,q)的三个参数分别代表自回归依赖的过去数据个数、差分阶数和移动平均依赖的过去数据个数。

平稳性与差分
ARIMA 要求序列平稳（均值、方差不随时间变化）。通过 **ADF 检验** 判断：p-value < 0.05 则平稳。若不平稳，进行 **差分**（$d = 1$ 一阶差分，$d = 2$ 二阶差分，极少超过 2）。过差分会破坏自相关结构。

确定 p 和 q（ACF / PACF）
对差分后的平稳序列计算：

- **自相关函数 ACF**：MA(q) 模型在滞后 q 后截尾；
- **偏自相关函数 PACF**：AR(p) 模型在滞后 p 后截尾。
  若两者均拖尾，则需尝试 ARMA(p,q)。也可根据 **AIC / BIC** 信息准则选择最优模型。

模型拟合与诊断
常用最大似然估计（MLE）或最小二乘法估计参数 ϕ_i, θ_i。拟合后需检查 **残差是否为白噪声**：残差序列应无趋势，其 ACF/PACF 各滞后点接近 0，且 **Ljung-Box 检验** p-value > 0.05。若不通过，则调整 p, q 或加入季节性。

预测方法（含例题）

对序列求d阶差分，然后套公式

例题：已知某商品日销量满足 ARIMA(1,1,1)，$\phi_1 = 0.6,\ \theta_1 = 0.3,\ c = 0$。最近数据如下：

t	实际 y_t	预测 $\hat{y}_t$	残差 ε_t
5	50	48	2
6	53	55	-2
7	49	50	-1

预测第 8 天销量 $\hat{y}_8$。

解：
$\hat{y}_8 = y_7 + \phi_1(y_7 - y_6) + \theta_1\varepsilon_7$
$= 49 + 0.6 \times (49 - 53) + 0.3 \times (-1) = 49 - 2.4 - 0.3 = 46.3$
答：46.3。

多步预测时递归代入，且未来残差设为 0。

局限性

- 只捕捉**线性**关系，无法处理非线性模式（如突变、门限效应）。
- **单变量**，不能融合外部特征（天气、节假日等）。
- 仅适合**短期预测**，长期误差累积严重。
- 需手动选择 p, d, q（虽有自动算法，但仍有局限）。
- 对缺失值、异常值敏感。

扩展

- **SARIMA**：加入季节性成分，形式为 ARIMA(p,d,q)(P,D,Q)_s，处理周期波动。
- **ARIMAX**：引入外生变量 x_t：$y_t = \beta x_t + \mathrm{ARIMA}(p,d,q)$。
- 深度学习模型（LSTM、Transformer）可处理非线性和长序列，但可解释性较差。

建模流程总结
原始序列 → ADF 平稳性检验 → 若不平稳则差分（d 次）→ 观察 ACF/PACF 确定 p, q（结合 AIC/BIC）→ 拟合 ARIMA(p,d,q) → 残差诊断（Ljung-Box）→ 通过后生成预测。

ETS（指数平滑状态空间模型）

将序列分解为 **误差（Error）**、**趋势（Trend）**、**季节性（Seasonal）** 三个成分，每个成分可为加性（A）或乘性（M）。 常用组合：ETS(A,A,A)（加性误差、加性趋势、加性季节）。

适用：有明确趋势和季节性的数据，解释性强。

Theta 模型

构造两条 Theta 线：

- $\theta = 0$：只保留长期趋势（线性回归）
- $\theta = 2$：放大局部波动（指数平滑）

预测结果为两条线预测值的加权平均。

特点：简单高效，在 M3 竞赛中表现优异。

4.4.3 评价指标（回归）

- **MSE**：$\frac{1}{n}\sum(y_i - \hat{y}_i)^2$
- **MAE**：$\frac{1}{n}\sum|y_i - \hat{y}_i|$
- **RMSE**：$\sqrt{\mathrm{MSE}}$
- **MAPE**：$\frac{100\%}{n}\sum\left|\frac{y_i - \hat{y}_i}{y_i}\right|$
- **CRPS**（连续排序概率分数）：评估概率预测分布与真实值的吻合程度，值越小越好。

4.5 聚类分析（Clustering）

4.5.1 基本概念

- 无监督学习，将样本划分为若干**簇（cluster）**，使得**簇内相似、簇间相异**
- 三个关键问题：
    1. 如何定义"簇"?
    2. 如何度量相似性（距离）？
    3. 如何确定簇的数量?

4.5.2 K-means 聚类

算法步骤：

1. 随机选择 K 个初始中心点

2. 将每个样本分配到最近的中心点
3. 重新计算每个簇的中心（均值）
4. 重复 2–3 直到收敛

目标函数（误差平方和 SSE）：

$$\text{SSE} = \sum_{i=1}^{K} \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mathbf{m}_i\|^2$$

特点：

优点	缺点
简单快速，适合大规模数据	需预设 K
对球状簇效果好	对初始中心敏感
容易解释	对噪声和异常值敏感，只适用于数值型数据

改进方法：多次初始化、二分 K-means。

4.5.3 层次聚类（Hierarchical Clustering）

- **凝聚式（自底向上）**：每个样本初始为单独簇，逐步合并最近的两个簇
- **分裂式（自顶向下）**：所有样本为一个大簇，逐步分裂

簇间距离度量：

方法	定义	特点
单链（MIN）	两个簇最近点之间的距离	能处理非椭圆形状，但对噪声敏感
全链（MAX）	两个簇最远点之间的距离	对噪声鲁棒，易破碎大簇
组平均	簇间所有点对距离的平均	折中方案
中心距离	簇中心之间的距离	类似 K-means

优势：无需事先指定 K，可输出树状图（dendrogram）。

4.5.4 密度聚类（DBSCAN）

核心概念：

- **ε-邻域**：以点 p 为中心、半径为 ε 的区域
- **核心点**：ε-邻域内至少包含 MinPts 个点
- **边界点**：不是核心点，但落在某个核心点的 ε-邻域内
- **噪声点**：既不是核心点也不是边界点

算法流程：

1. 找出所有核心点
2. 将距离在 ε 内的核心点连接成簇
3. 将边界点分配给关联的核心点簇
4. 剩余点为噪声

特点：

优点	缺点
可发现任意形状的簇	对参数 ε 和 MinPts 敏感
对噪声鲁棒	密度差异大时效果差

4.5.5 聚类评估

- **内部指标**（无标签）：SSE、轮廓系数（Silhouette Coefficient）
- **外部指标**（有标签）：熵、Jaccard 系数、纯度（Purity）
- **相对指标**：比较不同参数或算法，如 SSE 随 K 的变化（肘部法则）

4.6 异常检测（Anomaly Detection）

4.6.1 定义

找出数据集中与大多数数据显著不同的样本（异常点/离群点）。

特点：

- 异常点通常稀少
- 可能有重要含义（欺诈、入侵、故障）

4.6.2 常用方法

类别	方法	说明
基于统计	箱图（IQR）、z-score	假设数据分布，超出一定范围即为异常
基于距离	KNN 距离	异常点远离大部分点
基于密度	DBSCAN、LOF	局部密度显著低的点为异常
基于聚类	聚类后不属于任何簇的点	小簇或孤立点
基于模型	孤立森林、自编码器	学习正常模式，重构误差大者为异常

4.6.3 应用场景

- 信用卡欺诈检测
- 网络入侵检测
- 工业设备故障预警
- 医疗健康（心率/血压异常）

第四章 总结

任务	核心方法	特点
关联分析	Apriori, FP-Growth	发现项集间的规律，需设定 minsup 和 minconf
分类	决策树、朴素贝叶斯、KNN、SVM、集成学习	有监督，需标签数据
预测（回归/时间序列）	ARIMA, ETS, Theta	预测连续值或未来趋势
聚类	K-means, 层次聚类, DBSCAN	无监督，发现自然分组
异常检测	统计、距离、密度、模型	识别罕见样本

> **考试建议**：重点掌握 **支持度/置信度/Lift** 计算、Apriori 剪枝过程、FP-Growth 思想、**决策树分裂指标（熵、基尼系数、增益率）**、朴素贝叶斯估计、SVM 间隔思想、集成学习基本概念（Bagging vs Boosting）、聚类评估、异常检测常见方法。熟练运用 **混淆矩阵** 计算各项指标（准确率、精确率、召回率、F1），理解 **ROC/AUC** 含义。

附录

我叫王露露，今年二十岁了。我在中国科学技术大学上学。我有一门课叫做数据分析及实践，同学们上这门课可高兴了。刘淇老师是一个非常慈祥的老师，程明月老师是一个非常好玩的老师，三个助教是三个非常认真的助教，我要向他们学习。