数据分析及实践 — 复习讲义

> 基于刘淇老师、程明月老师课堂内容整理 | 中国科学技术大学

第一部分：知识架构

第一章：数据科学基础

1.1 大数据的特点（4V）

- **核心概念**：大数据的四个维度 — Volume（数据量大，PB级）、Variety（种类多样，结构化/半结构化/非结构化）、Velocity（高实时性，产生与处理速度快）、Value（价值巨大，蕴含潜在商业/科研价值）
- **考试重点**：能说出 4V 并简要解释每个 V 的含义

1.2 科学范式演进

- **核心概念**：五个范式依次为 — 经验科学（观察实验）→ 理论科学（数学模型）→ 计算科学（计算机模拟）→ 数据密集化科学（以数据为中心）→ 第五范式（AI 辅助科研）
- **易混淆点**：第三范式（计算科学）与第四范式（数据密集化科学）的区别 — 前者重模拟，后者重数据驱动发现
- **考试重点**：能列举五个范式并说出代表性特征

1.3 合成数据（Synthetic Data）

- **核心概念**：基于计算机模拟或算法生成的人造数据，模仿现实世界观察
- **优势**：低成本、可控性强、无隐私安全问题、可减少真实世界偏见
- **缺陷**（七大类）：数据质量（真实性不足、过度简化）、偏差问题（放大原始偏差）、模型退化（自噬循环、分布崩塌）、评估困难（缺乏统一标准）、法律风险（版权争议）、成本门槛（训练计算量大）、缺乏反馈（无法捕捉动态变化）
- **易混淆点**：合成数据（无中生有）vs 数据增强（有中生更多）
- **考试重点**：合成数据的优缺点对比

1.4 数据的未来：数据 Prompt 化

- **核心概念**：将各类数据（如图、表格）描述为文本，利用 LLM 的自然语言理解能力处理
- **考试重点**：理解"数据 Prompt 化"的基本思路

1.5 什么是数据科学

- **核心概念**：基于数学、统计学理论，运用计算机技术进行大规模数据计算、分析与应用的学科
- **另一种表述**（鄂维南院士）：用数据的方法研究科学，用科学的方法研究数据

第二章：数据入门

2.1 数据采集

2.1.1 检索与公开数据

- **核心概念**：Google Dataset Search（2018）、ImageNet（1400万图像）、国内公开数据（国家统计局）
- **代表性公开数据集**：MovieLens、SNAP、阿里天池、KDDCup
- **考试重点**：知道几个代表性数据集的名称和用途

2.1.2 合成数据与数据增强

- **核心概念**：合成数据是从零生成；数据增强是对已有数据做变换（如 AugGPT 利用 LLM 重构语义相似样本）
- **Gartner 预测**：到 2030 年，合成数据将完全超越真实数据用于 AI 模型
- **考试重点**：区分两者概念

2.1.3 数据众包

- **核心概念**：利用大众力量收集、分析和处理数据的模式
- **对比**：专家标注（准确高、人少、慢、贵）vs 众包标注（准确低、人多、快、便宜）
- **考试重点**：众包流程（需求方 → 平台 → 大众 → 质量评估 → 返回）

2.1.4 网络爬虫

- **核心概念**：
  - 行为流程：载入 → 解析 → 存储
  - **GET vs POST**：GET 参数在 URL，不安全，长度受限；POST 参数在请求体，更安全
  - **响应状态码**：200（成功）、404（未找到）
  - **动态页面处理**：Ajax 需抓包分析（Charles）或 Selenium/WebDriver 模拟浏览器
- **反爬虫与应对**：验证码、封 IP → 减少频率、多 Cookie、多 IP 代理
- **数据解析**：JSON（简洁、体积小、易编解码）vs XML（规范、描述能力强、支持命名空间和属性）
- **Robots 协议**：网站通过 `robots.txt` 规定可爬取范围
- **法律合规**：《数据安全法》（2021）、《生成式人工智能服务管理暂行办法》（2023）
- **考试重点**：GET/POST 区别、JSON vs XML 对比、反爬应对策略、法律红线

2.1.5 去重服务

- **核心概念**：Bloom 过滤器 — 二进制向量 + 多个哈希函数，所有哈希结果一致判定为重复

2.2 数据存储

2.2.1 数据类型

- **三种类型**：
  - 结构化数据：关系型数据库、二维表，固定结构
  - 半结构化数据：XML、JSON，含自描述标记
  - 非结构化数据：文本、图像、视频、音频，无固定结构

2.2.2 关系型数据库（SQL）

- **核心概念**：
  - 逻辑结构：二维表（行 = 元组，列 = 属性），必须满足第一范式（每个分量不可再分）
  - **完整性**：实体完整性（主键唯一非空）、参照完整性（外键约束）、用户定义完整性
  - **安全性**：自主存取控制（DAC，用户自主授权）、强制存取控制（MAC，系统标记安全等级）
  - **索引**：B+树（动态平衡）、Hash（快速查找），PRIMARY KEY 和 UNIQUE 自动建索引
- **关系模式的不足**：数据冗余、更新异常、插入异常、删除异常
- **考试重点**：三种完整性、MAC 的读写规则（主体许可证 ≥ 客体密级可读，≤ 可写）

2.2.3 NoSQL 数据库

- **四大类型**：

类型	代表	数据模型	优点	适用场景
文档型	MongoDB	文档（BSON）	灵活无固定结构	Web应用、日志
键值型	Redis	哈希表	极快	缓存、计数器、秒杀
列存储	HBase	列簇	高扩展、压缩好	日志、大数据分析
图数据库	Neo4j	节点+关系	免索引邻接 O(1)	社交网络、推荐

- **NoSQL vs RDBMS**：NoSQL 无预定义模式、最终一致性、CAP 定理；RDBMS 高度组织化、SQL、ACID
- **易混淆点**：MongoDB 的 BSON vs JSON；Redis 的多种 value 类型
- **考试重点**：四种 NoSQL 的对比选择、CAP vs ACID

2.2.4 图像与图数据存储

- **图像存储**：存路径、存像素值（彩色图 = H×W×3 数组，灰度图 = H×W 数组，0~255）
- **图存储**：Neo4j 的免索引邻接实现 O(1) 遍历（深度 5 朋友查询：MySQL 1543s vs Neo4j 2.13s）

2.3 数据预处理

2.3.1 数据清理 — 缺失值

- **缺失类型**：
  - MCAR（完全随机缺失）：缺失与任何变量无关，可安全删除
  - MAR（随机缺失）：缺失仅与已观测变量有关，与缺失值本身无关 → 可用回归/EM 填补
  - MNAR（非随机缺失）：缺失与自身取值有关 → 需专门建模
- **处理方法**：删除、特殊值填充、均值/中位数/众数、热卡填充、KNN、回归模型、EM 算法
- **易混淆点**：MAR 的"随机"是条件随机（给定观测变量后），不是无条件随机
- **考试重点**：三种缺失机制的辨析与对应的处理策略

2.3.2 数据清理 — 噪声

- **方法**：
  - **分箱（Binning）**：等深分箱 → 按箱均值/中值/边界平滑
  - **回归**：用回归模型平滑不符合趋势的数据
  - **聚类**：识别落在簇外的离群点

2.3.3 数据集成 — 冗余检测

- **Pearson 相关系数**：衡量线性相关程度，[-1, 1]
  - 样本公式：$r = \frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum(X_i-\bar{X})^2 \cdot \sum(Y_i-\bar{Y})^2}}$
- **卡方检验**：判断两个分类变量是否独立
  - 公式：$\chi^2 = \sum \frac{(O_{ij}-E_{ij})^2}{E_{ij}}$，$E_{ij} = \frac{\text{行合计} \times \text{列合计}}{\text{总样本数}}$
- **距离度量**：
  - 欧几里得：$d = \sqrt{\sum(p_k - q_k)^2}$
  - 曼哈顿：$d = \sum |p_k - q_k|$
  - 汉明：等长向量中不同位置的个数
  - 明可夫斯基：$d = \left(\sum |p_k - q_k|^r\right)^{1/r}$（r=1 曼哈顿，r=2 欧几里得）
  - 马氏距离：$D_M = \sqrt{(\mathbf{p}-\mathbf{q})^T \Sigma^{-1} (\mathbf{p}-\mathbf{q})}$，消除量纲和相关性影响
- **相似度**：
  - SMC（简单匹配系数）：$\frac{F_{11}+F_{00}}{F_{01}+F_{10}+F_{11}+F_{00}}$
  - Jaccard：$\frac{F_{11}}{F_{01}+F_{10}+F_{11}}$（排除全 0）
  - 余弦相似度：$\cos\theta = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|}$
- **有序数据度量**：
  - Spearman 秩相关系数：$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$
  - NDCG：$\mathrm{NDCG}_k = \frac{\mathrm{DCG}_k}{\mathrm{IDCG}_k}$，$\mathrm{DCG}_k = \sum_{i=1}^{k} \frac{2^{rel_i}-1}{\log_2(i+1)}$
- **考试重点**：各距离/相似度公式的适用场景，Pearson vs Spearman vs 卡方

2.3.4 数据变换

- **规范化**：
  - 最小-最大（归一化）：$v' = \frac{v - \min}{\max - \min} \times (new_max - new_min) + new_min$
  - z-score：$v' = \frac{v-\mu}{\sigma}$（假设正态分布）
  - 小数定标：$v' = v / 10^j$
- **离散化**：
  - 信息熵：$H(t) = -\sum p(j|t) \log_2 p(j|t)$
  - 信息增益：$Gain = H(P) - \sum \frac{n_i}{n} H(i)$
- **考试重点**：三种规范化方法的公式和对比，熵和信息增益的计算

2.3.5 数据规约

- **PCA**：去均值 → 协方差矩阵 $C = \frac{1}{m} X^T X$ → 特征值分解 → 取前 k 大特征向量 → $Y = XP$
- **特征子集选择策略**：
  - Filter：独立于模型（信息增益、距离）
  - Wrapper：以分类器性能评价（计算量大）
  - Embedded：特征选择嵌入训练（L1 正则化、决策树）
- **考试重点**：PCA 基本步骤、三种特征选择策略的区别

2.4 特征工程

2.4.1 基本概念

- **特征工程流程**：头脑风暴 → 特征设计 → 特征选择 → 评估模型 → 上线测试

- **特征越好 → 模型越灵活、越简单、性能越出色**

2.4.2 特征设计方法

- **One-hot 编码**：每个属性值对应一维。优点：直观简洁。缺点：维度灾难、语义鸿沟（所有向量正交）
- **TF-IDF**：$TF(w,d) = \frac{词出现次数}{文档总词数}$，$IDF(w) = \log \frac{N}{DF(w)}$（或 $\log \frac{N}{1+DF(w)}$），$TF\text{-}IDF = TF \times IDF$
  - 优点：简单快速、符合直觉；缺点：未考虑词序和位置、对短文本效果差
- **函数变换**：傅里叶变换（时域 → 频域）
- **特征组合**：高阶特征、因子分解机（FM）

2.4.3 特征学习（自动提取）

- **Auto-Encoder**：无监督学习特征
- **CNN**：层次化特征（Layer1 边缘/颜色 → Layer2 纹理/轮廓 → Layer3/4 物体部分）
- **RNN**：序列数据特征，保留位置和顺序信息
- **预训练模型**：ImageNet → ResNet/AlexNet/VGG；Word2Vec（CBOW, Skip-gram）；BERT, GPT, Transformer

2.4.4 特征选择

- **子集生成**：全局最优（穷举）、启发式（前向/后向/双向搜索）、随机（模拟退火、遗传算法）
- **评价策略**：Filter（独立于模型）、Wrapper（以分类器评价）、Embedded（嵌入训练）
- **L1 vs L2**：L1 使系数稀疏（自动特征选择），L2 使系数更平均

第三章：数据统计

3.1 数据分布基本指标

3.1.1 集中趋势

- **算术平均数**：$\mu = \frac{1}{n}\sum x_i$（未分组），$\mu = \frac{\sum x_i f_i}{\sum f_i}$（分组加权）
- **几何平均数**：$G = \sqrt[n]{x_1 x_2 \cdots x_n}$，适用于比率/增长率
- **中位数**：排序后中间位置的值
- **分位数**：Q_1（25%）、Q_2（50%，即中位数）、Q_3（75%）；IQR = $Q_3 - Q_1$
- **众数**：出现次数最多的值；异众比率 $V_r = 1 - \frac{f_m}{\sum f_i}$
- **易混淆点**：几何平均 vs 算术平均（增长率场景务必用几何平均）
- **考试重点**：各指标的定义、适用数据类型、箱图的组成要素

3.1.2 离散程度

- **方差**：$\sigma^2 = \frac{1}{N}\sum(x_i - \mu)^2$
- **标准差**：$\sigma = \sqrt{\sigma^2}$
- **极差**：$R = \max - \min$
- **四分位差**：$Q = Q_3 - Q_1$
- **变异系数**：$c_v = \frac{\sigma}{\mu}$，用于比较不同量纲/均值的离散程度
- **考试重点**：变异系数的使用场景（两个总体均值不等时比较离散程度）

3.1.3 分布形态

- **偏度**（Skewness）：三阶中心矩 / 标准差³。=0 对称，>0 右偏（长尾在右），<0 左偏
- **峰度**（Kurtosis）：四阶中心矩 / 方差²。正态分布 = 3，超额峰度 >0 尖峰，<0 平峰
- **箱图要素**：箱体（Q_1-Q_3）、中位线、须（Q_1-1.5×IQR 到 Q_3+1.5×IQR）、异常值（须外）
- **建模技巧**：均值≈中位数且偏度≈0 → 分布对称；极差/IQR 大 → 可能有长尾

3.2 参数估计

3.2.1 点估计方法

- **矩估计**：用样本矩替换总体矩
- **最小二乘估计（LSE）**：最小化残差平方和
- **极大似然估计（MLE）**：$\hat{\theta}_{MLE} = \arg\max_\theta L(\theta|X) = \arg\max_\theta \prod f(x_i|\theta)$
- **最大后验估计（MAP）**：$\hat{\theta}_{MAP} = \arg\max_\theta p(X|\theta)p(\theta)$，相当于 MLE + 正则化
- **贝叶斯估计**：计算后验分布 $p(\theta|X)$，而非单点值
- **易混淆点**：MLE vs MAP — MAP 引入了先验 $p(\theta)$；MLE vs 贝叶斯 — 贝叶斯求整个分布而非点估计
- **考试重点**：MLE 和 MAP 的计算、Beta-Binomial 共轭

3.2.2 点估计评价标准

- **无偏性**：$E(\hat{\theta}) = \theta$
- **有效性**：方差越小越有效
- **相合性（一致性）**：样本量越大，估计越接近真值
- **误差指标**：MAE = $\frac{1}{N}\sum|y_i - \hat{y}_i|$，MSE = $\frac{1}{N}\sum(y_i - \hat{y}_i)^2$，RMSE = $\sqrt{MSE}$

3.3 假设检验

- **基本原理**：小概率事件原理 + 反证法
- **两类错误**：
  - 第一类错误（α，弃真）：错误拒绝真实 H_0
  - 第二类错误（β，取伪）：错误接受虚假 H_0
  - 在固定样本量下 α 和 β 互斥，增大样本量可同时减小
- **Z 检验**：$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$（或 $s/\sqrt{n}$ 大样本近似）
- **常见临界值**：双侧 α=0.05 → Z=1.96，α=0.01 → Z=2.58；单侧 α=0.05 → Z=1.645
- **考试重点**：两类错误的含义和关系、Z 检验的计算

3.4 抽样方法

- **非概率抽样**：随意抽样、判断抽样、志愿抽样、滚雪球抽样（有主观偏差，无法推断总体）
- **等概率抽样**：
  - 简单随机抽样（SRS）：每个个体概率相等
  - 系统抽样：固定间隔 $k = N/n$
  - 分层抽样：层内差异小、层间差异大 → 按比例在每层内随机抽样
  - 整群抽样：随机抽群，调查群内全部个体（操作简单但群间差异大时误差大）
- **不等概率抽样**：入样概率与规模/重要性成正比
- **易混淆点**：分层抽样 vs 整群抽样 — 分层是层内全抽，整群是抽群后群内全查
- **考试重点**：四种等概率抽样方法的区分和适用场景

第四章：数据挖掘

4.1 数据挖掘基础

- **定义**：从大量数据中挖掘令人感兴趣的、有用的、隐含的、先前未知的模式或知识
- **四大任务**：

任务	类型	说明	示例
聚类	无监督	组内相似、组间相异	铁路票价制定
关联分析	无监督	发现项之间的关联	啤酒与尿布
分类与预测	监督	学习特征到标签的映射	垃圾邮件分类
异常检测	可监督/无监督	检测与大多数数据不同的样本	盗电检测

4.2 关联规则挖掘

4.2.1 基本概念

- **支持度**：$\text{Support}(X \to Y) = P(X \cup Y) = \frac{\text{含 } X,Y \text{ 的事务数}}{\text{总事务数}}$
- **置信度**：$\text{Confidence}(X \to Y) = P(Y|X) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)}$
- **频繁项集**：支持度 ≥ minsup 的项集
- **强关联规则**：置信度 ≥ minconf 的规则
- **挖掘两步策略**：① 频繁项集生成（只看支持度）→ ② 规则产生（只看置信度）

4.2.2 Apriori 算法

- **Apriori 性质（反单调性）**：频繁项集的所有非空子集必频繁；非频繁项集的所有超集必非频繁
- **流程**：连接步（$L_{k-1} \bowtie L_{k-1}$）→ 剪枝步（删除 (k-1) 子集不在 L_{k-1} 中的候选项）→ 扫描计数 → 迭代
- **优缺点**：优点（适用于稀疏数据、高频模式）；缺点（候选集爆炸、多次扫描数据库）
- **改进算法**：DHP、Partition、Sample、DIC、FP-Growth

4.2.3 FP-Growth 算法

- **核心**：构建 FP-Tree（频繁模式树）压缩数据库，不生成候选集
- **步骤**：
  1. 第一次扫描：统计单项支持度，排序
  2. 第二次扫描：构建 FP-Tree（共享前缀路径）
  3. 递归挖掘：从底向上，提取条件模式基 → 构建条件 FP 树 → 递归生成频繁项集
- **对比 Apriori**：不生成候选集、仅需 2 次扫描、适合稠密数据和长模式
- **考试重点**：FP-Tree 的构建过程、条件模式基的提取

4.2.4 关联规则评价

- **Lift（提升度）**：$\text{Lift} = \frac{P(X,Y)}{P(X)P(Y)}$
  - > 1 正相关，=1 独立，<1 负相关

- **φ 系数**：$\phi = \frac{P(X,Y)-P(X)P(Y)}{\sqrt{P(X)(1-P(X))P(Y)(1-P(Y))}}$
- **辛普森悖论**：总体趋势在分组后逆转，本质是混杂变量 + 不等样本量
  - 解决方法：合理分层、多变量回归、标准化
- **相关 ≠ 因果**：警惕隐藏变量 / 混杂变量

4.3 分类与预测

4.3.1 决策树

- **三大分裂指标**：

指标	公式	所属算法
信息增益	$Gain(D,A) = H(D) - \sum \frac{	D_j
增益率	$\frac{Gain(D,A)}{SplitInfo(D,A)}$	C4.5
基尼指数	$Gini(D) = 1 - \sum p_i^2$	CART

- **C4.5 启发式策略**：先筛选信息增益高于平均的特征，再从中选增益率最大者
- **连续属性**：排序后取相邻中点作为候选分裂点
- **剪枝**：预剪枝（提前停止）、后剪枝（建完整树后自底向上剪）
- **优缺点**：可解释性强、无需特征缩放、可处理混合类型；但容易过拟合、贪心搜索非全局最优

4.3.2 贝叶斯分类器

- **朴素贝叶斯核心假设**：给定类别下，各属性相互独立
- **分类决策**：$\hat{C} = \arg\max_C P(C) \prod P(A_i|C)$
- **拉普拉斯平滑**：$P(A_i = a|C = c) = \frac{\text{count}(A_i=a, C=c)+1}{\text{count}(C=c)+|\text{values}(A_i)|}$
- **连续属性**：假设正态分布 $P(A_i|C) = \frac{1}{\sqrt{2\pi}\sigma_{ic}} \exp\left(-\frac{(a-\mu_{ic})^2}{2\sigma_{ic}^2}\right)$

4.3.3 K 近邻（KNN）

- **核心**：基于实例学习，无需显式训练，相似样本属于同一类别
- **K 值影响**：太小 → 对噪声敏感（过拟合），太大 → 决策边界过平滑
- **优缺点**：简单直观、无需训练；但预测慢、对特征缩放敏感、需存储全部数据

4.3.4 感知机与 SVM

- **感知机**：$f(\mathbf{x}) = \text{sign}(\mathbf{w}^T\mathbf{x} + b)$，只能解决线性可分问题
- **SVM 核心**：最大化分类间隔，引入核函数处理非线性性
- **常用核函数**：线性核、多项式核、高斯核（RBF）、Sigmoid 核
- **软间隔**：引入松弛变量 ξᵢ 和惩罚参数 C，允许部分误分类

4.3.5 集成学习

方法	基学习器关系	并行/串行	主要作用	代表算法
Bagging	独立	并行	降低方差	随机森林

方法	基学习器关系	并行/串行	主要作用	代表算法
Boosting	依赖	串行	降低偏差	AdaBoost, GBDT, XGBoost

- **AdaBoost 权重更新**：$\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$

4.3.6 模型评估

- **混淆矩阵**：TP（真正）、FP（假正）、FN（假负）、TN（真负）
- **Accuracy** = $\frac{TP+TN}{Total}$
- **Precision** = $\frac{TP}{TP+FP}$
- **Recall** = $\frac{TP}{TP+FN}$
- **F1** = $2 \times \frac{P \times R}{P+R} = \frac{2TP}{2TP+FP+FN}$
- **ROC/AUC**：ROC 横轴 FPR（$\frac{FP}{TN+FP}$），纵轴 TPR（$\frac{TP}{TP+FN}$）；AUC 越大越好（1 完美，0.5 随机）
- **验证方法**：留出法、K 折交叉验证、留一法、自助法

4.4 时间序列预测

- **四成分**：趋势（Trend）、季节性（Seasonality，固定周期）、周期性（Cyclicality，不固定周期）、随机性（Irregularity）
- **ARIMA(p,d,q)**：
  - p：自回归阶数，q：移动平均阶数，d：差分阶数
  - 要求序列平稳 → ADF 检验（p < 0.05 平稳）
  - 确定 p,q：ACF 截尾定 q，PACF 截尾定 p
  - 预测公式（d=1 时）：$\hat{y}_{t+1} = y_t + \phi_1(y_t - y_{t-1}) + \theta_1\varepsilon_t$
- **ETS**：误差 × 趋势 × 季节性，每个成分可为加性（A）或乘性（M）
- **评价指标**：MSE、MAE、RMSE、MAPE、CRPS

4.5 聚类分析

方法	核心思想	优点	缺点
K-means	最小化 SSE，迭代更新中心	快速、适合球状簇	需预设 K、对初始值和噪声敏感
层次聚类	凝聚/分裂，生成树状图	无需预设 K	计算量大
DBSCAN	基于密度，核心点/边界点/噪声点	任意形状、对噪声鲁棒	对 ε 和 MinPts 敏感

- **簇间距离**（层次聚类）：单链（MIN）、全链（MAX）、组平均、中心距离
- **评估**：内部指标（SSE、轮廓系数）、外部指标（熵、纯度）

4.6 异常检测

- **常用方法**：
  - 基于统计：箱图（IQR）、z-score
  - 基于距离：KNN 距离
  - 基于密度：DBSCAN、LOF（局部异常因子）
  - 基于聚类：不属于任何簇的点
  - 基于模型：孤立森林、自编码器

- **应用**：信用卡欺诈、网络入侵、设备故障预警

第二部分：题型复习

2.1 选择型

> **知识点特征**：概念定义、分类归属、优缺点判断、公式选择、性质辨析。以下例题覆盖各章核心选择型考点。

例题 1（第一章 · 4V 概念）

大数据"4V"特征中，**Variety** 指的是？

A. 数据量大，通常达 PB 级别
B. 数据产生和处理速度快
C. 数据种类多样，包含结构化、半结构化和非结构化数据
D. 数据蕴含潜在商业或科研价值

> **答案**：C。Variety 指数据种类多样。

例题 2（第一章 · 合成数据）

以下哪项**不是**合成数据（Synthetic Data）的优势？

A. 降低数据获取成本
B. 完全避免模型退化问题
C. 无隐私安全问题
D. 可减少真实世界的偏见

> **答案**：B。合成数据存在模型退化（自噬循环、分布崩塌）的风险。

例题 3（第二章 · 缺失机制）

某调查中，高收入人群因其收入过高而拒绝填写工资，导致工资字段缺失。这种缺失属于？

A. MCAR（完全随机缺失）
B. MAR（随机缺失）
C. MNAR（非随机缺失）
D. 以上都不是

> **答案**：C。缺失原因与缺失值本身（高收入）有关，属于非随机缺失。

例题 4（第二章 · 数据存储）

以下哪种 NoSQL 数据库利用"免索引邻接"实现在图数据上的 O(1) 遍历性能？

A. MongoDB
B. Redis

C. HBase
D. Neo4j

> **答案**：D。Neo4j 的免索引邻接技术使图遍历为 O(1)。

例题 5（第二章 · 数据预处理）

计算两个二值向量 $\mathbf{p} = (1,0,0,0,0,0,0,0,0,0)$ 和 $\mathbf{q} = (0,0,0,0,0,0,1,0,0,1)$ 的 Jaccard 系数，结果是？

A. 0.7
B. 0.3
C. 0
D. 1

> **答案**：C。$F_{11} = 0, F_{01} = 2, F_{10} = 1$，Jaccard = $0/(2+1+0) = 0$。

例题 6（第三章 · 集中趋势）

某理财产品三年收益率分别为 10%、-5%、15%，则三年平均年化收益率最适合使用以下哪种指标？

A. 算术平均数
B. 中位数
C. 几何平均数
D. 众数

> **答案**：C。收益率/比率数据应用几何平均数。

例题 7（第三章 · 假设检验）

在假设检验中，若原假设 H_0 实际为真，但检验结果拒绝了 H_0，则犯的错误是？

A. 第一类错误（α）
B. 第二类错误（β）
C. 弃伪错误
D. 取真错误

> **答案**：A。H_0 为真却拒绝 → 弃真 → 第一类错误。

例题 8（第四章 · 关联规则）

Apriori 算法中，若 {A, B} 不是频繁项集，则以下哪个项集**一定**也不是频繁项集？

A. {A}
B. {B}
C. {A, B, C}
D. {A, C}

> **答案**：C。非频繁项集的超集必不频繁（反单调性）。

例题 9（第四章 · 集成学习）

关于 Bagging 和 Boosting，以下说法**正确**的是?

A. Bagging 的基学习器是串行生成的
B. Boosting 主要用于降低方差
C. 随机森林属于 Bagging 方法
D. Boosting 的各基学习器之间相互独立

> **答案**：C。随机森林是 Bagging 的代表算法。Bagging 并行、降低方差；Boosting 串行、降低偏差。

例题 10（第四章 · 聚类）

DBSCAN 聚类算法中，若一个点既不是核心点，也不落在任何核心点的 ε-邻域内，则该点被称为?

A. 边界点
B. 噪声点
C. 中心点
D. 支持向量

> **答案**：B。噪声点既非核心点也非边界点。

2.2 简答型

> **知识点特征**：流程描述、对比分析、原理解释、方法列举。答题时应分条列点，3-5 条核心要点即可。

例题 1（第二章 · 数据采集）

简述 GET 请求和 POST 请求的主要区别。

> **参考答案**： ① GET 将参数放在 URL 中，POST 将参数放在请求体（Form Data）中； ② GET 安全性较低（参数暴露在 URL 中），POST 更安全； ③ GET 的 URL 长度受限，POST 可传输更多数据； ④ 应用场景：GET 常用于查询，POST 常用于登录和提交数据。

例题 2（第二章 · 数据存储）

简述关系型数据库（RDBMS）与 NoSQL 数据库的主要区别。

> **参考答案**： ① 数据模型：RDBMS 采用严格的二维表结构，需满足范式约束；NoSQL 无预定义模式，支持文档/键值/列族/图等多种模型； ② 查询语言：RDBMS 使用标准 SQL；NoSQL 通常无声明性查询语言； ③ 一致性：RDBMS 保证 ACID（强一致性）；NoSQL 多为最终一致性，遵循 CAP 定理； ④ 扩展性：RDBMS 多为垂直扩展；NoSQL 多为水平扩展（分布式）。

例题 3（第四章 · 分类）

简述决策树过拟合的两个主要原因及对应的解决方案。

> **参考答案**： ① **噪声影响**：训练数据中的噪声被决策树学习，导致模型复杂度超过真实规律。解决：预剪枝（设置最小样本数、最大深度）或后剪枝（建完整树后自底向上剪枝）； ② **多重比较过程**：决策树在众多分裂选项中反复选择，可能偶然产生看似好的分裂。解决：使用增益率（C4.5）代替信息增益（ID3）来惩罚取值过多的特征，或使用交叉验证选择最佳树深度。

例题 4（第四章 · 关联规则）

简述辛普森悖论（Simpson's Paradox）的本质及避免方法。

> **参考答案**：① **本质**：总体数据中呈现的趋势在分组后发生逆转，数学上源于加权平均与条件概率的方向不一致；② **原因**：存在混杂变量（同时影响自变量和因变量），以及各组样本量差异悬殊；③ **避免方法**：合理分层分析、使用多变量回归控制混杂变量、计算标准化率、可视化分组数据。

例题 5（第三章 · 参数估计）

简述 MLE（极大似然估计）和 MAP（最大后验估计）的区别与联系。

> **参考答案**：① **MLE**：最大化似然函数 $p(X|\theta)$，只依赖数据，无先验信息；② **MAP**：最大化后验概率 $p(\theta|X) \propto p(X|\theta)p(\theta)$，引入了参数 θ 的先验分布 $p(\theta)$；③ **联系**：MAP = MLE + 先验正则化。当先验为均匀分布时 MAP 退化为 MLE；④ **样本量影响**：样本量增大时，MLE 和 MAP 的结果趋于一致（先验影响减弱）。

2.3 计算型

> **知识点特征**：公式代入、多步推导、数值计算。应写出完整步骤。

例题 1（第二章 · 数据变换）

某课程考试成绩范围为 [45, 95]，请分别使用以下方法将成绩 72 规范化：(1) 最小-最大规范化，映射到 [0, 1] (2) z-score 规范化（假设全班均值 μ = 70，标准差 σ = 12）

> **参考答案**：(1) $v' = \frac{72-45}{95-45} = \frac{27}{50} = 0.54$ (2) $v' = \frac{72-70}{12} = \frac{2}{12} \approx 0.167$

例题 2（第二章 · 距离度量）

已知两个向量 $\mathbf{A} = (2, 5, 1, 0)$ 和 $\mathbf{B} = (5, 2, 3, 4)$，计算：(1) 欧几里得距离 (2) 曼哈顿距离

> **参考答案**：(1) $d_{Euc} = \sqrt{(2-5)^2 + (5-2)^2 + (1-3)^2 + (0-4)^2} = \sqrt{9+9+4+16} = \sqrt{38} \approx 6.16$ (2) $d_{Man} = |2-5| + |5-2| + |1-3| + |0-4| = 3+3+2+4 = 12$

例题 3（第二章 · 信息熵）

某节点有 12 个样本，分为 3 类：C1 = 4 个，C2 = 6 个，C3 = 2 个。计算该节点的信息熵。

> **参考答案**：$p_1 = 4/12 = 1/3$，$p_2 = 6/12 = 1/2$，$p_3 = 2/12 = 1/6$
>
> $H = -[\frac{1}{3}\log_2\frac{1}{3} + \frac{1}{2}\log_2\frac{1}{2} + \frac{1}{6}\log_2\frac{1}{6}]$
>
> $= -[\frac{1}{3} \times (-1.585) + \frac{1}{2} \times (-1) + \frac{1}{6} \times (-2.585)]$
>
> $= -[-0.528 - 0.5 - 0.431] = 1.459$

例题 4（第三章 · MLE）

从某正态总体 $N(\mu, 1)$ 中抽取 5 个独立样本：$[2.3, 1.8, 2.6, 2.1, 1.7]$。求 μ 的极大似然估计值。

> **参考答案**：对正态分布 $N(\mu, 1)$，MLE 的 $\hat{\mu} = \frac{1}{n}\sum x_i$
>
> $\hat{\mu} = \frac{2.3+1.8+2.6+2.1+1.7}{5} = \frac{10.5}{5} = 2.1$

例题 5（第四章 · 关联规则）

某超市 1000 笔交易中：购买牛奶的有 400 笔，购买面包的有 350 笔，同时购买两者的有 200 笔。计算规则"牛奶 → 面包"的： (1) 支持度 (2) 置信度 (3) 提升度（Lift），并判断两者的关系

> **参考答案**： (1) $\text{Support} = \frac{200}{1000} = 0.2$（20%） (2) $\text{Confidence} = \frac{0.2}{0.4} = 0.5$（50%） (3) $\text{Lift} = \frac{0.2}{0.4 \times 0.35} = \frac{0.2}{0.14} \approx 1.43$
>
> Lift > 1，说明购买牛奶对购买面包有正向促进作用。

例题 6（第四章 · 分类评估）

某二分类模型对 500 个测试样本的预测结果如下：TP=120，FN=30，FP=50，TN=300。计算： (1) Accuracy (2) Precision (3) Recall (4) F1 分数

> **参考答案**： (1) $\text{Accuracy} = \frac{120+300}{500} = \frac{420}{500} = 0.84$ (2) $\text{Precision} = \frac{120}{120+50} = \frac{120}{170} \approx 0.706$ (3) $\text{Recall} = \frac{120}{120+30} = \frac{120}{150} = 0.8$ (4) $\text{F1} = 2 \times \frac{0.706 \times 0.8}{0.706+0.8} = \frac{2 \times 0.565}{1.506} \approx 0.75$

例题 7（第四章 · 时间序列）

已知某时间序列满足 ARIMA(1,1,0)，$\phi_1 = 0.5$，最近数据为：$y_4 = 30$, $y_5 = 34$, $y_6 = 31$。预测 y_7。

> **参考答案**： $\hat{y}_7 = y_6 + \phi_1(y_6 - y_5) = 31 + 0.5 \times (31 - 34) = 31 - 1.5 = 29.5$

第三部分：模拟真题

> **考试时间**：120 分钟 | **满分**：100 分

一、选择题（共 15 题，每题 2 分，共 30 分）

1. 以下哪个**不是**大数据的 4V 特征之一？

A. Volume
B. Veracity
C. Velocity
D. Variety

---

2. 下列关于合成数据的说法，**错误**的是？

A. 合成数据基于计算机模拟或算法生成
B. 合成数据与数据增强是完全相同的概念
C. 合成数据可降低数据获取成本
D. 合成数据存在"自噬循环"导致的模型退化风险

---

3. 在爬虫开发中，使用 Selenium/WebDriver 的主要目的是？

A. 提高爬取速度
B. 处理动态页面（JavaScript 渲染）
C. 破解验证码
D. 优化数据存储格式

---

4. 在 MongoDB 中，与关系型数据库中"表"概念对应的是？

A. Database
B. Collection
C. Document
D. Field

---

5. 下列哪种缺失值处理方法利用了"找到与缺失样本最相似的对象，并用其值填充"的思想？

A. 均值填充
B. KNN 填充
C. 热卡填充（Hot-deck）
D. EM 算法

---

6. 已知两个分类变量的列联表，要检验它们是否独立，最适合使用？

A. Pearson 相关系数
B. Spearman 秩相关系数
C. 卡方检验
D. 余弦相似度

---

7. 一组数据的均值为 50，中位数为 45，则该数据的分布最可能是？

A. 对称分布
B. 左偏分布
C. 右偏分布
D. 均匀分布

---

8. 关于假设检验的两类错误，以下说法**正确**的是？

A. 在样本量固定时，α 和 β 可以同时减小
B. 第一类错误是指 H_0 为假但接受了 H_0
C. 增大样本量可以同时减小 α 和 β
D. α + β = 1

---

9. 关联规则挖掘中，规则 $X \to Y$ 的置信度计算公式为？

A. $P(X \cup Y)$
B. $\frac{P(X \cup Y)}{P(X)}$

C. $\frac{P(X\cup Y)}{P(Y)}$
D. $\frac{P(X)}{P(X\cup Y)}$

---

10. FP-Growth 算法相对于 Apriori 算法的主要优势是？

A. 只需要一次扫描数据库
B. 不生成候选集，避免组合爆炸
C. 内存占用更小
D. 更适合稀疏数据

---

11. 决策树算法中，C4.5 使用什么指标来选择分裂特征？

A. 信息增益
B. 基尼指数
C. 增益率
D. 分类错误率

---

12. 关于 KNN 算法，下列说法**错误**的是？

A. KNN 是基于实例的学习，无需显式训练
B. K 值过小容易受噪声影响而过拟合
C. KNN 预测时计算量较小
D. KNN 对特征缩放敏感

---

13. 在集成学习中，随机森林（Random Forest）属于什么方法？

A. Boosting
B. Bagging
C. Stacking
D. 以上都不是

---

14. 关于 DBSCAN 算法，以下说法**正确**的是？

A. DBSCAN 需要事先指定簇的数量 K
B. DBSCAN 对噪声点敏感
C. DBSCAN 可以发现任意形状的簇
D. DBSCAN 只适用于球状簇

---

15. 在二分类问题中，ROC 曲线的纵轴是？

A. FPR（假正率）
B. TPR（真正率，即召回率）
C. Precision（精确率）
D. Accuracy（准确率）

二、简答题（共 5 题，每题 6 分，共 30 分）

1.（第二章 · 数据采集）
简述网络爬虫中常见的三种反爬虫策略及各自对应的应对方法。

2.（第二章 · 特征工程）
简述 Filter、Wrapper、Embedded 三种特征选择策略的区别，并各举一种代表性方法。

3.（第三章 · 抽样方法）
简述分层抽样与整群抽样的区别，并说明各自的适用场景。

4.（第四章 · 分类）
简述 SVM（支持向量机）中"核函数"（Kernel Trick）的作用，并列举两种常用核函数及其表达式。

5.（第四章 · 聚类）
简述 K-means 聚类算法的基本步骤，并指出该算法的两个主要缺点及其对应的改进思路。

三、计算题（共 6 题，共 40 分）

1.（6 分 · 第二章 · 数据集成）

已知两变量 $X = [3, 7, 11]$，$Y = [9, 21, 33]$，计算 X 与 Y 的 Pearson 相关系数。

2.（6 分 · 第二章 · 信息增益）

某数据集 D 含 20 个样本，二分类：正类 12 个，负类 8 个。现按特征 A 将 D 分为两个子集：

- D_1：12 个样本（正类 9，负类 3）
- D_2：8 个样本（正类 3，负类 5）

计算特征 A 的信息增益（Information Gain）。（计算过程中熵值精确到小数点后三位）

3.（6 分 · 第四章 · 关联规则）

某事务数据库共 5 个事务，minsup = 2（以计数计）：

TID	事务
1	{A, B, C}
2	{A, C}
3	{A, B}
4	{B, C}
5	{A, B, C}

(1) 列出所有频繁 1 项集和频繁 2 项集（含支持度计数）。
(2) 假设 minconf = 60%，规则 $A \to B$ 是否满足置信度要求？请计算并说明。

4.（7 分 · 第三章 · 参数估计）

抛一枚硬币 12 次，观察到 9 次正面、3 次反面。设正面概率为 θ。

(1) 求 θ 的极大似然估计（MLE）。
(2) 假设先验分布为 $\mathrm{Beta}(3,3)$，求 θ 的最大后验估计（MAP）。（提示：Beta 分布的众数为 $\frac{\alpha-1}{\alpha+\beta-2}$）
(3) 简述 MAP 估计值相对于 MLE 估计值的变化方向及其原因。

5.（7 分 · 第四章 · 决策树）

某节点包含 16 个样本，二分类（正类 10 个，负类 6 个）。现考虑按特征 B 划分：

- B=1：8 个样本（正类 7，负类 1）
- B=0：8 个样本（正类 3，负类 5）

(1) 计算划分前的基尼指数 $\mathrm{Gini}(D)$。
(2) 计算按特征 B 划分后的加权基尼指数 $\mathrm{Gini}_{\mathrm{split}}(D, B)$。
(3) 计算基尼增益 $\Delta\mathrm{Gini}$。

6.（8 分 · 第四章 · 朴素贝叶斯）

下表为天气数据集，目标是预测是否适合户外运动（Play）：

天气(Outlook)	温度(Temp)	湿度(Humidity)	是否运动(Play)
Sunny	Hot	High	No
Sunny	Hot	High	No
Overcast	Hot	High	Yes
Rain	Mild	High	Yes
Rain	Cool	Normal	Yes
Rain	Cool	Normal	No
Overcast	Cool	Normal	Yes
Sunny	Mild	High	No
Sunny	Cool	Normal	Yes
Rain	Mild	Normal	Yes

现有一个新样本：{Outlook=Sunny, Temp=Cool, Humidity=Normal}，请使用朴素贝叶斯分类器预测其类别（使用拉普拉斯平滑，$\alpha = 1$）。

参考答案与评分标准

一、选择题答案与解析

第 1 题

> 以下哪个**不是**大数据的 4V 特征之一？

答案：B（Veracity）

解析：大数据的经典 4V 特征为 **Volume**（数据量大）、**Velocity**（高实时性）、**Variety**（种类多样）和 **Value**（价值巨大）。Veracity（真实性/准确性）是后来部分学者补充的"第 5V"，不属于经典 4V。注意题目问的是"不是"，易因思维惯性选错。

对应知识点：第一章 1.1 大数据的特点（4V）

第 2 题

> 下列关于合成数据的说法，**错误**的是？

答案：B（合成数据与数据增强是完全相同的概念）

解析：合成数据与数据增强是两个不同概念——合成数据是"无中生有"（从零生成人造数据），数据增强是"有中生更多"（对已有标注数据做变换生成新样本）。A、C、D 均为合成数据的正确描述：它基于算法生成、可降低成本、但存在自噬循环（模型反复在自身生成的数据上训练导致分布崩塌）。

对应知识点：第一章 1.3 合成数据；第二章 2.1.2 合成数据与数据增强

第 3 题

> 在爬虫开发中，使用 Selenium/WebDriver 的主要目的是？

答案：B（处理动态页面/JavaScript 渲染）

解析：Selenium/WebDriver 是一个浏览器自动化工具，核心用途是模拟真实浏览器行为来加载和渲染 JavaScript 动态生成的页面内容。A 错误——Selenium 启动真实浏览器，速度反而更慢；C 错误——破解验证码通常用 OCR 或打码平台，不是 Selenium 的主要用途；D 错误——数据存储格式由开发者自行处理，与 Selenium 无关。

对应知识点：第二章 2.1.4 网络爬虫 · 动态页面处理

第 4 题

> 在 MongoDB 中，与关系型数据库中"表"概念对应的是？

答案：B（Collection）

解析：MongoDB 的层级结构为：Database（数据库）→ **Collection（集合，对应 RDBMS 的表）** → Document（文档，对应 RDBMS 的行/元组）→ Field（字段，对应 RDBMS 的列/属性）。A（Database）对应整个数据库实例，层级过高；C（Document）对应行而非表；D（Field）对应列而非表。

对应知识点：第二章 2.2.3 NoSQL · MongoDB 详解

第 5 题

> 下列哪种缺失值处理方法利用了"找到与缺失样本最相似的对象，并用其值填充"的思想？

答案：C（热卡填充 Hot-deck）

解析：热卡填充（Hot-deck Imputation）的核心思想是在数据集中找到与缺失样本在其他属性上最相似的一个完整样本，直接用该样本的值填充缺失值。A（均值填充）使用全局统计量而非个体相似性。B（KNN 填充）虽然也基于相似性，但它使用 K 个最近邻的加权平均，而非"找到最相似的一个对象并用其值直接填充"——这是热卡与 KNN 的关键区别。D（EM 算法）通过期望最大化进行概率模型估计，不基于相似性匹配。

对应知识点：第二章 2.3.1 数据清理 · 缺失值处理方法

第 6 题

> 已知两个分类变量的列联表，要检验它们是否独立，最适合使用？

答案：C（卡方检验）

解析：卡方检验（χ^2 Test）专用于判断两个**分类（离散）变量**之间是否独立，通过比较观测频数 O_{ij} 与期望频数 E_{ij} 的差异来检验。A（Pearson 相关系数）适用于两个连续变量的线性相关性检验。B（Spearman 秩相关系数）适用于有序数据或等级数据的相关性。D（余弦相似度）适用于向量空间中的方向相似度度量。题干关键词"分类变量"和"列联表"直接指向卡方检验。

对应知识点：第二章 2.3.3 数据集成 · 卡方检验

第 7 题

> 一组数据的均值为 50，中位数为 45，则该数据的分布最可能是？

答案：C（右偏分布）

解析：在右偏（正偏）分布中，由于右侧存在长尾，少数极端大值会拉动均值向右偏移，而中位数不受极端值影响，因此表现为 **均值 > 中位数**。本题均值 50 > 中位数 45，符合右偏特征。A（对称分布）：均值 ≈ 中位数。B（左偏分布）：均值 < 中位数。D（均匀分布）：均值 ≈ 中位数。

对应知识点：第三章 3.1.3 分布形态 · 偏度；第三章 3.1.1 集中趋势

第 8 题

> 关于假设检验的两类错误，以下说法**正确**的是？

答案：C（增大样本量可以同时减小 α 和 β）

解析：增大样本量可以提高检验的功效，使抽样分布更加集中，从而同时降低两类错误的概率。A 错误——在样本量固定时，α 减小会导致 β 增大（二者互斥），不能同时减小。B 错误——第一类错误（α）是指 H_0 为真时拒绝 H_0（弃真），而"H_0 为假但接受 H_0"是第二类错误（β，取伪）。D 错误——α + β 不等于 1，两者之间没有固定的数量关系。

对应知识点：第三章 3.3 假设检验 · 两类错误

第 9 题

> 关联规则挖掘中，规则 $X \rightarrow Y$ 的置信度计算公式为?

答案：B（$\frac{P(X \cup Y)}{P(X)}$）

解析：置信度的定义是"在 X 出现的条件下 Y 也出现的概率"，即条件概率 $P(Y|X) = \frac{P(X \cup Y)}{P(X)} = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)}$。A 是支持度 Support 的公式。C 是 $X \rightarrow Y$ 和 $Y \rightarrow X$ 颠倒后的结果。D 是倒数关系，无实际意义。

对应知识点：第四章 4.2.1 关联规则 · 基本概念

第 10 题

> FP-Growth 算法相对于 Apriori 算法的主要优势是?

答案：B（不生成候选集，避免组合爆炸）

解析：FP-Growth 通过构建 FP-Tree 压缩数据库，采用分治策略直接挖掘频繁项集，完全避免候选集生成步骤——这正是对 Apriori 候选集爆炸问题的最核心改进。A 错误——FP-Growth 需要扫描数据库**两遍**而非一遍。C 错误——FP-Growth 需在内存中构建 FP-Tree 和条件树，内存占用通常比 Apriori 更大。D 错误——FP-Growth 更适合**稠密数据和长模式**，Apriori 更适合稀疏数据和短模式。

对应知识点：第四章 4.2.3 FP-Growth；Apriori vs FP-Growth 对比表

第 11 题

> 决策树算法中，C4.5 使用什么指标来选择分裂特征?

答案：C（增益率）

解析：三种经典决策树算法的分裂指标：**ID3** 使用信息增益（Information Gain），**C4.5** 使用增益率（Gain Ratio = 信息增益 / 分裂信息），**CART** 使用基尼指数（Gini Index）。C4.5 引入增益率是为了解决 ID3 中信息增益偏好取值较多特征的问题。

对应知识点：第四章 4.3.1 决策树 · 常用算法对比表

第 12 题

> 关于 KNN 算法，下列说法**错误**的是?

答案：C（KNN 预测时计算量较小）

解析：KNN 是懒惰学习（Lazy Learning），训练阶段几乎不花时间，但预测时需要计算测试样本与**所有训练样本**的距离——当训练集很大时，预测计算量非常大。A、B、D 均为正确描述：KNN 无需显式训练、K 值过小易过拟合、不同特征的量纲会严重影响距离计算结果因此需提前标准化。

对应知识点：第四章 4.3.3 K 近邻（KNN）· 特点对比表

第 13 题

> 在集成学习中，随机森林（Random Forest）属于什么方法？

答案：B（Bagging）

解析：随机森林是 Bagging（Bootstrap Aggregating）的代表性算法——对训练集做有放回抽样（Bootstrap），在每个采样子集上独立训练一棵决策树，同时在每个节点分裂时随机选择特征子集，最后通过投票（分类）或平均（回归）汇总结果。A（Boosting）的代表算法是 AdaBoost、GBDT、XGBoost，基学习器串行生成，重在降低偏差。C（Stacking）是使用元学习器组合多个不同模型的方法。

对应知识点：第四章 4.3.5 集成学习 · Bagging vs Boosting 对比表

第 14 题

> 关于 DBSCAN 算法，以下说法**正确**的是？

答案：C（DBSCAN 可以发现任意形状的簇）

解析：DBSCAN 基于密度连通性定义簇，不假设簇的形状为球形，因此可以发现任意形状的簇。A 错误——DBSCAN 无需预设 K 值（这正是它相对于 K-means 的优势），但需指定 ε（邻域半径）和 MinPts（最小点数）。B 错误——DBSCAN 对噪声鲁棒，它能主动识别并排除噪声点，而非对噪声敏感。D 错误——只能发现球状簇的是 K-means，而非 DBSCAN。

对应知识点：第四章 4.5 聚类分析 · DBSCAN 特点对比表

第 15 题

> 在二分类问题中，ROC 曲线的纵轴是？

答案：B（TPR，真正率，即召回率）

解析：ROC 曲线的横轴为 FPR（假正率 = $\frac{FP}{TN+FP}$），纵轴为 **TPR**（真正率 = $\frac{TP}{TP+FN}$ = Recall）。TPR 越高说明正样本被正确识别的比例越高。A（FPR）是横轴而非纵轴。C（Precision = $\frac{TP}{TP+FP}$）是 PR 曲线的纵轴而非 ROC 曲线。D（Accuracy）不出现在 ROC 曲线中。

对应知识点：第四章 4.3.6 模型评估 · ROC/AUC

二、简答题评分标准

第 1 题（每种策略 + 应对 2 分，共 6 分）：

- 验证码 → OCR 识别或人工打码平台（2 分）

- 账号/IP 封禁 → 多 Cookie（识别用户）、多 IP 代理（2 分）
- 返回假数据 → 数据校验、多源比对（2 分）
- （答"减少访问频率、设置爬取间隔"也可给分）

第 2 题（每个策略 2 分，共 6 分）：

- Filter：独立于学习模型，基于数据统计特性（信息增益、卡方检验、相关系数）（2 分）
- Wrapper：以目标分类器性能为评价标准（如准确率），搜索最优子集，计算量大（2 分）
- Embedded：特征选择嵌入模型训练过程（L1 正则化、决策树特征重要性）（2 分）

第 3 题（区别 4 分 + 场景 2 分，共 6 分）：

- 分层抽样：先按特征分层（层内差异小，层间差异大），再在每层内随机抽样（2 分）
- 整群抽样：将总体分为若干群，随机抽取部分群，对抽中群的全部个体调查（2 分）
- 适用：分层抽样适用于层间差异大且需要保证各层代表性的情况；整群抽样适用于群内差异大、群间差异小，且操作简便性优先的场景（2 分）

第 4 题（作用 2 分 + 两种核各 2 分，共 6 分）：

- 作用：将原始低维数据映射到高维特征空间，使线性不可分的数据在高维空间中变得线性可分，且通过核技巧避免了显式计算高维映射（2 分）
- 高斯核（RBF）：$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$（2 分）
- 多项式核：$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$（2 分）
- （线性核、Sigmoid 核也给分）

第 5 题（步骤 2 分 + 缺点及改进各 2 分，共 6 分）：

- 步骤：① 随机选择 K 个初始中心点；② 将每个样本分配到最近的中心；③ 重新计算每个簇的均值作为新中心；④ 重复 ②③ 直到收敛（2 分）
- 缺点 1：需预设 K → 改进：肘部法则、轮廓系数（2 分）
- 缺点 2：对初始中心敏感 → 改进：多次初始化选最优、K-means++（2 分）
- （答"对噪声和异常值敏感"也可给分，改进思路：二分 K-means）

三、计算题答案与评分标准

第 1 题（6 分 · Pearson 相关系数）

解：

- $\bar{X} = \frac{3+7+11}{3} = 7$，$\bar{Y} = \frac{9+21+33}{3} = 21$（1 分）
- 分子：$(3-7)(9-21) + (7-7)(21-21) + (11-7)(33-21) = (-4) \times (-12) + 0 + 4 \times 12 = 48 + 0 + 48 = 96$（2 分）
- $\sum (X_i - \bar{X})^2 = 16 + 0 + 16 = 32$（1 分）
- $\sum (Y_i - \bar{Y})^2 = 144 + 0 + 144 = 288$（1 分）
- $r = \frac{96}{\sqrt{32 \times 288}} = \frac{96}{\sqrt{9216}} = \frac{96}{96} = 1$（1 分）

结果：$r = 1$，两变量完全正线性相关。

第 2 题（6 分 · 信息增益）

解：

- 划分前：$H(D) = -[\frac{12}{20}\log_2\frac{12}{20} + \frac{8}{20}\log_2\frac{8}{20}] = -[0.6\times(-0.737) + 0.4\times(-1.322)] = -[-0.442 - 0.529] = 0.971$（2 分）
- D_1 熵：$H(D_1) = -[\frac{9}{12}\log_2\frac{9}{12} + \frac{3}{12}\log_2\frac{3}{12}] = -[0.75\times(-0.415) + 0.25\times(-2)] = -[-0.311 - 0.5] = 0.811$（1 分）
- D_2 熵：$H(D_2) = -[\frac{3}{8}\log_2\frac{3}{8} + \frac{5}{8}\log_2\frac{5}{8}] = -[0.375\times(-1.415) + 0.625\times(-0.678)] = -[-0.531 - 0.424] = 0.955$（1 分）
- 条件熵：$H(D|A) = \frac{12}{20}\times 0.811 + \frac{8}{20}\times 0.955 = 0.487 + 0.382 = 0.869$（1 分）
- 信息增益：$Gain(D, A) = 0.971 - 0.869 = 0.102$（1 分）

第 3 题（6 分 · 关联规则）

解：

(1) 频繁项集（3 分）：

项集	支持度计数
{A}	4（T1,T2,T3,T5）
{B}	4（T1,T3,T4,T5）
{C}	4（T1,T2,T4,T5）

项集	支持度计数
{A,B}	3（T1,T3,T5）
{A,C}	3（T1,T2,T5）
{B,C}	3（T1,T4,T5）

所有计数 ≥ 2，故全部为频繁项集。

(2) 规则 A → B（3 分）：

- $\text{Support}(A) = 4/5 = 0.8$
- $\text{Support}(A \cup B) = 3/5 = 0.6$
- $\text{Confidence}(A \to B) = 0.6/0.8 = 0.75 = 75\%$
- $75\% > 60\%$（minconf），满足置信度要求。

第 4 题（7 分 · 参数估计）

解：

(1) MLE（2 分）：$\hat{\theta}_{MLE} = \frac{9}{12} = 0.75$

(2) MAP（3 分）： 先验 Beta(3,3)，似然为 9 正 3 反。 后验 = Beta(3+9, 3+3) = Beta(12, 6) $\hat{\theta}_{MAP} = \frac{12-1}{12+6-2} = \frac{11}{16} = 0.6875$

(3) 变化方向及原因（2 分）： MAP 估计值 0.6875 比 MLE 估计值 0.75 更接近先验均值 0.5（Beta(3,3) 的均值为 0.5）。 原因：MAP 引入了先验信息，先验认为 θ 接近 0.5，因此将估计值向先验均值"拉回"。随着样本量增大，这种影响会逐渐减弱。

第 5 题（7 分 · 基尼指数）

解：

(1) 划分前基尼指数（2 分）： $\text{Gini}(D) = 1 - [(\frac{10}{16})^2 + (\frac{6}{16})^2] = 1 - [\frac{100}{256} + \frac{36}{256}] = 1 - \frac{136}{256} = 1 - 0.53125 = 0.46875$

(2) 划分后加权基尼指数（3 分）： $\text{Gini}(D_{B=1}) = 1 - [(\frac{7}{8})^2 + (\frac{1}{8})^2] = 1 - [\frac{49}{64} + \frac{1}{64}] = 1 - \frac{50}{64} = 0.21875$

$\text{Gini}(D_{B=0}) = 1 - [(\frac{3}{8})^2 + (\frac{5}{8})^2] = 1 - [\frac{9}{64} + \frac{25}{64}] = 1 - \frac{34}{64} = 0.46875$

$\text{Gini}_{\text{split}} = \frac{8}{16} \times 0.21875 + \frac{8}{16} \times 0.46875 = 0.109375 + 0.234375 = 0.34375$

(3) 基尼增益（2 分）： $\Delta\text{Gini} = 0.46875 - 0.34375 = 0.125$

第 6 题（8 分 · 朴素贝叶斯）

解：

(1) 计算先验概率（使用拉普拉斯平滑，α=1）（2 分）：

$P(Yes) = \frac{5+1}{10+2} = \frac{6}{12} = 0.5$

$P(No) = \frac{5+1}{10+2} = \frac{6}{12} = 0.5$

(2) 计算条件概率（4 分）：

Outlook（取值 Sunny/Overcast/Rain，共 3 种）：

	Sunny	Overcast	Rain
Yes	$P = \frac{2+1}{5+3} = \frac{3}{8}$	$\frac{2+1}{5+3} = \frac{3}{8}$	$\frac{1+1}{5+3} = \frac{2}{8}$
No	$P = \frac{3+1}{5+3} = \frac{4}{8}$	$\frac{1+1}{5+3} = \frac{2}{8}$	$\frac{1+1}{5+3} = \frac{2}{8}$

Temp（取值 Hot/Mild/Cool，共 3 种）：

	Hot	Mild	Cool
Yes	$P = \frac{1+1}{5+3} = \frac{2}{8}$	$\frac{1+1}{5+3} = \frac{2}{8}$	$\frac{3+1}{5+3} = \frac{4}{8}$
No	$P = \frac{2+1}{5+3} = \frac{3}{8}$	$\frac{1+1}{5+3} = \frac{2}{8}$	$\frac{2+1}{5+3} = \frac{3}{8}$

Humidity（取值 High/Normal，共 2 种）：

	High	Normal
Yes	$P = \frac{2+1}{5+2} = \frac{3}{7}$	$\frac{3+1}{5+2} = \frac{4}{7}$
No	$P = \frac{3+1}{5+2} = \frac{4}{7}$	$\frac{2+1}{5+2} = \frac{3}{7}$

(3) 预测新样本 {Outlook=Sunny, Temp=Cool, Humidity=Normal}（2 分）：

$$P(Yes) \times P(Sunny|Yes) \times P(Cool|Yes) \times P(Normal|Yes) = 0.5 \times \frac{3}{8} \times \frac{4}{8} \times \frac{4}{7}$$

$$= 0.5 \times 0.375 \times 0.5 \times 0.571 = 0.0536$$

$$P(No) \times P(Sunny|No) \times P(Cool|No) \times P(Normal|No) = 0.5 \times \frac{4}{8} \times \frac{3}{8} \times \frac{3}{7}$$

$$= 0.5 \times 0.5 \times 0.375 \times 0.429 = 0.0402$$

$\because 0.0536 > 0.0402$，$\therefore$ 预测为 **Yes**（适合户外运动）。

> 📝 **分数自检**：选择题 30 + 简答题 30 + 计算题 (6+6+6+7+7+8) = 30 + 30 + 40 = **100 分** ✓

> 🗓️ **最后更新**：2026 年 6 月 | **整理人注**：本讲义综合了课堂 PPT、教材及复习重点，仅供复习参考。重点掌握数据挖掘（第四章）中的关联规则和分类算法，以及数据预处理中的规范化、距离度量和信息熵计算。