数据分析及实践 — 三轮复习（冲刺回归）

刘淇老师、程明月老师 · 中国科学技术大学 | 2026 年 6 月

使用说明

三轮复习是考前最后冲刺阶段。**一轮**帮你建立完整知识体系（"会"），**二轮**按题型横向打通并模拟实战（"通"），**三轮**聚焦于：

1. **背下来** — 用速记清单把散落在各章的公式和概念浓缩到十几分钟能过一遍的量
2. **不再错** — 把反复出现的高频陷阱集中曝光，考前看一遍避免重蹈覆辙
3. **拿满步骤分** — 学会答题框架和时间分配，会的题不丢分
4. **再练一套** — 第二套模拟卷补充一轮二轮未覆盖或覆盖不足的考点

> **推荐使用顺序**：① 先独立完成模拟卷（120 分钟限时）→ ② 对照答案批改 → ③ 在速记清单上标记错误涉及的公式/概念 → ④ 读易错陷阱确认自己没有中招 → ⑤ 考前 15 分钟再过一遍速记清单。

第一部分：考前速记清单

一、公式速查

数据预处理

用途	公式	注意事项
Min-Max 归一化	$v' = \frac{v-\min}{\max-\min}$（→[0,1]）	对极值敏感，新数据可能超界
z-score	$v' = \frac{v-\mu}{\sigma}$	假设正态分布，结果为"几个标准差"
小数定标	$v' = v/10^j$，j 使 max|v'|<1	简单粗暴
信息熵	$H = -\sum p_i \log_2 p_i$	底数为 2，均匀分布时熵最大 = $\log_2 C$
信息增益	$Gain = H(D) - \sum \frac{	$D_j
增益率	$\frac{Gain}{SplitInfo}$，SplitInfo = $-\sum \frac{	$D_j
基尼指数	$Gini = 1 - \sum p_i^2$	CART 分裂指标；二分类均匀时 = 0.5

距离与相似度

指标	公式	关键记忆点
欧几里得	$d = \sqrt{\sum (p_k - q_k)^2}$	直线距离
曼哈顿	$d = \sum \lvert p_k - q_k \rvert$	城市街区距离

指标	公式	关键记忆点
汉明	不同位置的个数	等长二值向量
明可夫斯基	$d=(\sum\|p_k-q_k\|^r)^{1/r}$	r=1 曼哈顿，r=2 欧几里得
马氏	$D_M=\sqrt{(\mathbf{p}-\mathbf{q})^T\Sigma^{-1}(\mathbf{p}-\mathbf{q})}$	消除量纲和相关性
SMC	$\frac{F_{11}+F_{00}}{\text{全部}}$	二值向量，含 00 匹配
Jaccard	$\frac{F_{11}}{F_{01}+F_{10}+F_{11}}$	二值向量，排除 00
余弦相似度	$\frac{\mathbf{A}\cdot\mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|}$	只看方向不看长度
Pearson r	$\frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum(X_i-\bar{X})^2\cdot\sum(Y_i-\bar{Y})^2}}$	线性相关，[-1,1]
Spearman ρ	$1-\frac{6\sum d_i^2}{n(n^2-1)}$	等级/排序相关
卡方 χ^2	$\sum\frac{(O_{ij}-E_{ij})^2}{E_{ij}}$，$E_{ij}=\frac{\text{行合计}\times\text{列合计}}{n}$	分类变量独立性检验

规范化比较

方法	优点	缺点
Min-Max	简单，保留分布关系	对极值非常敏感
z-score	不受量纲影响	需知 μ 和 σ，假设正态
小数定标	实现简单	无实际比较意义

参数估计

方法	目标	关键
MLE	$\max p(X\|\theta)$	只依赖数据，无先验
MAP	$\max p(X\|\theta)p(\theta)$	MLE + 先验正则化
贝叶斯	求后验分布 $p(\theta\|X)$	保留不确定性，不求单点

关联规则

指标	公式	含义
Support	$P(X\cup Y)$	规则出现频率
Confidence	$P(X\cup Y)/P(X)$	X 出现时 Y 也出现的概率
Lift	$P(X,Y)/(P(X)P(Y))$	>1 正相关，=1 独立，<1 负相关

分类评估

指标	公式	口诀
Accuracy	$\frac{TP+TN}{Total}$	总体正确率
Precision	$\frac{TP}{TP+FP}$	查准率——预测为正的里面多少是真
Recall	$\frac{TP}{TP+FN}$	查全率——真实为正的里面多少被找出来
F1	$\frac{2PR}{P+R} = \frac{2TP}{2TP+FP+FN}$	P 和 R 的调和平均
FPR	$\frac{FP}{TN+FP}$	ROC 横轴
TPR	$\frac{TP}{TP+FN}$ = Recall	ROC 纵轴

决策树三大分裂指标

算法	指标	特点
ID3	信息增益（Entropy 减少量）	偏向取值多的特征 → 易过拟合
C4.5	增益率（Gain / SplitInfo）	惩罚取值多的特征，泛化更好
CART	基尼指数	二分类专长，速度快（无数对数）

ARIMA

- **p**：自回归阶数（PACF 截尾定 p）
- **d**：差分阶数（ADF 检验 p<0.05 平稳 → d=0；否则 d=1 或 2）
- **q**：移动平均阶数（ACF 截尾定 q）
- **d=1 时预测**：$\hat{y}_{t+1} = y_t + \phi_1(y_t - y_{t-1}) + \ldots + \theta_1\varepsilon_t + \ldots$

聚类方法

方法	类型	需预设 K	处理任意形状	对噪声
K-means	划分	✓	✗	敏感
层次聚类	层次	✗	部分	一般
DBSCAN	密度	✗	✓	鲁棒

二、概念速记

大数据 4V

Volume（量大）· **Velocity**（快速）· **Variety**（多样）· **Value**（价值）

科学五范式

经验 → 理论 → 计算 → 数据密集 → **AI 驱动（第五范式）**

三种缺失机制

- **MCAR**：缺失完全随机，与任何变量无关 → 可安全删除
- **MAR**：缺失仅与观测变量有关，与自身取值无关 → 回归/EM 填补
- **MNAR**：缺失与自身取值有关 → 需专门建模

结构化 vs 半结构化 vs 非结构化

结构化（二维表）→ 半结构化（XML/JSON，自描述标记）→ 非结构化（文本/图像/视频）

NoSQL 四兄弟

MongoDB（文档，灵活）→ **Redis**（键值，极快缓存）→ **HBase**（列存储，海量日志）→ **Neo4j**（图，社交网络 O(1) 遍历）

SQL 三种完整性

实体（主键唯一非空）→ **参照**（外键）→ **用户定义**（年龄范围等）

GET vs POST

GET：URL 传参 / 不安全 / 长度受限 · POST：请求体传参 / 安全 / 无长度限制

MAC 读写规则

主体许可证 ≥ 客体密级 → 可读；主体许可证 ≤ 客体密级 → 可写

数据清洗三步

缺失值（删/填）→ 噪声（分箱/回归/聚类）→ 不一致（编码统一/去重）

规范化三兄弟

Min-Max（对极值敏感）· z-score（正态假设）· 小数定标（量级差距大时用）

特征选择三策略

Filter（独立统计）→ **Wrapper**（分类器评价）→ **Embedded**（训练中选）

PCA 步骤

去均值 → 协方差矩阵 → 特征分解 → 取前 k 大 → 投影

关联规则两步走

① 频繁项集生成（看 Support ≥ minsup）→ ② 规则产生（看 Confidence ≥ minconf）

Apriori 核心性质

频繁项集的子集必频繁 · 非频繁项集的超集必不频繁（反单调性）

FP-Growth 三步

扫一遍计数排序 → 扫二遍建 FP-Tree → 从下往上递归挖条件树

置信度反单调性

规则前件越大（后件越小）→ 置信度越高：conf(ABC→D) ≥ conf(AB→CD) ≥ conf(A→BCD)

辛普森悖论

总体趋势在分组后**逆转**。本质：混杂变量 + 不等样本量。解决：分层 / 多变量回归。

分类 vs 聚类

分类：**有监督**，已知标签 · 聚类：**无监督**，无标签

Bagging vs Boosting

Bagging：并行 / 独立 / 降方差 / 代表：随机森林 **Boosting**：串行 / 依赖 / 降偏差 / 代表：AdaBoost, GBDT, XGBoost

朴素贝叶斯假设

给定类别下各属性**相互独立**（"朴素"的含义）

SVM 核函数四选

线性 / 多项式 $(x^T y)^d$ / 高斯 RBF $\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$ / Sigmoid

时间序列四成分

趋势（长期方向）+ **季节性**（固定周期）+ **周期性**（不固定周期）+ **随机性**（噪声）

异常检测五类法

统计（IQR/z-score）→ 距离（KNN）→ 密度（DBSCAN/LOF）→ 聚类 → 模型（孤立森林/AutoEncoder）

箱图要素

箱体（Q_1~Q_3，IQR）→ 中位线 → 须（±1.5×IQR）→ 异常值（须外）

两类错误

α（弃真）：H_0 真却拒绝 · **β（取伪）**：H_0 假却接受 · 增大 n 可同时减小

k-NN 的"懒惰"

训练 = 存数据（秒级）· 预测 = 算所有样本距离（慢）

层次聚类簇间距离

单链 MIN（近）→ 全链 MAX（远）→ 组平均 → 中心距离

第二部分：易错陷阱 20 条

> 以下陷阱均选自一轮和二轮复习中反复出现的高频错误点，每题附加"锚点记忆"帮助你在考场快速辨别。

陷阱 1：MCAR / MAR / MNAR 辨析

常见错误：看到"随机缺失"就认为是完全随机。 **正确理解**：MAR 的"随机"是**条件随机**——给定观测变量后缺失相当于随机发生，并不要求缺失与一切都无关。只有 MCAR 才是无条件完全随机。

> 🔗 锚点：MAR = Missing **At** Random，At 表示"在给定条件下"随机。

陷阱 2：几何平均 vs 算术平均

常见错误：计算平均增长率时用算术平均。 **正确理解**：增长率、收益率、合格率等比率数据必须用**几何平均**。投资两年，涨 100% 再跌 50%，算术平均 = +25%（荒谬），几何平均 = 0%（正确）。

> 🔗 锚点：看到"率"就想到几何平均。

陷阱 3：卡方检验 vs Pearson 相关

常见错误：不分变量类型乱用。 **正确理解**：卡方 → 两个**分类**变量的独立检验。Pearson → 两个**连续**变量的**线性**相关。Spearman → **有序/等级**变量的单调相关。

> 🔗 锚点：列联表 → 卡方；散点图直线 → Pearson；排名 → Spearman。

陷阱 4：MLE 方差的 n vs n-1

常见错误：混淆总体方差和样本方差的分母。 **正确理解**：MLE 估计正态方差时分母为 **n**（$\hat{\sigma}^2 = \frac{1}{n}\sum(x_i - \hat{\mu})^2$），是有偏的。样本无偏方差分母为 **n-1**（$s^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$）。

> 🔗 锚点：MLE = 直接最大化 = n；无偏估计 = n-1。

陷阱 5：Pearson r = 0 ≠ 不相关

常见错误：r = 0 就下结论"两变量无关"。 **正确理解**：r = 0 只说明无**线性**相关，可能存在强烈的非线性关系（如 $Y = X^2$ 的对称抛物线）。

> 🔗 锚点：Pearson 只测**直线**，曲线它看不出来。

陷阱 6：Jaccard ≠ SMC

常见错误：把 SMC 当 Jaccard 用。 **正确理解**：Jaccard 分子和分母都**不含 F_{00}**（两个都是 0 的属性不参与计算），适合购物篮等稀疏场景。SMC 包含 F_{00}。

> 🔗 锚点：Jaccard = 排除全 0；SMC = 全算进去。

陷阱 7：Lift 的分子分母别搞反

常见错误：写成 $P(X)P(Y)/P(X,Y)$。 **正确理解**：Lift = $P(X,Y)/(P(X)P(Y))$。Lift > 1 正相关（X 促进 Y），Lift = 1 独立，Lift < 1 负相关（X 抑制 Y）。

> 🔗 锚点：联合概率在上，独立期望在下。

陷阱 8：置信度方向不能互换

常见错误：认为 Confidence(A→B) = Confidence(B→A)。 **正确理解**：Confidence(A→B) = $P(A \cup B)/P(A)$，Confidence(B→A) = $P(A \cup B)/P(B)$。两者分母不同，一般不等。

> 🔗 锚点：谁在前，谁做分母。

陷阱 9：信息增益 ≠ 增益率，别把 ID3 当 C4.5

常见错误：答"C4.5 用信息增益选择特征"。 **正确理解**：ID3 用信息增益（偏向多值特征）→ C4.5 用**增益率**（除以 SplitInfo 作为惩罚）→ CART 用**基尼指数**。

> 🔗 锚点：C4.5 = 增益**率**（多了一个字，多了一个惩罚项）。

陷阱 10：混淆矩阵的 Precision 和 Recall 别背反

常见错误：把 Precision 当成 Recall。 **正确理解**：Precision（查准）= TP/(TP+FP)，分母是**预测为正**的。Recall（查全）= TP/(TP+FN)，分母是**真实为正**的。

> 🔗 锚点：**P**recision 看 **P**redicted（预测为正的列）。**R**ecall 看 **R**eal（真实为正的行）。

陷阱 11：ROC 横轴是 FPR 不是 Precision

常见错误：把 PR 曲线和 ROC 曲线坐标搞混。 **正确理解**：ROC → 横轴 FPR（假正率），纵轴 TPR（真正率 =Recall）。PR 曲线 → 横轴 Recall，纵轴 Precision。

> 🔗 锚点：ROC 两个轴都是"率"——FPR 和 TPR。

陷阱 12：K-means 初始中心敏感 ≠ 需要预设 ε

常见错误：把 K-means 和 DBSCAN 的参数要求搞混。 **正确理解**：K-means 需预设 **K**（簇数），对初始中心敏感。DBSCAN 需预设 **ε** 和 **MinPts**，对参数敏感。

> 🔗 锚点：K-means → K；DBSCAN → ε + MinPts。

陷阱 13：Apriori 剪枝用子集，不是超集

常见错误：说"非频繁的超集要剪掉"。 **正确理解**：Apriori 性质是反单调的：如果 k-项集不频繁，则它的**所有超集**都不频繁（在剪枝步中，我们检查候选 k-项集的 **(k-1)-子集**是否都在频繁集中）。

> 🔗 锚点：向下看子集（判断保留），向上杀超集（判断剔除）。

陷阱 14：拉普拉斯平滑别忘了加

常见错误：朴素贝叶斯中某条件概率为 0，连乘导致整体为 0。 **正确理解**：必须用拉普拉斯平滑：$P(A_i = a|C = c) = \frac{\text{count}+1}{\text{count}(C=c)+|\text{values}(A_i)|}$。分子加 1，分母加该属性的取值种类数。

> 锚点：分子 +1，分母 + 属性取值个数。一看到贝叶斯就条件反射做平滑。

陷阱 15：FP-Tree 扫描次数 = 2，不是 1

常见错误：记成 FP-Growth 只需扫描 1 次。 **正确理解**：第一次扫描 → 统计单项支持度 + 排序；第二次扫描 → 构建 FP-Tree。**后续挖掘不再扫描原始数据库**。

> 锚点：2 次扫描建树，之后全在内存。

陷阱 16：分层抽样 vs 整群抽样

常见错误：两者混淆。 **正确理解**：分层 → **层内差异小、层间差异大**，每层**内**随机抽。整群 → 抽几个群，**群内全查**，适合群内差异大群间差异小的场景。

> 锚点：分层 = 层层都抽；整群 = 抽了群就全查。

陷阱 17：Bagging 降方差，Boosting 降偏差

常见错误：说 Boosting 降方差。 **正确理解**：Bagging 并行训练独立模型 → 平均后降低**方差**（防止过拟合）。Boosting 串行修正误差 → 逐步降低**偏差**（提高拟合能力）。

> 锚点：**B**agging → **V**ariance（B 对应 V？反过来记：独立 = 方差小）；**B**oosting → **B**ias（两个 B）。

陷阱 18：感知机 ≠ 逻辑回归

常见错误：把两者混为一谈。 **正确理解**：感知机输出 ±1（硬分类），用阶跃函数；逻辑回归输出概率（软分类），用 Sigmoid。感知机要求线性可分才能收敛，逻辑回归线性不可分也能用。

> 锚点：感知机 = 是/否；逻辑回归 = 概率多少。

陷阱 19：ARIMA 的 d 很少超过 2

常见错误：平稳性不过就一直差分下去。 **正确理解**：d 一般取 0、1 或 2，极少超过 2。**过差分**会破坏自相关结构，反而让模型变差。

> 锚点：d 最多 2，过差分毁数据。

陷阱 20：信息熵的底数是 2

常见错误：用 ln（自然对数）算熵。 **正确理解**：信息论中的熵以 **2 为底**，单位是 bit。虽然有时也使用自然对数，但本课程考试中以 2 为底。均匀二分类 H = 1 而非 ln(2)≈0.693。

> 🔗 锚点：H = 1（二分均匀时），对应 $\log_2 2 = 1$。

第三部分：考试策略与答题模板

一、时间分配建议（120 分钟）

阶段	时间	内容	策略
选择题	20 min	15 道 × ~80 秒/道	先做确定的，不会的标记后跳，最后回来蒙
简答题	30 min	5 道 × 6 min/道	关键词先行，再展开。拿不准的先列框架再填
计算题	60 min	6 道题（6/6/6/7/7/8 分）	按分值分配：6 分 ≈ 8min，7 分 ≈ 10min，8 分 ≈ 12min
检查	10 min	全卷	优先复查计算题中间步骤和单位

二、简答题万能框架

```
【框架】定义 → 核心要点（3-4 条）→ 一句话总结/举例

示例模板（6 分题）：
① 定义：XXX 是指……（1 分）
② 要点 1：……（1-2 分）
③ 要点 2：……（1-2 分）
④ 要点 3：……（1-2 分）
⑤ 小结/举例：例如……（1 分）
```

核心原则：

- 分条列点，每条一行，让阅卷人一眼看到给分点
- 对比类简答（如 "A 与 B 的区别"）必须**两边都写**，不能只写一边
- 流程类简答（如 "算法的步骤"）按 1→2→3→4 编号，一个步骤一条

三、计算题分步得分技巧

1. **写公式**（占 15-20% 分数）：即使后面算错，公式对就有分。每道计算题第一步先写出所用公式。
2. **代数据**（占 15-20% 分数）：把题目给的数值代入公式，清晰标注在草稿和答卷上。
3. **计算过程**（占 40-50% 分数）：中间结果保留 3 位小数，最终结果保留 2 位。
4. **结论/解读**（占 10-15% 分数）：算出数字不是终点——比如算完 F1 分数要说"说明模型综合表现较好"，算完 Lift 要说">1 表明正相关"。

常见丢分点

错误类型	示例	如何避免
忘写公式	直接代数字	每题第一步先抄公式
小数舍入过早	中间步骤就四舍五入	中间保留 3 位，最后一步再约
忘写单位/结论	算了 r=0.85 就停了	加一句"说明高度正相关"
混淆分母	MLE 方差除以 n 还是 n-1	考前在速记清单上反复确认
log 底数搞错	用 ln 算熵	考试统一 $\log_2$

第四部分：第二套仿真模拟卷

> **考试时间**：120 分钟 | **满分**：100 分

一、选择题（共 15 题，每题 2 分，共 30 分）

1. 科学范式的演进顺序，以下排列**正确**的是？

A. 经验科学 → 计算科学 → 理论科学 → 数据密集化科学
B. 经验科学 → 理论科学 → 计算科学 → 数据密集化科学
C. 理论科学 → 经验科学 → 计算科学 → 数据密集化科学
D. 计算科学 → 经验科学 → 理论科学 → 数据密集化科学

---

2. 关于网络爬虫中 GET 与 POST 请求，以下说法**错误**的是？

A. GET 的参数放在 URL 中，POST 的参数放在请求体中
B. GET 的 URL 长度不受限制
C. POST 比 GET 更安全，常用于登录
D. GET 适合数据查询，POST 适合数据提交

---

3. 在 SQL 的强制存取控制（MAC）中，若主体许可证级别为"秘密"，客体密级为"机密"，且安全等级从低到高为：公开 < 秘密 < 机密 < 绝密，则该主体对客体？

A. 可读可写
B. 可读不可写
C. 不可读不可写
D. 可写不可读

---

4. 以下哪种 NoSQL 数据库最适合用于电商秒杀场景中的库存扣减（避免超卖）？

A. MongoDB
B. Redis
C. HBase
D. Neo4j

---

5. 以下关于规范化方法的描述，**正确**的是？

A. Min-Max 规范化不受极值影响
B. z-score 规范化不依赖于均值和标准差
C. 小数定标规范化通过移动小数点将数据映射到 [-1, 1] 区间
D. z-score 规范化后均值为 0，标准差为 1

---

6. 关于 PCA（主成分分析），以下说法**错误**的是？

A. PCA 的目标是最大化投影后方差
B. 各主成分之间相互正交（独立）
C. PCA 的第一步是对数据做归一化
D. 通常选择特征值最大的 k 个特征向量进行投影

---

7. 某流水线生产零件的合格率分别为 95%、90%、85%，则三道工序的平均合格率最适合使用？

A. 算术平均数
B. 中位数
C. 几何平均数
D. 加权算术平均数

---

8. 在箱图中，若 $Q_1 = 20$，$Q_3 = 50$（IQR = 30），则上须（上边缘）的端点值为？

A. 80
B. 95
C. 65
D. 50 + 1.5 × 30 = 95（取不超过数据最大值的值）

---

9. 关于高级关联规则挖掘，利用概念层次将 {光明牛奶} 抽象为 {牛奶} 来提高支持度，属于？

A. 多维关联规则
B. 多层关联规则
C. 负模式挖掘
D. 序列模式挖掘

---

10. 感知机模型的输出函数是？

A. Sigmoid 函数
B. 阶跃函数（sign）
C. ReLU 函数
D. Softmax 函数

---

11. 决策树剪枝中，"先构建完整的决策树，再自底向上将子树替换为叶节点"属于？

A. 预剪枝
B. 后剪枝

C. 特征选择
D. 集成学习

---

12. AdaBoost 算法中，基学习器 G_t 的投票权重 α_t 与其加权错误率 ϵ_t 的关系是？

A. α_t 随 ϵ_t 增大而增大
B. $\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$，错误率越低权重越大
C. $\alpha_t = \epsilon_t$
D. 所有基学习器权重相等

---

13. 关于层次聚类的簇间距离度量，使用"两个簇中最近的两个点之间的距离"来定义簇间距离的方法称为？

A. 全链（MAX）
B. 组平均
C. 单链（MIN）
D. 中心距离

---

14. 以下哪种异常检测方法主要基于"异常点的局部密度显著低于其邻居"这一原理？

A. z-score
B. 箱图（IQR）
C. LOF（局部异常因子）
D. 孤立森林

---

15. ARIMA(1,1,0) 中，第一个参数 "1" 代表？

A. 差分阶数为 1
B. 自回归阶数为 1
C. 移动平均阶数为 1
D. 季节性周期为 1

二、简答题（共 5 题，每题 6 分，共 30 分）

1.（第二章 · 数据预处理）
简述三种缺失值机制（MCAR、MAR、MNAR）的定义及各自对应的推荐处理策略。

2.（第四章 · 关联规则）
什么是辛普森悖论？请用伯克利大学研究生录取案例说明其产生原因，并提出两种避免方法。

3.（第四章 · 分类 · 决策树）
简述决策树过拟合的三个主要原因，并说明预剪枝和后剪枝的区别。

4.（第四章 · 时间序列）
简述 ARIMA 建模的完整流程（从原始序列到最终预测），并说明如何确定参数 p、d、q。

5.（第四章 · 异常检测）
列举异常检测的五大类方法并各举一种代表性技术，简要说明其核心原理。

三、计算题（共 6 题，共 40 分）

1.（6 分 · 第二章 · TF-IDF）

某小型语料库包含 3 篇文档：

- d_1："data mining is useful"（4 个词）
- d_2："data science is interesting"（4 个词）
- d_3："mining is important"（3 个词）

(1) 计算词 "data" 的 IDF 值（使用公式 $IDF = \log \frac{N}{DF}$，以自然对数为底）。
(2) 计算 "data" 在 d_1 中的 TF-IDF 值。
(3) 解释为什么 IDF 公式中要取对数。

（注：计算结果精确到小数点后 3 位。）

2.（6 分 · 第二章/第三章 · z-score 比较）

甲、乙两位学生参加了两门不同难度的考试：

- 数学：满分 150，甲得分 132，全班平均 108，标准差 18
- 物理：满分 100，乙得分 78，全班平均 64，标准差 14

(1) 使用 z-score 规范化，分别计算甲和乙的标准化成绩。
(2) 谁的相对排名更高？说明理由。
(3) 简述 z-score 规范化相对于 Min-Max 规范化的一个优势和劣势。

3.（6 分 · 第四章 · 信息增益 + 增益率）

某数据集 D 含 12 个样本，二分类（正 8，负 4）。考虑按特征 A 分裂：

- $A = A_1$：6 个样本（正 5，负 1）
- $A = A_2$：6 个样本（正 3，负 3）

(1) 计算划分前的信息熵 H(D)。
(2) 计算按特征 A 分裂的信息增益 Gain(D, A)。
(3) 计算特征 A 的增益率 GainRatio(D, A)。

（计算过程中熵值精确到小数点后 3 位。）

4.（7 分 · 第二章 · 距离与相似度）

已知三个二维点：$\mathbf{x}_1 = (3, 4)$，$\mathbf{x}_2 = (6, 8)$，$\mathbf{x}_3 = (0, 5)$。

(1) 计算 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 之间的欧几里得距离。
(2) 计算 $\mathbf{x}_1$ 和 $\mathbf{x}_3$ 之间的曼哈顿距离。
(3) 计算 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 之间的余弦相似度，并解释结果为什么等于 1。
(4) 若使用 Min-Max 规范化将三个点的 x 坐标映射到 [0, 1]，请写出规范化后的 x 坐标。

5.（7 分 · 第四章 · Apriori 关联规则）

某超市 8 个事务，minsup = 2（以计数计），minconf = 70%：

TID	事务
1	{牛奶, 面包, 黄油}
2	{牛奶, 面包}
3	{面包, 黄油}
4	{牛奶, 面包, 黄油}
5	{牛奶}
6	{牛奶, 黄油}
7	{面包}
8	{牛奶, 面包, 黄油}

(1) 写出所有频繁 1 项集及其支持度计数。
(2) 写出所有频繁 2 项集及其支持度计数。（请写出 Apriori 的剪枝过程）
(3) 计算规则 {黄油} → {牛奶} 的支持度、置信度和提升度（Lift），并解读结果。

6.（8 分 · 第四章 · 朴素贝叶斯 + 决策树综合）

下表为贷款审批数据集，目标变量为 Loan（是否批准贷款）：

信用等级(Credit)	年收入(Income)	有房产(House)	Loan
A	High	Yes	Yes
B	Medium	No	No
A	Medium	No	Yes
C	Low	No	No
B	High	Yes	Yes
A	High	No	Yes
C	Medium	Yes	No
B	Low	No	No
A	Medium	Yes	Yes

信用等级(Credit)	年收入(Income)	有房产(House)	Loan
B	High	No	Yes

现有一个新申请者：{Credit=B, Income=Medium, House=No}，请回答：

(1) 使用拉普拉斯平滑（α = 1），用朴素贝叶斯分类器预测该申请者的 Loan 类别（Yes 或 No）。
(2) 计算该数据集 Loan 的基尼指数 Gini。
(3) 若以"House"作为根节点分裂特征，计算分裂后的加权基尼指数，并判断该分裂是否有效（即基尼增益是否大于 0）。

（所有概率和指数精确到小数点后 3 位。）

参考答案与评分标准

一、选择题答案与解析

第 1 题

> 科学范式的演进顺序，以下排列**正确**的是？

答案：B（经验科学 → 理论科学 → 计算科学 → 数据密集化科学）

解析：科学范式按历史顺序：第一范式（经验/观察实验）→ 第二范式（理论/数学模型）→ 第三范式（计算/计算机模拟）→ 第四范式（数据密集/以数据为中心）→ 第五范式（AI 驱动）。A 把理论和计算顺序颠倒；C 以理论开头跳过经验；D 以计算开头完全错序。

对应知识点：第一章 1.2 科学范式

第 2 题

> 关于网络爬虫中 GET 与 POST 请求，以下说法**错误**的是？

答案：B（GET 的 URL 长度不受限制）

解析：GET 的 URL **有长度限制**（不同浏览器约 2KB~8KB），这是其重要缺陷之一。A 正确——参数位置不同；C 正确——POST 的 Form Data 不在 URL 中暴露；D 正确——查询和提交的典型分工。

对应知识点：第二章 2.1.4 网络爬虫 · 请求方式

第 3 题

> 在 SQL MAC 中，主体"秘密"级，客体"机密"级，该主体对客体？

答案：D（可写不可读）

解析：MAC 规则——主体许可证 ≥ 客体密级 → 可读；主体许可证 ≤ 客体密级 → 可写。本题"秘密" < "机密"，故：不可读（秘密 < 机密，不满足 ≥），可写（秘密 < 机密，满足 ≤）。注意写是"向下写"——低级别主体可以

向高级别客体写入（防止高密级数据泄露到低级别）。

对应知识点：第二章 2.2.2 关系型数据库 · 安全性 · MAC

第 4 题

> 哪种 NoSQL 数据库最适合电商秒杀的库存扣减（避免超卖）？

答案：B（Redis）

解析：Redis 是键值型内存数据库，读写极快，支持原子操作（INCR/DECR），天然适合计数器、秒杀库存这种高并发场景。A（MongoDB）适合灵活文档存储；C（HBase）适合海量日志和大数据分析；D（Neo4j）适合社交网络等关系密集型场景。

对应知识点：第二章 2.2.3 NoSQL · Redis 详解

第 5 题

> 关于规范化方法的描述，**正确**的是？

答案：D（z-score 规范化后均值为 0，标准差为 1）

解析：z-score 变换 $v' = (v - \mu)/\sigma$ 的结果是标准化分布——均值恒为 0，标准差恒为 1。A 错误——Min-Max 对极值非常敏感；B 错误——z-score 依赖 μ 和 σ；C 错误——小数定标映射到 (-1, 1)，不是 [-1, 1]（边界不闭合）。

对应知识点：第二章 2.3.4 数据变换 · 规范化

第 6 题

> 关于 PCA，以下说法**错误**的是？

答案：C（PCA 的第一步是对数据做归一化）

解析：PCA 的标准第一步是**去均值（中心化）**，使每个特征的均值为 0，而不是归一化。是否需要归一化取决于数据特征——若各特征量纲不同，可在去均值后做标准化。但 PCA 的核心步骤是去均值而不是归一化。A、B、D 均为正确描述。

对应知识点：第二章 2.3.5 数据规约 · PCA

第 7 题

> 三道工序合格率 95%、90%、85%，平均合格率最适合用？

答案：C（几何平均数）

解析：合格率是比率数据，总合格率 = 95% × 90% × 85% = 72.675%，平均合格率 = (0.95 × 0.90 × 0.85)^(1/3) ≈ 89.9%。若用算术平均 = 90%，与真实总合格率不符。一切"率"的均值首选几何平均。

对应知识点：第三章 3.1.1 集中趋势 · 几何平均数

第 8 题

> 箱图中 Q_1=20, Q_3=50, 上须端点值?

答案：D（Q_3 + 1.5 × IQR = 95，且取不超过数据最大值的值）

解析：IQR = 50 - 20 = 30，上须理论端点 = Q_3 + 1.5 × IQR = 50 + 45 = 95。但须的实际端点 $\min(\max(\text{数据}), 95)$——即取 95 和数据最大值中较小的那个。D 完整描述了这一规则。A、B、C 各有遗漏：A(80) 是 Q_3 + IQR（不是 1.5 倍），B(95) 没标注"不超过数据最大值"的限制条件，C(65) 计算错误。

对应知识点：第三章 3.1.1 箱图要素

第 9 题

> 利用概念层次将 {光明牛奶} 抽象为 {牛奶} 来提高支持度，属于?

答案：B（多层关联规则）

解析：多层关联规则利用**概念层次树**（taxonomy），将低层概念（光明牛奶）替换为高层概念（牛奶→乳制品→食品），以提高支持度从而发现更通用的模式。A（多维关联规则）涉及多个属性维度（如年龄+购买商品）；C（负模式）如 {可口可乐} → ¬{百事可乐}；D（序列模式）考虑时间顺序 A→B→C。

对应知识点：第四章 4.2.8 关联规则扩展 · 多层关联规则

第 10 题

> 感知机模型的输出函数是?

答案：B（阶跃函数 sign）

解析：感知机的输出 $f(\mathbf{x}) = \text{sign}(\mathbf{w}^T\mathbf{x} + b)$，符号函数（阶跃函数）直接输出 +1 或 -1，属于硬分类。A（Sigmoid）是逻辑回归的激活函数；C（ReLU）常用于深度神经网络；D（Softmax）用于多分类输出概率。

对应知识点：第四章 4.3.5 感知机

第 11 题

> "先构建完整决策树，再自底向上将子树替换为叶节点"属于?

答案：B（后剪枝）

解析：后剪枝（Post-pruning）先让决策树充分生长，然后基于验证集从叶子节点向上回溯，若剪掉某子树后验证集误差不增大（或不显著增大），则将该子树替换为叶节点。A（预剪枝）是在构建过程中提前停止。C 和 D 是完全不同的概念。

对应知识点：第四章 4.3.1 决策树 · 过拟合与剪枝

第 12 题

> AdaBoost 基学习器投票权重 α_t 与错误率 ϵ_t 的关系？

答案：B（$\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$，错误率越低权重越大）

解析：当 ϵ_t 越小（学习器越准），$\frac{1-\epsilon_t}{\epsilon_t}$ 越大，α_t 越大——即准确率高的学习器在投票中获得更大话语权。当 $\epsilon_t = 0.5$（随机猜测），$\alpha_t = 0$；当 $\epsilon_t = 0$（完美），$\alpha_t \to \infty$（实践中需截断）。A 说法完全反了；C 和 D 错误。

对应知识点：第四章 4.3.5 集成学习 · AdaBoost

第 13 题

> 层次聚类中"两个簇中最近的两个点之间的距离"称为？

答案：C（单链 MIN）

解析：单链（Single Linkage/MIN）以两个簇中**最近**的一对点的距离作为簇间距离，能处理非椭圆形状但易受噪声影响。A 全链（MAX）取最远点距离，对噪声鲁棒但易破碎大簇。B 组平均取所有点对距离的均值。D 中心距离取簇质心距离。

对应知识点：第四章 4.5.3 层次聚类 · 簇间距离度量

第 14 题

> 基于"局部密度显著低于邻居"原理的异常检测方法是？

答案：C（LOF）

解析：LOF（Local Outlier Factor，局部异常因子）的核心思想是比较一个点的局部密度与其 k 近邻的局部密度——若该点密度明显低于邻居，则 LOF 值 > 1，判定为异常。A（z-score）基于全局均值和标准差；B（箱图 IQR）基于分位数；D（孤立森林）基于随机划分——异常点更容易被孤立（路径更短）。

对应知识点：第四章 4.6 异常检测 · 常用方法

第 15 题

> ARIMA(1,1,0) 中第一个参数 "1" 代表？

答案：B（自回归阶数为 1）

解析：ARIMA(p, d, q) 三个参数依次为——**p**（自回归阶数 AR）、**d**（差分阶数 I）、**q**（移动平均阶数 MA）。ARIMA(1,1,0) 表示 p=1（一阶自回归），d=1（一阶差分），q=0（无移动平均项）。

对应知识点：第四章 4.4 时间序列 · ARIMA 参数

二、简答题评分标准

第 1 题（每个机制 2 分，共 6 分）：

- **MCAR**（完全随机缺失）：缺失与任何已观测或未观测变量均无关（如仪器随机故障）。策略：可安全删除缺失样本或简单填补（均值等）。（2 分）
- **MAR**（随机缺失）：缺失概率仅依赖于已观测的其他变量，与缺失值自身无关（如期末成绩缺失与平时成绩有关）。策略：推荐基于模型的填补（回归、EM 算法）。（2 分）
- **MNAR**（非随机缺失）：缺失概率与缺失值本身有关（如高收入者拒填工资）。策略：需建立选择模型或进行敏感性分析，不能简单删除。（2 分）

第 2 题（定义 2 分 + 案例分析 2 分 + 避免方法 2 分，共 6 分）：

- **定义**：辛普森悖论指总体数据中的趋势在按某变量分组后发生逆转的现象。数学上源于加权平均方向与各条件概率方向不一致。（2 分）
- **伯克利案例**：总体数据看，男性录取率约 44%，女性约 35%，似乎存在性别歧视。但按专业分组后，大多数专业中女性录取率反而**高于**男性。原因是女性集中在录取率低的竞争激烈专业（英语、心理），男性集中在录取率高的专业（工程、计算机）。（2 分）
- **避免方法**：① 合理分层分析，按可能的混杂变量分组检验；② 使用多变量回归控制混杂变量；③ 计算标准化率（按统一权重加权）。（任答两条即可，2 分）

第 3 题（三个原因各 1 分 + 预剪枝/后剪枝区别 3 分，共 6 分）：

- **三个原因**：① 噪声——训练数据中的噪声被树学习，导致模型复杂度过高；② 缺乏代表性样本——训练集不能充分代表全体数据；③ 多重比较——决策树在大量分裂候选中反复选择，可能偶然产生看似好的分裂。（3 分）
- **预剪枝**：在构建过程中提前停止分裂（如设定最大深度、最小样本数、最小信息增益阈值），优点：节省训练时间；缺点：可能过早停止导致欠拟合。（1.5 分）
- **后剪枝**：先构建完整决策树，再自底向上评估子树是否应替换为叶节点（基于验证集误差或成本复杂度），优点：更灵活不易欠拟合；缺点：训练开销大。（1.5 分）

第 4 题（流程 3 分 + 参数确定 3 分，共 6 分）：

- **流程**：① 原始序列 → 平稳性检验（ADF 检验，$p<0.05$ 为平稳）→ ② 若不平稳，进行差分（d 阶）直至平稳 → ③ 观察差分后序列的 ACF/PACF 图确定 p 和 q（可结合 AIC/BIC 选择）→ ④ 拟合 ARIMA(p,d,q) 模型 → ⑤ 残差诊断（Ljung-Box 检验，残差应为白噪声）→ ⑥ 通过后生成预测。（3 分）
- **参数确定**：d——通过 ADF 检验和差分次数确定，一般不超过 2；p——看 PACF 图截尾位置（偏自相关在第 p 阶后截尾）；q——看 ACF 图截尾位置（自相关在第 q 阶后截尾）。若两者均拖尾，则需尝试 ARMA(p,q)，可借助 AIC/BIC 信息准则选择最优组合。（3 分）

第 5 题（五大类各 1.2 分，共 6 分，每类需含方法名 + 简要原理）：

类别	代表方法	核心原理
基于统计	z-score / 箱图 IQR	假设数据服从某分布，落在分布尾部的点为异常
基于距离	KNN 距离	远离大部分样本的点为异常
基于密度	DBSCAN / LOF	局部密度显著低于邻居的点为异常
基于聚类	K-means + 距离阈值	聚类后不属于任何大簇的孤立点为异常

类别	代表方法	核心原理
基于模型	孤立森林 / 自编码器	学习正常模式，重构误差大或易被孤立的点为异常

（每类回答方法名 + 一句话原理即可得满分。）

三、计算题答案与评分标准

第 1 题（6 分 · TF-IDF）

(1) IDF 计算（2 分）：

词 "data" 出现在 d_1 和 d_2 中，DF = 2，N = 3。

$$IDF(data) = \ln \frac{3}{2} = \ln(1.5) \approx 0.405$$

(2) TF-IDF 计算（3 分）：

d_1 中词 "data" 出现 1 次，总词数 = 4，TF = 1/4 = 0.25。

$$TF\text{-}IDF(data, d_1) = 0.25 \times 0.405 = 0.101$$

(3) 取对数的原因（1 分）：

取对数可以压缩 IDF 的值域范围，避免当某个词只在极少数文档中出现时 IDF 值过大，使 TF-IDF 的分布更加合理。同时，对数符合信息论中信息量与概率的对数关系。

第 2 题（6 分 · z-score 比较）

(1) 标准化成绩（4 分）：

甲（数学）：$z_{甲} = \frac{132-108}{18} = \frac{24}{18} \approx 1.333$

乙（物理）：$z_{乙} = \frac{78-64}{14} = \frac{14}{14} = 1.000$

(2) 相对排名（1 分）：

甲的 z-score（1.333）> 乙的 z-score（1.000），说明甲在其所在群体中的相对位置更靠前——甲的成绩比班级平均高 1.333 个标准差，乙只高 1.000 个标准差。甲的相对排名更高。

(3) 优势与劣势（1 分）：

优势：z-score 不受原始量纲影响，可以直接比较不同科目/不同量纲的数据。 劣势：对离群点敏感（均值和标准差受极值影响）；且结果无具体物理意义，不易向非技术人员解释。

第 3 题（6 分 · 信息增益 + 增益率）

(1) 划分前 H(D)（2 分）：

$p_1 = 8/12 = 2/3$，$p_2 = 4/12 = 1/3$

$H(D) = -[\frac{2}{3}\log_2\frac{2}{3} + \frac{1}{3}\log_2\frac{1}{3}]$

$= -[\frac{2}{3}\times(-0.585) + \frac{1}{3}\times(-1.585)] = -[-0.390 - 0.528] = 0.918$

(2) 信息增益（2 分）：

A_1：$p_1 = 5/6, p_2 = 1/6$

$H(D_{A_1}) = -[\frac{5}{6}\log_2\frac{5}{6} + \frac{1}{6}\log_2\frac{1}{6}] = -[0.833\times(-0.263) + 0.167\times(-2.585)] = -[-0.219 - 0.432] = 0.651$

A_2：$p_1 = 3/6 = 1/2, p_2 = 3/6 = 1/2$，$H(D_{A_2}) = 1.000$

$H(D|A) = \frac{6}{12}\times 0.651 + \frac{6}{12}\times 1.000 = 0.326 + 0.500 = 0.826$

$Gain(D, A) = 0.918 - 0.826 = 0.092$

(3) 增益率（2 分）：

$SplitInfo = -[\frac{6}{12}\log_2\frac{6}{12} + \frac{6}{12}\log_2\frac{6}{12}] = -[0.5\times(-1) + 0.5\times(-1)] = 1.000$

$GainRatio = \frac{0.092}{1.000} = 0.092$

第 4 题（7 分 · 距离与相似度）

(1) 欧几里得距离（2 分）：

$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{(3-6)^2 + (4-8)^2} = \sqrt{9+16} = \sqrt{25} = 5$

(2) 曼哈顿距离（1 分）：

$d(\mathbf{x}_1, \mathbf{x}_3) = |3-0| + |4-5| = 3 + 1 = 4$

(3) 余弦相似度（3 分）：

$\mathbf{x}_1 \cdot \mathbf{x}_2 = 3\times 6 + 4\times 8 = 18 + 32 = 50$

$\|\mathbf{x}_1\| = \sqrt{9+16} = 5$，$\|\mathbf{x}_2\| = \sqrt{36+64} = 10$

$\cos\theta = \frac{50}{5\times 10} = \frac{50}{50} = 1$

结果为 1 说明两个向量方向完全一致——$\mathbf{x}_2 = (6, 8)$ 恰好是 $\mathbf{x}_1 = (3, 4)$ 的 2 倍，它们在空间中方向相同，仅长度不同。余弦相似度只看方向不看长度，因此完全相似。

(4) Min-Max 规范化（1 分）：

x 坐标原始值：{3, 6, 0}，min = 0，max = 6。

$x'_1 = \frac{3-0}{6-0} = 0.5$，$x'_2 = \frac{6-0}{6-0} = 1.0$，$x'_3 = \frac{0-0}{6-0} = 0$

规范化后 x 坐标：$\{0.5, 1.0, 0\}$

第 5 题（7 分 · Apriori 关联规则）

(1) 频繁 1 项集（2 分）：

扫描 8 个事务：

- {牛奶}：T1,T2,T4,T5,T6,T8 → 计数 6 ≥ 2 ✓
- {面包}：T1,T2,T3,T4,T7,T8 → 计数 6 ≥ 2 ✓
- {黄油}：T1,T3,T4,T6,T8 → 计数 5 ≥ 2 ✓

全部为频繁项集。

(2) 频繁 2 项集（3 分）：

$C_2 = L_1 \bowtie L_1$ = {{牛奶,面包}, {牛奶,黄油}, {面包,黄油}}，全部 3 个候选。

扫描计数：

- {牛奶,面包}：T1,T2,T4,T8 → 4 ≥ 2 ✓
- {牛奶,黄油}：T1,T4,T6,T8 → 4 ≥ 2 ✓
- {面包,黄油}：T1,T3,T4,T8 → 4 ≥ 2 ✓

全部 ≥ 2，C_3 = {{牛奶,面包,黄油}}。其子集 {牛奶,面包}, {牛奶,黄油}, {面包,黄油} 均在 L_2 中，无需剪枝。扫描：T1,T4,T8 → 计数 3 ≥ 2 ✓。L_3 = {{牛奶,面包,黄油}}。

(由于 L_3 只有 1 个项集，无法自连接生成 C_4，算法停止。)

(3) 规则 {黄油} → {牛奶}（2 分）：

$$\text{Support} = P(\text{黄油}, \text{牛奶}) = \frac{4}{8} = 0.5$$

$$\text{Confidence} = \frac{\text{Support}(\text{黄油},\text{牛奶})}{\text{Support}(\text{黄油})} = \frac{4/8}{5/8} = \frac{4}{5} = 0.8 = 80\%$$

$$\text{Lift} = \frac{P(\text{黄油},\text{牛奶})}{P(\text{黄油}) \times P(\text{牛奶})} = \frac{0.5}{0.625 \times 0.75} = \frac{0.5}{0.46875} \approx 1.067$$

解读：Lift ≈ 1.067 > 1，说明购买黄油对购买牛奶有微弱的正向促进作用；80% > 70%（minconf），该规则是强关联规则。

第 6 题（8 分 · 朴素贝叶斯 + 基尼指数）

(1) 朴素贝叶斯分类（5 分）：

先验（拉普拉斯平滑，α=1，类别 2）：

$$P(Yes) = \frac{6+1}{10+2} = \frac{7}{12} \approx 0.583$$

$$P(No) = \frac{4+1}{10+2} = \frac{5}{12} \approx 0.417$$

Credit（取值 A/B/C，3 种）：

	A	**B**	**C**
Yes(6)	$\frac{3+1}{6+3} = \frac{4}{9}$	$\frac{2+1}{6+3} = \frac{3}{9}$	$\frac{1+1}{6+3} = \frac{2}{9}$
No(4)	$\frac{0+1}{4+3} = \frac{1}{7}$	$\frac{1+1}{4+3} = \frac{2}{7}$	$\frac{2+1}{4+3} = \frac{3}{7}$

Income（High/Medium/Low，3 种）：

	High	Medium	Low
Yes	$\frac{3+1}{6+3}=\frac{4}{9}$	$\frac{2+1}{6+3}=\frac{3}{9}$	$\frac{1+1}{6+3}=\frac{2}{9}$
No	$\frac{0+1}{4+3}=\frac{1}{7}$	$\frac{1+1}{4+3}=\frac{2}{7}$	$\frac{3+1}{4+3}=\frac{4}{7}$

House（Yes/No，2 种）：

	Yes	No
Yes	$\frac{3+1}{6+2}=\frac{4}{8}$	$\frac{3+1}{6+2}=\frac{4}{8}$
No	$\frac{0+1}{4+2}=\frac{1}{6}$	$\frac{4+1}{4+2}=\frac{5}{6}$

新样本 {Credit=B, Income=Medium, House=No}：

$$P(Yes\|X) \propto 0.583 \times \frac{3}{9} \times \frac{3}{9} \times \frac{4}{8} = 0.583 \times 0.333 \times 0.333 \times 0.5 \approx 0.0324$$

$$P(No\|X) \propto 0.417 \times \frac{2}{7} \times \frac{2}{7} \times \frac{5}{6} = 0.417 \times 0.286 \times 0.286 \times 0.833 \approx 0.0284$$

$\because 0.0324 > 0.0284$，$\therefore$ 预测为 **Yes（批准贷款）**。

(2) 数据集基尼指数（1.5 分）：

$$Gini(D) = 1 - [(\frac{6}{10})^2 + (\frac{4}{10})^2] = 1 - [0.36 + 0.16] = 1 - 0.52 = 0.48$$

(3) 按 House 分裂（1.5 分）：

House=Yes：3 个样本 → Yes=3, No=0

- $Gini(House = Yes) = 1 - [1^2 + 0^2] = 0$

House=No：7 个样本 → Yes=3, No=4

- $Gini(House = No) = 1 - [(\frac{3}{7})^2 + (\frac{4}{7})^2] = 1 - [\frac{9}{49} + \frac{16}{49}] = 1 - \frac{25}{49} \approx 0.490$

$$Gini_{split} = \frac{3}{10} \times 0 + \frac{7}{10} \times 0.490 = 0 + 0.343 = 0.343$$

$$\Delta Gini = 0.48 - 0.343 = 0.137 > 0$$

基尼增益 ≈ 0.137 > 0，说明该分裂有效——按 House 分裂后数据纯度得到提升。

> 📝 **分数自检**：选择题 30 + 简答题 30 + 计算题 (6+6+6+7+7+8) = 30 + 30 + 40 = **100 分** ✓

> 🗓️ **最后更新**：2026 年 6 月 | **三轮复习使用建议**：本卷侧重考察一轮二轮未充分覆盖的知识点（MAC、Redis、几何平均、LOF、TF-IDF、ARIMA 参数、AdaBoost 权重、增益率、层次聚类距离），建议独立计时完成后对照解析查漏补缺。

> 🏁 **三轮资料全家福**：
>
> - DataAnalysis一轮复习.md — 原始详细讲义（地毯式覆盖）
> - DataAnalysis二轮复习.md — 知识架构 + 题型分类 + 第一套模拟卷

> - `DataAnalysis三轮复习.md` — 速记清单 + 易错陷阱 + 答题策略 + 第二套模拟卷（本文件）